Esercitazione 9

Corso di Probabilità e Statistica per l'Informatica

27 maggio 2024

Questi esercizi sono ispirati o tratti da

[EL] Epifani I., Ladelli L.M., *Esercizi di Probabilità per l'Ingegneria, le Scienze e l'Economia*, Edizioni La Dotta, 2021 (versione online scaricabile da WeBeep);

[ELP] Epifani I., Ladelli L.M., Posta G., *Appunti di calcolo delle probabilità*, (scaricabili da WeBeep);

[R] Ross S.M., *Probabilità e statistica per l'ingegneria e le scienze* (3a edizione), Apogeo, 2015.

Test e intervalli di confidenza per la differenza dei valori attesi di due popolazioni

Esercizio 9.1: Si vuole confrontare, mediante un esperimento clinico, l'efficacia di due farmaci antiallergici, che indichiamo con A e B. Su $n = 50$ pazienti che acconsentono a sottoporsi a tale esperimento, 27 selezionati a caso vengono curati con il farmaco A, mentre ai restanti 23 viene assegnato il farmaco B. Le risposte a tali farmaci da parte dei pazienti, valutate sulla base di un opportuno indice clinico adimensionale, sono indipendenti e distribuite secondo una $N(\mu_A, 0.9)$ per il farmaco A e secondo una $N(\mu_B, 0.9)$ per il farmaco B.

(a) Per mezzo di un opportuno test al livello di significatività del 5%, si decida se è evidente dai dati che $\mu_A > \mu_B$, sapendo che l'esperimento clinico ha fornito media campionaria delle risposte pari a 11.51 per il farmaco A e pari a 10.69 per il farmaco B.

(b) Si determini il p-value del test del punto (a) e se ne tragga una conclusione. È una conclusione debole o forte?

(c) Calcolare la potenza del test costruito al punto (a) quando $\mu_A = \mu_B + 0.39$.

(d) Supponendo ora di suddividere un gruppo di n volontari in due campioni ugualmente numerosi, uno per ciascun farmaco, quanto deve valere n affinché la potenza del test del punto (a) sia maggiore o uguale all'80% quando $\mu_A = \mu_B + 0.39$?

Soluzione

(a) Se vogliamo verificare se i dati mostrano evidenza che $\mu_A > \mu_B$, dobbiamo fare un test che abbia questa affermazione come ipotesi alternativa:

$$H_0 : \mu_A \leq \mu_B \quad (\text{o } H_0 : \mu_A = \mu_B) \qquad \text{contro} \qquad H_1 : \mu_A > \mu_B \,.$$

La scelta di H_0 tra le due possibilità date sopta è del tutto ininfluente; è H_1 difatti che fissa la forma della regione di rifiuto (intervallo unilatero destro, sinistro o bilatero). Siccome il testo ci dice che i due campioni sono gaussiani con varianza nota ($\sigma_A^2 = \sigma_B^2 = 0.9$ per entrambi i campioni), possiamo fare uno Z-test. La regola di rifiuto al livello α di un tale test per la differenza delle medie è

$$\text{“rifiuto } H_0 \text{ se } Z_0 = \frac{\bar{X}_A - \bar{X}_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} > z_{1-\alpha}\text{”} \,. \qquad (*)$$

Dai dati ricaviamo

$$z_0 = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} = \frac{11.51 - 10.69}{\sqrt{\frac{0.9}{27} + \frac{0.9}{23}}} = 3.046$$

Per fare il test al livello $\alpha = 5\%$, dobbiamo confrontare questo valore con il quantile

$$z_{1-\alpha} = z_{0.95} = 1.645 \,.$$

Dal momento che $z_0 = 3.046 > 1.645 = z_{0.95}$, dobbiamo rifiutare H_0 e concludiamo che $\mu_A > \mu_B$ al 5% di significatività.

(b) Il p-value si ricava imponendo nella regola (*) l'uguaglianza

$$\begin{aligned} z_0 \equiv z_{1-\alpha} \quad &\Leftrightarrow \quad \Phi(z_0) = \Phi(z_{1-\alpha}) = 1 - \alpha \\ &\Leftrightarrow \quad \alpha = 1 - \Phi(z_0) = 1 - \Phi(3.046) = 1 - \frac{0.9982 + 0.9986}{2} = 0.0016 = 0.16\% \,. \end{aligned}$$

Quindi, p-value = 0.16%, e perciò si rifiuta H_0 a tutti i livelli di significatività ragionevoli. Quando un test si conclude rifiutando H_0, la conclusione è sempre forte (si ha evidenza forte a favore di H_1).

(c) Ricordando che la differenza delle medie campionarie di due campioni gaussiani indipendenti ha *sempre* densità

$$\bar{X}_A - \bar{X}_B \sim N\left(\mu_A - \mu_B,\, \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}\right)$$

(indipendentemente dal fatto che H_0 sia vera oppure no), abbiamo

$$\begin{aligned}
\text{potenza} &= \mathbb{P}_{H_0 \text{ falsa}}\,(\text{“rifiuto } H_0\text{”}) \\
&= \mathbb{P}_{\mu_A=\mu_B+0.39}\left(\frac{\bar{X}_A-\bar{X}_B}{\sqrt{\frac{\sigma_A^2}{n_A}+\frac{\sigma_B^2}{n_B}}} > z_{1-\alpha}\right) \\
&= \mathbb{P}_{\mu_A=\mu_B+0.39}\Bigg(\underbrace{\frac{\bar{X}_A-\bar{X}_B-(\mu_A-\mu_B)}{\sqrt{\frac{\sigma_A^2}{n_A}+\frac{\sigma_B^2}{n_B}}}}_{\sim N(0,1)} > z_{1-\alpha}-\frac{\mu_A-\mu_B}{\sqrt{\frac{\sigma_A^2}{n_A}+\frac{\sigma_B^2}{n_B}}}\Bigg) \\
&= 1-\Phi\left(z_{1-\alpha}-\frac{\mu_A-\mu_B}{\sqrt{\frac{\sigma_A^2}{n_A}+\frac{\sigma_B^2}{n_B}}}\right) \qquad \text{con } \mu_A=\mu_B+0.39 \\
&= 1-\Phi\left(1.645-\frac{0.39}{\sqrt{\frac{0.9}{27}+\frac{0.9}{23}}}\right) = 1-\Phi(0.1962) = 1-\frac{0.57535+0.57926}{2} \\
&= 0.422695 = 42.2695\%\,.
\end{aligned}$$

(d) Recuperando l'espressione della potenza dal punto precedente, abbiamo

$$\begin{aligned}
\text{potenza} &= 1-\Phi\left(z_{1-\alpha}-\frac{\mu_A-\mu_B}{\sqrt{\frac{\sigma_A^2}{n_A}+\frac{\sigma_B^2}{n_B}}}\right) \qquad \text{con } \mu_A=\mu_B+0.39 \\
&= 1-\Phi\left(1.645-\frac{0.39}{\sqrt{\frac{0.9}{n/2}+\frac{0.9}{n/2}}}\right) \qquad \text{se ora } n_A=n_B=\frac{n}{2} \\
&= 1-\Phi\left(1.645-\frac{0.39}{\sqrt{\frac{3.6}{n}}}\right)\,.
\end{aligned}$$

Se vogliamo che la potenza del test sia maggiore o uguale all'80%, dobbiamo

imporre

$$
\begin{aligned}
& 1 - \Phi\left(1.645 - \frac{0.39}{\sqrt{\frac{3.6}{n}}}\right) \geq 0.80 \\
\Rightarrow \quad & \Phi\left(1.645 - \frac{0.39}{\sqrt{\frac{3.6}{n}}}\right) \leq 0.20 \\
\Rightarrow \quad & 1.645 - \frac{0.39}{\sqrt{\frac{3.6}{n}}} \leq z_{0.20} = -z_{1-0.20} = -z_{0.80} = -0.84 \\
\Rightarrow \quad & \frac{3.6}{n} \leq \left(\frac{0.39}{0.84 + 1.645}\right)^2 \\
\Rightarrow \quad & n \geq 3.6 \cdot \left(\frac{0.84 + 1.645}{0.39}\right)^2 = 146.159\,.
\end{aligned}
$$

Poiché n deve essere un numero intero, la soluzione è $n \geq 147$.

Esercizio 9.2: Le aziende H305 e Antares producono microprocessori. Il tempo di clock di uno qualsiasi di tali microprocessori (misurato in GHz) è descritto da una variabile aleatoria normale la cui varianza è nota e dipende dal processo produttivo impiegato da ciascuna azienda: nel caso di H305 la varianza è $\sigma_H^2 = 0.09\,\mathrm{GHz}^2$, nel caso di Antares è $\sigma_A^2 = 0.25\,\mathrm{GHz}^2$. L'azienda H305 sta progettando una campagna pubblicitaria comparativa nella quale intende affermare che il valore atteso μ_A del tempo di clock dei propri micoroprocessori è superiore a quello μ_B dei microprocessori prodotti dalla rivale Antares; tuttavia, ritenendo molto sconveniente fare un'affermazione di questo tipo quando in realtà è falsa, la H305 vuole essere ragionevolmente sicura di quello che dice prima di intraprendere la campagna. Vengono pertanto esaminati un campione casuale di $n_H = 35$ microprocessori H305, trovando la media campionaria $\bar{x}_H = 5.12\,\mathrm{h}$, e un campione casuale di $n_A = 25$ microprocessori Antares, trovando la media campionaria $\bar{x}_A = 4.97\,\mathrm{h}$.

(a) Si fissino le ipotesi nulla e alternativa di un test volto a dimostrare che il tempo di clock atteso dei microprocessori H305 è maggiore di quello dei microprocessori Antares. Si tragga la conclusione del test al livello di significatività del 5%.

(b) Utilizzando un opportuno stimatore non distorto, si fornisca una stima della differenza fra i tempi di clock attesi dei due tipi di processori. Si fornisca inoltre un intervallo di confidenza unilatero del tipo $(c, +\infty)$ al livel-

lo del 95% per tale differenza. Quale relazione c'è fra tale intervallo e la conclusione del test del punto precedente?

(c) Si calcoli la probabilità che il test al livello 5% del punto (a) induca la H305 a rinunciare erroneamente alla sua campagna pubblicitaria comparativa, quando in realtà $\mu_H = \mu_A + 0.1$.

(d) Mantenendo costante $n_H = 35$, si calcoli quanto dovrebbe valere n_A per ridurre la probabilità calcolata in (c) sotto il 50%.

(e) Mantenendo costante $n_H = 35$, si calcoli quanto dovrebbe valere n_A per ridurre la probabilità calcolata in (c) sotto il 10%.

Soluzione

(a) Si tratta di fare un test per le ipotesi $H_0 : \mu_H = \mu_A$ (o $H_0 : \mu_H \leq \mu_A$) vs. $H_1 : \mu_H > \mu_A$. La regola al livello di significatività α è

$$\text{“rifiuto } H_0 \text{ se } Z_0 = \frac{\bar{X}_H - \bar{X}_A}{\sqrt{\frac{\sigma_H^2}{n_H} + \frac{\sigma_A^2}{n_A}}} > z_{1-\alpha}\text{”} .$$

Si ottiene la realizzazione

$$z_0 = \frac{5.12 - 4.97}{\sqrt{\frac{0.09}{35} + \frac{0.25}{25}}} = 1.338 .$$

Poiché $z_0 = 1.338 \not> z_{1-\alpha} = z_{0.95} = 1.645$, non si può rifiutare H_0 al livello $\alpha = 5\%$.

(b) Uno stimatore non distorto della differenza $\mu_H - \mu_A$ fra i tempi di clock attesi è la differenza delle medie campionarie $\bar{X}_H - \bar{X}_A$. La stima corrispondente è la realizzazione $\bar{x}_H - \bar{x}_A = 5.12 - 4.97 = 0.15$. L'intervallo di confidenza al livello $\gamma = 95\%$ richiesto è

$$\mu_H - \mu_A \in \left(\bar{x}_H - \bar{x}_A - z_\gamma \sqrt{\frac{\sigma_H^2}{n_H} + \frac{\sigma_A^2}{n_A}} , +\infty \right) = \left(5.12 - 4.97 - 1.645 \cdot \sqrt{\frac{0.09}{35} + \frac{0.25}{25}} , +\infty \right)$$
$$= (-0.0344 , +\infty) ,$$

dove di nuovo abbiamo usato il quantile $z_\gamma = z_{0.95} = 1.645$. Per relazione di dualità fra test e intervalli di confidenza, accetto $H_0 : \mu_H - \mu_A \leq 0 =: \delta_0$ nel test unilatero al livello di significatività del 5% svolto nel punto precedente se e solo se $\delta_0 = 0$ appartiene all'$IC_{\mu_H - \mu_A}(95\%)$ ricavato adesso. E infatti è proprio quello che succede.

(c) La probabilità richiesta è la probabilità di errore di II tipo

$$\begin{aligned}
\mathbb{P}_{H_0 \text{ falsa}}(\text{“accetto } H_0\text{”}) &= \mathbb{P}_{\mu_H=\mu_A+1}\left(\frac{\bar{X}_H - \bar{X}_A}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}} \le z_{1-\alpha}\right) \\
&= \mathbb{P}_{\mu_H-\mu_A=0.1}\Bigg(\underbrace{\frac{\bar{X}_H - \bar{X}_A - (\mu_H-\mu_A)}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}}}_{N(0,1)} \le z_{1-\alpha} - \frac{(\mu_H-\mu_A)}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}}\Bigg) \\
&= \Phi\left(z_{1-\alpha} - \frac{0.1}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}}\right) = \Phi\left(1.645 - \frac{0.1}{\sqrt{\frac{0.09}{35}+\frac{0.25}{25}}}\right) \\
&= \Phi(0.753) = 0.77337 = 77.337\% \,.
\end{aligned}$$

(d) Per ridurre la probabilità di errore di II tipo sotto il 50%, deve essere

$$\begin{aligned}
&\Phi\left(z_{1-\alpha} - \frac{0.1}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}}\right) \le 50\% \quad \Rightarrow \quad z_{1-\alpha} - \frac{0.1}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}} \le 0 \\
&\Rightarrow \quad n_A \ge \frac{\sigma_A^2}{\left(\frac{0.1}{z_{1-\alpha}}\right)^2 - \frac{\sigma_H^2}{n_H}} = \frac{0.25}{\left(\frac{0.1}{1.645}\right)^2 - \frac{0.09}{35}} = 222.414 \,.
\end{aligned}$$

Occorrono pertanto almeno $n_A = 223$ microprocessori Antares.

(e) Osserviamo che la probabilità di errore di II tipo è una funzione decrescente sia di n_H sia di n_A e

$$\begin{aligned}
\lim_{n_A\to+\infty} \mathbb{P}_{H_0 \text{ falsa}}(\text{“accetto } H_0\text{”}) &= \lim_{n_A\to+\infty} \Phi\left(z_{1-\alpha} - \frac{0.1}{\sqrt{\frac{\sigma_H^2}{n_H}+\frac{\sigma_A^2}{n_A}}}\right) \\
&= \Phi\left(z_{1-\alpha} - \frac{0.1}{\sqrt{\frac{\sigma_H^2}{n_H}}}\right) = \Phi\left(1.645 - \frac{0.1}{\sqrt{\frac{0.09}{35}}}\right) = \Phi(-0.327) = 1 - \Phi(0.327) \\
&= 1 - 0.62930 = 47.070\% \,.
\end{aligned}$$

Pertanto, mantenendo costante $n_H = 35$, è impossibile ridurre tale probabilità di errore sotto il 47.070% e quindi a maggior ragione sotto il 10%. Occorre per forza aumentare anche n_H.

Esercizio 9.3: Una grossa industria vuole confrontare le caratteristiche di due resine plastiche per costruire tubature. La resina A è meno costosa della resina B, ma si sospetta che la resina B abbia un maggior allungamento medio

percentuale (capacità del materiale di allungarsi senza superare la rottura). Un campione sperimentale di numerosità 25 della resina A ha fornito un allungamento medio percentuale pari a 2.1 e una deviazione standard campionaria pari a 0.51, mentre un campione di numerosità 16 della resina B ha fornito un allungamento medio percentuale pari a 2.5 e una deviazione standard campionaria pari a 0.58. Si supponga che i campioni delle due resine siano normali, indipendenti e che le loro reali deviazioni standard siano uguali.

(a) Utilizzando un opportuno stimatore non distorto, si fornisca una stima del valore della varianza comune alle due resine.

(b) Al livello di significatività dell'2.5%, i dati a disposizione evidenziano che l'allungamento medio della resina B è maggiore di quello della resina A? Si costruisca un opportuno test statistico. *[Sì.]*

(c) Si determini il p-value del test del punto precedente.

(d) Si costruisca un intervallo di confidenza bilatero di livello del 95% per la differenza tra gli allungamenti medi delle due resine considerate.

Ora si supponga invece che $\sigma_A = \sigma_B = 0.55$ sia il vero valore delle deviazioni standard dei due campioni, *già noto* dall'esperienza passata per questo genere di misure.

(e) Con questa nuova informazione, i dati a disposizione permettono di concludere a livello del 2.5% che l'allungamento medio della resina B è maggiore di quello della resina A?

(f) Calcolare la potenza del test del punto (e) sapendo che il vero allungamento medio della resina A è pari a 1.9 e quello della resina B è 2.4.

Soluzione

(a) Uno stimatore non distorto della varianza comune σ^2 è la varianza pooled

$$S_P^2 = \frac{(n_A - 1)S_A^2 + (n_B - 1)S_B^2}{n_A + n_B - 2}\,.$$

Infatti, per verificarne la non distorsione dobbiamo dimostrare che $\mathbb{E}\left[S_P^2\right] = \sigma^2$; questa è in effetti una conseguenza immediata della linearità di $\mathbb{E}$ e del fatto che S_A^2 e S_B^2 sono stimatori non distorti di $\sigma_A^2 = \sigma_B^2 = \sigma^2$:

$$\mathbb{E}\left[S_P^2\right] = \mathbb{E}\left[\frac{(n_A - 1)S_A^2 + (n_B - 1)S_B^2}{n_A + n_B - 2}\right] = \frac{(n_A - 1)\mathbb{E}\left[S_A^2\right] + (n_B - 1)\mathbb{E}\left[S_B^2\right]}{n_A + n_B - 2}$$
$$\underset{\substack{b(S_A^2;\sigma^2)=0\\ b(S_B^2;\sigma^2)=0}}{=} \frac{(n_A - 1)\sigma^2 + (n_B - 1)\sigma^2}{n_A + n_B - 2} = \sigma^2\,.$$

Se usiamo S_P^2 come stimatore, la stima (= realizzazione sui dati) corrispondente è

$$s_P^2 = \frac{(n_A - 1)s_A^2 + (n_B - 1)s_B^2}{n_A + n_B - 2} = \frac{(25 - 1)\cdot 0.51^2 + (16 - 1)\cdot 0.58^2}{25 + 16 - 2} = 0.289446\,.$$

(b) Se cerchiamo evidenza del fatto che $\mu_B > \mu_A \Rightarrow$ dobbiamo mettere questa affermazione come ipotesi alternativa. Impostiamo dunque il test per le ipotesi

$$H_0 : \mu_A \geq \mu_B \quad (\text{o } H_0 : \mu_A = \mu_B) \qquad \text{contro} \qquad H_1 : \mu_A < \mu_B$$

Avendo a che fare con due campioni gaussiani indipendenti a varianze incognite ma uguali, possiamo fare un T-test. Con le H_0, H_1 appena scelte, la regola di rifiuto è

$$\text{“rifiuto } H_0 \text{ se } T_0 := \frac{\bar{X} - \bar{Y}}{S_P \sqrt{\frac{1}{m} + \frac{1}{n}}} < -t_{1-\alpha}(m+n-2)\text{”}$$

Dai dati otteniamo

$$t_0 = \frac{\bar{x}_A - \bar{x}_B}{s_P \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} = \frac{2.1 - 2.5}{\sqrt{0.289446}\sqrt{\frac{1}{25} + \frac{1}{16}}} = -2.3223$$

che al livello $\alpha = 2.5\%$ dobbiamo confrontare con

$$-t_{1-\alpha}(n_A + n_B - 2) = -t_{0.975}(39) \simeq -t_{0.975}(40) = -2.0211\,.$$

Dato che $-2.3223 < -2.0211$, rifiutiamo H_0 al 2.5%.

(c) Il p-value si ricava imponendo l'uguaglianza nella regola di rifiuto del test, cioè risolvendo l'equazione

$$t_0 \equiv -t_{1-\alpha}(39)\,.$$

in α. Sulle tabelle troviamo

$$-t_{0.99}(39) \simeq -t_{0.99}(40) = -2.4233 < t_0 = -2.3223 < -2.0211 = -t_{0.975}(40) \simeq -t_{0.975}(39)$$

e quindi

$$0.975 < 1 - \alpha < 0.99 \quad \Rightarrow \quad 0.01 < \alpha = p\text{-value} < 0.025\,.$$

Un p-value $\in (1\%\,,\, 2.5\%)$ è basso, e quindi abbiamo una forte evidenza in favore dell'ipotesi alternativa H_1.

(d) Un $IC_{\mu_X - \mu_Y}(\gamma)$ bilatero per i due campioni gaussiani a varianze incognite me uguali assegnati è

$$\mu_X - \mu_Y \in \left(\bar{x}_A - \bar{x}_B \pm t_{\frac{1+\gamma}{2}}(n_A + n_B - 2)\, s_P \sqrt{\frac{1}{n_A} + \frac{1}{n_B}} \right)\,.$$

Come già visto, al livello $\gamma = 95\%$ abbiamo $t_{\frac{1+\gamma}{2}}(n_A + n_B - 2) = t_{0.975}(39) \simeq 2.0211$ e quindi

$$\mu_X - \mu_Y \in \left(2.1 - 2.5 \pm 2.0211 \cdot \sqrt{0.289446} \cdot \sqrt{\frac{1}{25} + \frac{1}{16}} \right) = (-0.4 \pm 0.3481) = (-0.7481\,,\, -0.0519)\,.$$

Notiamo però che non c'è alcuna relazione di dualità col test precedente, in quanto il test era *unilatero* mentre il presente IC è *bilatero*.

(e) Le ipotesi da testare sono le stesse di prima:

$$H_0 : \mu_A \geq \mu_B \;\; (\text{o } H_0 : \mu_A = \mu_B) \qquad \text{contro} \qquad H_1 : \mu_A < \mu_B$$

Ora tuttavia, poiché le varianze sono note a priori, possiamo fare uno Z-test al posto del T-test precedente. La regola di rifiuto diventa

$$\text{“rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} < -z_{1-\alpha}\text{”}\,.$$

Poiché

$$z_0 = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} = \frac{2.1 - 2.5}{\sqrt{\frac{0.55^2}{25} + \frac{0.55^2}{16}}} = -2.272$$
$$-z_{1-\alpha} = -z_{1-0.025} = -z_{0.975} = -1.96\,.$$

abbiamo $z_0 < -z_{1-\alpha}$ con $\alpha = 2.5\%$, e quindi rifiutiamo H_0 anche in questo caso.
Notare che il p-value ora si può calcolare esattamente, ed è

$$p\text{-value} = \Phi(z_0) = \Phi(-2.272) = 1 - 0.98840 = 1.160\%\,,$$

confrontabile con quello del punto (d).

(f) La potenza è

$$\begin{aligned}
\text{potenza} &= \mathbb{P}_{H_0 \text{ falsa}}\,(\text{“rifiuto } H_0\text{”}) \\
&= \mathbb{P}_{\mu_A = 1.9,\, \mu_B = 2.4}\left(\frac{\bar{X}_A - \bar{X}_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} < -z_{1-\alpha} \right) \\
&= \mathbb{P}_{\mu_A = 1.9,\, \mu_B = 2.4}\Bigg(\underbrace{\frac{\bar{X}_A - \bar{X}_B - (\mu_A - \mu_B)}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}}}_{\sim N(0,1)} < -z_{1-\alpha} - \frac{\mu_A - \mu_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} \Bigg) \\
&= \Phi\left(-z_{1-\alpha} - \frac{\mu_A - \mu_B}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} \right) \qquad \text{con } \mu_A = 1.9,\ \mu_B = 2.4 \\
&= \Phi\left(-1.96 - \frac{1.9 - 2.4}{\sqrt{\frac{0.55^2}{25} + \frac{0.55^2}{16}}} \right) = \Phi(0.880) \\
&= 0.81057 = 81.057\%\,,
\end{aligned}$$

dove abbiamo usato il fatto che per le medie campionarie di due campioni gaussiani indipendenti vale *sempre*

$$\bar{X}_A - \bar{X}_B \sim N\left(\mu_A - \mu_B,\, \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B} \right)$$

Esercizio 9.4: Un gruppo di 6 pazienti si è sottoposto a una certa cura dimagrante. All'inizio della cura i pazienti pesavano (in Kg):

$$77.1 \qquad 87.3 \qquad 104.2 \qquad 98.9 \qquad 91.6 \qquad 78.7\,.$$

Dopo tre mesi i loro pesi sono diventati rispettivamente (sempre in Kg):

$$72.5 \qquad 88.4 \qquad 96.1 \qquad 95.7 \qquad 82.3 \qquad 69.0\,.$$

Si assuma che per un paziente qualunque le due variabili aleatorie

$$X = \text{peso prima della cura}\,, \qquad Y = \text{peso dopo la cura}$$

costituiscano un vettore gaussiano (X, Y).

(a) Si costruisca un intervallo di confidenza unilatero del tipo $(c, +\infty)$ al livello del 95% per ciascuno dei tre parametri $\mathbb{E}[X]$, $\mathbb{E}[Y]$ e $\mathbb{E}[X - Y]$.

(b) Al livello di significatività del 5% si può affermare che la cura è stata efficace, cioè che mediamente c'è stato un calo di peso? Rispondete svolgendo un opportuno test d'ipotesi.

(c) Qual è un intervallo in cui cade il p-value del test del punto precedente? Quali conclusioni ne traete?

(d) Se la cura prometteva un calo di almeno 4 Kg, si può dire allo stesso livello di sigificatività del 5% che è stata efficace? Qual è in questo caso un intervallo per il p-value? Quali conclusioni ne traete?

Soluzione

È utile innanzitutto riassumere i dati in una tabella, calcolando per ciascun paziente i-esimo la differenza $D_i = X_i - Y_i$ fra il suo peso iniziale X_i e quello finale Y_i:

paziente (i)	1	2	3	4	5	6
peso prima della cura (x_i)	77.1	87.3	104.2	98.9	91.6	78.7
peso dopo la cura (y_i)	72.5	88.4	96.1	95.7	82.3	69.0
differenze $(d_i = x_i - y_i)$	4.6	-1.1	8.1	3.2	9.3	9.7

Da questa tabella possiamo facilmente ricavare i valori di media e varianza campionarie di ciascuna riga:

$$\bar{x} = 89.633\,, \quad s_X^2 = 116.799\,, \quad \bar{y} = 84.000\,, \quad s_Y^2 = 132.560\,, \quad \bar{d} = 5.633\,, \quad s_D^2 = 17.679\,.$$

D'ora in poi indicheremo come di consueto $\mathbb{E}[X_i] = \mu_X$, $\mathbb{E}[Y_i] = \mu_Y$ e $\mathbb{E}[D_i] = \mu_D = \mu_X - \mu_Y$.

(a) Sia $X_1, \ldots, X_6$, sia $Y_1, \ldots, Y_6$, sia $D_1, \ldots, D_6$ sono campioni gaussiani, anche se ovviamente non sono indipendenti fra loro. Infatti, la non indipendenza di $D_1, \ldots, D_6$ dagli altri due campioni è ovvia, mentre la non

indipendenza di $X_1, \ldots, X_6$ da $Y_1, \ldots, Y_6$ segue dal fatto che il peso di un paziente dopo la cura dipende in generale dal peso che egli aveva all'inizio
Gli intervalli cercati al livello $\gamma = 95\%$ sono

$$\mu_X \in \left(\overline{x} - t_\gamma(n-1)\,\frac{s_X}{\sqrt{n}}\,,\, +\infty \right) = \left(89.633 - 2.0150\,\sqrt{\frac{116.799}{6}}\,,\, +\infty \right) = (80.743\,,\, +\infty)$$

$$\mu_Y \in \left(\overline{y} - t_\gamma(n-1)\,\frac{s_Y}{\sqrt{n}}\,,\, +\infty \right) = \left(84.000 - 2.0150\,\sqrt{\frac{132.560}{6}}\,,\, +\infty \right) = (74.529\,,\, +\infty)$$

$$\mu_D \in \left(\overline{d} - t_\gamma(n-1)\,\frac{s_D}{\sqrt{n}}\,,\, +\infty \right) = \left(5.633 - 2.0150\,\sqrt{\frac{17.679}{6}}\,,\, +\infty \right) = (2.175\,,\, +\infty)$$

dove abbiamo sostituito $n = 6$ e $t_\gamma(n-1) = t_{0.95}(5) = 2.0150$.

(b) Dobbiamo decidere fra le ipotesi statistiche

$$H_0 : \mu_X = \mu_Y \quad (\Leftrightarrow\ \mu_D = 0\,) \qquad \text{vs.} \qquad H_1 : \mu_X > \mu_Y \quad (\Leftrightarrow\ \mu_D > 0\,)\,.$$

Possiamo farlo impostando un test per la differenza dei valori attesi di dati gaussiani accoppiati. La regola di tale test al livello di significatività α è

$$\text{“rifiuto } H_0 \text{ se } T_0 := \frac{\bar{D}}{S}\sqrt{n} > t_{1-\alpha}(n-1)\text{”}\,.$$

Con $\alpha = 5\%$ e $n = 6$ ritroviamo il quantile $t_{1-\alpha}(n-1) = t_{0.95}(5) = 2.0150$ già usato al punto (a). Dai dati ricaviamo invece la realizzazione

$$t_0 := \frac{5.633}{\sqrt{17.679}}\sqrt{6} = 3.282\,.$$

Poiché $t_0 > t_{0.95}(5)$, dobbiamo rifiutare H_0 al livello di significatività del 5%. Ciò è consistente con l'$IC_{\mu_D}(95\%)$ unilatero trovato al punto precedente, in quanto il valore $\delta_0 = 0$ in effetti non appartiene a tale intervallo.

(c) Per trovare il p-value, imponiamo l'uguaglianza nella regola di rifiuto e risolviamo rispetto a α:

$$\begin{aligned} t_0 \equiv t_{1-\alpha}(5) \quad &\Rightarrow \quad 2.5706 = t_{0.975}(5) < 3.282 = t_{1-\alpha}(5) < t_{0.99}(5) = 3.3649 \\ &\Rightarrow \quad 0.975 < 1-\alpha < 0.99 \quad \Rightarrow \quad 0.01 < \alpha < 0.025\,. \end{aligned}$$

In altre parole, $1\% < p\text{-value} < 2.5\%$. Con un p-value così piccolo, possiamo rifiutare H_0 e accettare H_1 (conclusione forte). C'è quindi evidenza dai dati che la cura dimagrante funziona.

(d) Ora dobbiamo fare un test per le ipotesi

$$H_0 : \mu_X - \mu_Y \le 4 \quad (\Leftrightarrow\ \mu_D \le 4\,) \qquad \text{vs.} \qquad H_1 : \mu_X - \mu_Y > 4 \quad (\Leftrightarrow\ \mu_D > 4\,)\,.$$

Posto $\delta_0 = 4$, possiamo ripetere lo stesso tipo di test precedente, in cui ora la regola è

$$\text{“rifiuto } H_0 \text{ se } T_0 := \frac{\bar{D} - \delta_0}{S}\sqrt{n} > t_{1-\alpha}(n-1)\text{”}\,.$$

Anche qui, per svolgere il test al livello di significatività $\alpha = 5\%$ non occorre ricalcolare la realizzazione della statistica test T_0 e ricavare un'altra volta il quantile $t_{1-\alpha}(n-1)$ dalle tavole. Basta semplicemente osservare che $\delta_0 = 4$ cade dentro l'$IC_{\mu_D}(95\%)$ unilatero duale che abbiamo calcolato nel punto (a), cioè $(2.175\,,\,+\infty)$, e quindi non possiamo rifiutare H_0. È necessario invece ricalcolare la realizzazione della statistica test per determinare il nuovo p-value. Si ha

$$t_0 = \frac{5.633 - 4}{17.679}\sqrt{6} = 0.952$$

e quindi questa volta bisogna risolvere rispetto a α l'equazione

$$\begin{aligned} 0.952 \equiv t_{1-\alpha}(5) \quad &\Rightarrow \quad 0.9195 = t_{0.80}(5) < 0.952 = t_{1-\alpha}(5) < t_{0.85}(5) = 1.1558 \\ &\Rightarrow \quad 0.80 < 1-\alpha < 0.85 \quad \Rightarrow \quad 0.15 < \alpha < 0.20\,. \end{aligned}$$

Con un p-value compreso fra il 15% e il 20% non c'è nessuna evidenza contro l'ipotesi nulla $H_0 : \mu_X - \mu_Y \leq 4$. In altre parole, i dati non dimostrano che la cura abbia mediamente prodotto il calo di peso promesso (conclusione debole).

Esercizio 9.5: Si teme che nel prossimo referendum non venga raggiunto il quorum (percentuale dei votanti superiore al 50%).

(a) Per prevedere se il quorum verrà raggiunto, si vuole costruire un intervallo di confidenza bilatero di livello 0.99 per la proporzione p dei votanti. A tale scopo, si intervistano n persone scelte a caso nella popolazione degli elettori e si chiede loro se si recheranno alle urne. Quanto grande deve essere n affinchè l'intervallo abbia ampiezza al più pari a 0.02?

(b) Si supponga che in Lombardia, su 1000 persone intervistate, ve ne siano 480 che dichiarano che si recheranno alle urne. I dati a disposizione consentono di affermare che in Lombardia il quorum non verrà raggiunto, con livello di significatività del 5%?

(c) Supponiamo inoltre che in Emilia Romagna su 1000 persone intervistate solo 427 si dichiarino intenzionate a votare. Tenendo conto dei dati al punto (b), possiamo concludere che in Lombardia la percentuale di votanti sarà maggiore che in Emilia Romagna, con livello di significatività ancora del 5%?

Soluzione

(a) Abbiamo un campione bernoulliano di numerosità n, con $X_i \sim B(1,p)$, dove p è la probabilità incognita che un elettore a caso vada a votare. Un $IC_p(\gamma)$ bilatero è

$$p \in \left(\bar{x} - z_{\frac{1+\gamma}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \, , \, \bar{x} + z_{\frac{1+\gamma}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \right) ,$$

la cui ampiezza è

$$\delta = 2\, z_{\frac{1+\gamma}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \leq 2\, z_{\frac{1+\gamma}{2}} \sqrt{\frac{\frac{1}{4}}{n}} = \frac{1}{\sqrt{n}}\, z_{\frac{1+\gamma}{2}} \, .$$

in quanto $\bar{x}(1-\bar{x}) \in [0\,,\, 1/4]$ *sempre*. Se vogliamo essere sicuri che $\delta \leq 0.02$, basta richiedere

$$\begin{aligned} \frac{1}{\sqrt{n}}\, z_{\frac{1+\gamma}{2}} \leq 0.02 \quad \Rightarrow \quad n \geq \left(\frac{z_{\frac{1+\gamma}{2}}}{0.02} \right)^2 = \left(\frac{z_{0.995}}{0.02} \right)^2 \qquad \text{al livello } \gamma = 0.99 \\ = \left(\frac{2.575}{0.02} \right)^2 = 16576.56 \, . \end{aligned}$$

Bisogna quindi intervistare almeno $n = 16577$ persone.

(b) Chiedersi se i dati a disposizione consentono di affermare che in Lombardia il quorum *non* verrà raggiunto significa cercare evidenza forte del fatto che la proporzione p di votanti è minore del 50%. Questa affermazione va quindi messa come ipotesi alternativa:

$$H_0 : p \geq 0.5 \;\; (\text{o } H_0 : p = 0.5) \qquad \text{contro} \qquad H_1 : p < 0.5 \, .$$

La regola di un test al livello α per le ipotesi precedenti è

$$\text{“rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X} - 0.5}{\sqrt{0.5 \cdot (1-0.5)}} \sqrt{n} < -z_{1-\alpha} \text{”} \, ,$$

dove $\bar{x}$ è la frequenza empirica di votanti. Coi dati dell'esercizio,

$$n = 1000 \qquad \bar{x} = \frac{480}{1000} = 0.48 \quad \Rightarrow \quad z_0 = \frac{0.48 - 0.5}{\sqrt{0.5 \cdot (1-0.5)}} \sqrt{1000} = -1.265 \, ,$$

che al 5% va confrontata col quantile

$$-z_{1-\alpha} = -z_{1-0.05} = -z_{0.95} = -1.645 \, .$$

Dal momento che $-1.265 \not< -1.645$, H_0 non si rifiuta e quindi *non* possiamo affermare che in Lombardia il quorum *non* verrà raggiunto (conclusione debole a favore di $H_0 : p \geq 0.5$).

(c) Ora abbiamo un nuovo campione di altri 1000 intervistati in Emilia Romagna, che chiameremo $Y_1, \dots, Y_{1000}$ ($X_1, \dots, X_{1000}$ era il campione della Lombardia). Anche le Y_i sono bernoulliane, ma, per distinguere il loro parametro incognito da quello degli intervistati in Lombardia, chiamiamo p_{ER} e p_L le rispettive probabilità (p_L è la vecchia p dei punti (a) e (b)). Ora si richiede di fare un test per le ipotesi

$$H_0 : p_L \leq p_{ER} \qquad \text{contro} \qquad H_1 : p_L > p_{ER}\,.$$

Si tratta di un test per la differenza delle frequenze. Una regola di rifiuto al livello α è

$$\text{“rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X} - \bar{Y}}{\sqrt{\hat{P}(1-\hat{P})\left(\frac{1}{m} + \frac{1}{n}\right)}} > z_{1-\alpha}\text{”}\,.$$

Abbiamo già trovato $\bar{x}$ al punto precedente, mentre ora in più ci viene detto che $\bar{y} = \frac{427}{1000} = 0.427$. Dobbiamo ancora calcolare

$$\hat{p} = \frac{m\bar{x} + n\bar{y}}{m+n} = \frac{480 + 427}{1000 + 1000} = 0.4535$$

e quindi

$$z_0 = \frac{0.480 - 0.427}{\sqrt{0.4535 \cdot (1 - 0.4535) \cdot \left(\frac{1}{1000} + \frac{1}{1000}\right)}} = 2.381\,.$$

Al livello $\alpha = 5\%$, questo valore è maggiore di $z_{1-\alpha} = z_{0.95} = 1.645$, e di conseguenza possiamo rifiutare H_0 (conclusione forte a favore di $H_1 : p_L > p_{ER}$).

Test di adattamento e d'indipendenza

Esercizio 9.6: Un provider per il collegamento internet afferma che i suoi abbonati riescono a connettersi immediatamente nel 50% dei casi, con un'attesa maggiore di 0 minuti ma inferiore a 1 minuto nel 40% dei casi e infine con un'attesa maggiore di 1 minuto nel restante 10% dei casi. Per verificare l'affermazione del provider, un utente decide di annotare i tempi di attesa da lui sperimentati in 70 tentativi di collegamento e ottiene i seguenti risultati:

	linea libera	attesa ≤ 1 min	attesa > 1 min	totale
Num. tentativi	37	22	11	70

Sottoponete a test, al livello di significatività dell'1%, l'affermazione H_0 : “il provider ha ragione”. Determinate il p-value dei dati, o almeno un intervallo in

cui cade il p-value.

Soluzione
Per ogni $i = 1, \dots, n$ sia X_i la variabile aleatoria

$$X_i = \begin{cases} 1 & \text{se l'}i\text{-esimo tentativo riesce immediatamente}\,, \\ 2 & \text{se l'}i\text{-esimo tentativo richiede un tempo compreso tra 0 e 1 minuti}\,, \\ 3 & \text{se l'}i\text{-esimo tentativo richiede più di 1 minuto}\,. \end{cases}$$

Allora $X_1, \dots, X_n$ è un campione aleatorio estratto da una densità discreta p incognita. Sia $p_0 : \{1, 2, 3\} \to [0, 1]$ la densità dichiarata dal provider, cioè $p_0(1) = 0.5$, $p_0(2) = 0.4$, $p_0(3) = 0.1$. Quanto affermato dal provider va messo nell'ipotesi nulla

$$H_0 : p = p_0\,,$$

che confronteremo con l'alternativa

$$H_1 : H_0 \text{ è falsa}\,.$$

Per ogni $h \in \{1, 2, 3\}$ indichiamo con O_h la variabile aleatoria che conta per quante volte il valore h viene preso dalle n variabili $X_1, \dots, X_n$. Abbiamo la tabella

h	1	2	3
o_h	37	22	11
$p_0(h)$	0.5	0.4	0.1
$np_0(h)$	35	28	7

e $n = 37 + 22 + 11 = 70$ è il numero totale dei tentativi. Notiamo che per ogni h si ha $np_0(h) > 5$, quindi è soddisfatta la condizione per fare un test del chi-quadrato di buon adattamento alla densità completamente specificata p_0. In tale test, si rifiuta l'ipotesi nulla H_0 al livello di significatività α se

$$T_0 > \chi^2_{1-\alpha}(k-1)\,,$$

dove T_0 è la statistica

$$T_0 = \sum_{h=1}^{3} \frac{(O_h - np_0(h))^2}{np_0(h)} \overset{\substack{\text{se } H_0 \\ \text{è vera}}}{\approx} \chi^2(k-1) = \chi^2(2)$$

e $k = 3$ sono le classi. Dai dati forniti otteniamo la realizzazione

$$t_0 = \frac{4}{35} + \frac{36}{28} + \frac{16}{7} = 3.6857$$

Al livello $\alpha = 1\%$ assegnato nel testo abbiamo $\chi^2_{1-\alpha}(2) = \chi^2_{0.99}(2) = 9.2104$. Poiché $t_0 = 3.6857 \not> \chi^2_{1-\alpha}(2) = 9.2104$, non possiamo rifiutare l'ipotesi nulla a tale livello. Notiamo che $3.2189 = \chi^2_{0.80}(2) < 3.6857 = \chi^2_{1-\alpha}(2) < 3.7942 = \chi^2_{0.85}(2)$, quindi il p-value del test è compreso fra il 15% e il 20%. Perciò non solo non possiamo possiamo rifiutare H_0 all'1%, ma neanche agli altri usuali livelli del 2.5% e del 5%.

Esercizio 9.7: Il tempo di esecuzione del programma `xxx` sul calcolatore `yyy` è compreso fra 60 e 120 minuti primi. Vogliamo verificare se questo tempo può essere modellizzato con una variabile aleatoria X assolutamente continua con densità

$$f_0(x) = \frac{1}{1800}(x-60)\,\mathbb{1}_{(60,120)}(x)\,.$$

A tal fine, su ciascuno di 75 calcolatori tutti del tipo `yyy` che lavorano indipendentemente l'uno dall'altro, abbiamo lanciato il programma `xxx` e registrato i tempi di esecuzione. Seguono i risultati sperimentali ottenuti:

Classi	$[60,75)$	$[75,80)$	$[80,95)$	$[95,105)$	$[105,110)$	$[110,120]$
Num. osservazioni	6	8	20	17	10	14

Sulla base dei dati raccolti, verificate con un opportuno test se la densità f_0 fornisce un buon modello probabilistico per il tempo di esecuzione del programma `xxx` su un calcolatore del tipo `yyy`.

Soluzione
Introduciamo la variabile aleatoria

$$X = \text{tempo di esecuzione del programma } \texttt{xxx} \text{ sul calcolatore } \texttt{yyy}\,.$$

Dobbiamo fare un test per le ipotesi

$$H_0 : X \sim f_0 \qquad \text{vs.} \qquad H_1 :\ H_0 \text{ è falsa}\,.$$

Posto $C_1 = [60,75)$, $C_2 = [80,95)$, $\ldots$, $C_6 = [110,120]$, le probabilità teoriche $p_0(h) = \mathbb{P}_{H_0 \text{ vera}}(X \in C_h)$ sono

$$p_0(1) = \mathbb{P}_{H_0 \text{ vera}}(60 \le X < 75) = \int_{60}^{75} \frac{1}{1800}(x-60)dx = \left.\frac{(x-60)^2}{3600}\right|_{60}^{75} = 0.0625$$

$$p_0(2) = \mathbb{P}_{H_0 \text{ vera}}(75 \le X < 80) = \left.\frac{(x-60)^2}{3600}\right|_{75}^{80} = 0.0486$$

$$p_0(3) = \mathbb{P}_{H_0 \text{ vera}}(80 \le X < 95) = \left.\frac{(x-60)^2}{3600}\right|_{80}^{95} = 0.2292$$

$$p_0(4) = \mathbb{P}_{H_0 \text{ vera}}(95 \le X < 105) = \left.\frac{(x-60)^2}{3600}\right|_{95}^{105} = 0.2222$$

$$p_0(5) = \mathbb{P}_{H_0 \text{ vera}}(105 \le X < 110) = \left.\frac{(x-60)^2}{3600}\right|_{105}^{110} = 0.1319$$

$$p_0(6) = \mathbb{P}_{H_0 \text{ vera}}(110 \le X < 120) = \left.\frac{(x-60)^2}{3600}\right|_{110}^{120} = 0.3056$$

Siccome $np_0(1) = 4.69$ e $np_0(2) = 3.65$ sono entrambi minori di 5, raggruppiamo C_1 e C_2 in un'unica classe C_1', ottenendo così la seguente tabella:

C'_h	$[60, 80)$	$[80, 95)$	$[95, 105)$	$[105, 110)$	$[110, 120]$
o'_h	14	20	17	10	14
$p'_0(h)$	0.1111	0.2292	0.2222	0.1319	0.3056
$np'_0(h)$	8.333	17.190	16.665	9.893	22.920

Con questa suddivisione in classi, il test di buon adattamento alla densità assolutamente continua f_0 diventa dunque un test di buon adattamento alla densità discreta p'_0, in cui le ipotesi statistiche sono

$$H_0 : X' \sim p'_0 \qquad \text{vs.} \qquad H_1 : \ H_0 \text{ è falsa}\,.$$

Nell'ipotesi nulla, la variabile aleatoria X' è la versione 'discretizzata' della variabile originaria X, cioè

$$X' = \begin{cases} 1 & \text{se } X \in [60, 80)\,, \\ 2 & \text{se } X \in [80, 95)\,, \\ \dots & \dots\,. \end{cases}$$

La regola del test al livello di significatività α è

$$\text{"rifiuto } H_0 \text{ se } T_0 = \sum_{h=1}^{5} \frac{(O'_h - np'_0(h))^2}{np'_0(h)} > \chi^2_{1-\alpha}(k-1)\text{"}\,,$$

dove $k = 5$ è il numero di classi. Valutando la statistica test T_0 coi dati assegnati otteniamo la realizzazione $t_0 = 7.7927$, che è compresa tra $\chi^2_{0.90}(4) = 7.7794$ e $\chi^2_{0.95}(4) = 9.4877$. Il p-value è dunque compreso tra il 5% e il 10%, e perciò non si può rifiutare l'ipotesi nulla H_0 agli usuali livelli di significatività dell'1%, 2.5% e 5%.

Esercizio 9.8: Da un'indagine su scala nazionale per valutare le prospettive d'impiego dei laureati in Ingegneria è emerso che un ingegnere neolaureato guadagna uno stipendio mensile X, che è una variabile aleatoria gaussiana di media $\mu_0 = 1350\,€$ e deviazione standard $\sigma_0 = 400\,€$. Abbiamo intervistato un campione di 100 ingegneri del Politecnico al loro primo impiego, chiedendo a ciascuno qual è il suo stipendio mensile. Le risposte sono state suddivise in tre fasce secondo la tabella seguente.

	$< 1100\,€$	tra $1100\,€$ e $1600\,€$	$> 1600\,€$
numero di risposte	19	51	30

1. Stabilite con un test opportuno se al livello di significatività del 5% i dati della nostra inchiesta sono compatibili con la distribuzione degli stipendi a livello nazionale.

2. Determinare un intervallo bilatero di confidenza 95% per la probabilità che un ingegnere del Politecnico guadagni più di 1600 €.

Nel nostro campione di 100 intervistati, ci sono 7 ingegneri informatici. La media delle loro risposte è stata $\bar{x}_7 = 1680\,€$. Si può supporre che gli stipendi $X_1 \dots X_7$ dei 7 informatici siano un campione gaussiano da una popolazione a media μ incognita e con la stessa deviazione standard $\sigma_0 = 400\,€$ della distribuzione nazionale.

3. Al livello di significatività del 5%, i dati evidenziano che il guadagno medio degli ingegneri informatici sia maggiore dei 1350 € della media nazionale?

Soluzione

1. Dobbiamo fare un test di adattamento dei nostri dati alla densità teorica $X \sim N(\mu_0, \sigma_0^2)$. Poichè i dati sono raggruppati in tre intervalli, bisogna calcolare la probabilità teorica di ciascuno di essi, cioè

$$\begin{aligned} p_0(1) &= \mathbb{P}\left(X < 1100\right) = \mathbb{P}\left(\frac{X-\mu_0}{\sigma_0} < \frac{1100-1350}{400}\right) = \Phi\left(\frac{1100-1350}{400}\right) = \Phi(-0.625) \\ &= 1 - \Phi(0.625) \simeq 1 - \frac{0.7324 + 0.7357}{2} = 0.26595 \\ p_0(3) &= \mathbb{P}\left(X > 1600\right) = \mathbb{P}\left(\frac{X-\mu_0}{\sigma_0} > \frac{1600-1350}{400}\right) = 1 - \Phi\left(\frac{1600-1350}{400}\right) \\ &= 1 - \Phi(0.625) \simeq 0.26595 \\ p_0(2) &= \mathbb{P}\left(1100 \le X \le 1600\right) = 1 - p_0(1) - p_0(3) \simeq 0.4681\,. \end{aligned}$$

La tabella riassuntiva è

	$< 1100\,€$	tra $1100\,€$ e $1600\,€$	$> 1600\,€$
numerosità empiriche	19	51	30
numerosità teoriche	$100 \cdot 0.26595 = 26.595$	$100 \cdot 0.4681 = 46.81$	$100 \cdot 0.26595 = 26.595$

Se p è la densità incognita delle tre classi, dobbiamo quindi fare un test per le ipotesi

$$H_0 : p = p_0 \qquad \text{contro} \qquad H_1 : p \neq p_0\,.$$

Osserviamo che tutte le numerosità teoriche sono > 5 e quindi è rispettata la regola per cui almeno l'80% delle $np_0(i)$ deve essere > 5 e tutte devono essere > 1. Possiamo quindi fare un test del chi-quadro di buon adattamento a una densità discreta completamente specificata. La statistica test da usare è

$$T_0 = \sum_{h=1}^{3} \frac{O_h^2}{np_0(h)} - n$$

e dai dati otteniamo la realizzazione

$$\begin{aligned} t_0 &= \frac{19^2}{26.595} + \frac{51^2}{46.81} + \frac{30^2}{26.595} - 100 \\ &\simeq 2.9800\,. \end{aligned}$$

La regione di rifiuto è

$$T_0 > \chi^2_{0.95}(2) = 5.9915\,,$$

e pertanto al 5% accettiamo H_0, cioè i neolaureati del Politecnico rispettano la distribuzione nazionale.

2. Dobbiamo calcolare un $IC_q(95\%)$ bilatero per la probabilità q che un ingegnere del Politecnico che guadagnano più di 1600 €. L'intervallo è del tipo

$$q \in \left(\hat{q} \pm z_{\frac{1+\gamma}{2}} \sqrt{\frac{\hat{q}(1-\hat{q})}{n}} \right)$$

dove

$$\hat{q} = \frac{30}{100} = 0.3$$

e

$$z_{\frac{1+\gamma}{2}} = z_{\frac{1+0.95}{2}} = z_{0.975} = 1.96\,.$$

Pertanto, al 95% di confidenza,

$$q \in \left(0.3 \pm 1.96 \cdot \sqrt{\frac{0.3(1-0.3)}{100}} \right) = (21.018\%\,,\, 38.982\%)\,.$$

3. Si richiede di fare un test per le ipotesi

$$H_0 : \mu = \mu_0 \qquad \text{contro} \qquad H_1 : \mu \neq \mu_0\,.$$

Si tratta di uno Z-test unilatero, in cui la statistica test è

$$z = \frac{1680 - 1350}{400}\sqrt{7} = 2.183$$

e la regione di rifiuto è

$$z > z_{0.95} = 1.645\,.$$

In base ai nostri dati, dobbiamo pertanto rifiutare H_0 al 5% di significatività, e concludere che c'è una forte evidenza del fatto che il guadagno medio degli informatici è maggiore della media nazionale.

Esercizio 9.9: Recita la guida all'immatricolazione in rete: La prova d'ammissione per i corsi di studio delle Facoltà di Ingegneria ha carattere orientativo:

gli studenti sono invitati a valutarne seriamente l'esito e l'indice attitudinale che ne consegue... La prova d'ammissione rappresenta la verifica di un'adeguata preparazione iniziale... Abbiamo i dati riguardanti un campione di 960 studenti provenienti dal liceo scientifico, 125 dal liceo classico e 287 dagli istituti tecnici. Hanno raggiunto il punteggio minimo di sufficiente preparazione iniziale 509 studenti del liceo scientifico, 67 del liceo classico e 122 degli istituti tecnici.

1. Sulla base di questi dati, l'adeguatezza della preparazione iniziale è legata al tipo di scuola di provenienza?

Supponiamo ora che, comunque sia andata la prova d'ammissione, tutti gli studenti del campione considerato abbiano deciso di iscriversi a un corso di ingegneria.

2. Dopo aver fornito una stima puntuale della proporzione q di matricole del prossimo anno accademico provenienti dagli istituti tecnici, determinate un intervallo asintotico di confidenza 90% per q.

3. Negli anni passati, i neo-iscritti al Politecnico si sono sempre ripartiti tra liceo scientifico, liceo classico e istituto tecnico nelle proporzioni 70%, 10%, 20%, rispettivamente. Effettuate un test al 5% di significatività per stabilire se, in base al nostro campione, anche quest'anno le matricole si distribuiscono in accordo con questa distribuzione oppure no.

Soluzione

1. La situazione si può riassumere con la tabella che segue: le sigle LS, LC e IT indicano le provenienze scolastiche, cioè rispettivamente liceo scientifico, liceo classico e istituto tecnico; alla fine di ogni riga è riportato il totale della riga ($o_{h,\bullet}$); alla fine di ogni colonna è riportato il totale della colonna ($o_{\bullet,k}$):

	LS	LC	IT	
Positivo	$o_{1,1} = 509$	$o_{1,2} = 67$	$o_{1,3} = 122$	$o_{1,\bullet} = 698$
Negativo	$o_{2,1} = 451$	$o_{2,2} = 58$	$o_{2,3} = 165$	$o_{2,\bullet} = 674$
	$o_{\bullet,1} = 960$	$o_{\bullet,2} = 125$	$o_{\bullet,3} = 287$	Tot. $= n = 1372$

Si testano le ipotesi statistiche

H_0 : la provenienza scolastica e l'esito della prova di ammissione sono indipendenti

$$H_1 : H_0 \text{ è falsa}.$$

Introtta la statistica

$$T_0 = n\left(\sum_{h=1}^{2}\sum_{k=1}^{3}\frac{(O_{h,k})^2}{O_{h,\bullet}O_{\bullet,k}} - 1\right)$$

si ha

$$T_0 \approx \chi^2((2-1)(3-1)) = \chi^2(2) \qquad \text{se } H_0 \text{ è vera}.$$

La regola di un test di livello di significatività α per le ipotesi statistiche precedenti è dunque

$$\text{“rifiuto } H_0 \text{ se } T_0 > \chi^2_{1-\alpha}(2)\text{”}\,.$$

La realizzazione della statistica test coi dati a disposizione è

$$\begin{aligned} t_0 =& 1372 \cdot \left(\frac{509^2}{698 \cdot 960} + \frac{67^2}{698 \cdot 125} + \frac{122^2}{698 \cdot 287} \right. \\ &\left. + \frac{451^2}{674 \cdot 960} + \frac{58^2}{674 \cdot 125} + \frac{165^2}{674 \cdot 287} - 1 \right) = 10.1780\,. \end{aligned}$$

Abbiamo

$$\begin{gathered} 9.2104 = \chi^2_{0.99}(2) < 10.1780 = \chi^2_{1-p\text{-value}}(2) < 10.5965 = \chi^2_{0.995}(2) \\ \Rightarrow \quad 0.5\% < p\text{-value} < 1\%\,. \end{gathered}$$

Con un p-value così piccolo c'è una forte evidenza a favore di H_1. Possiamo pertanto abbastanza tranquillamente concludere che la preparazione dipende effettivamente dal tipo di scuola.

2. La stima puntuale per la proporzione q di matricole provenienti da istituti tecnici è $\hat{q} = o_{\bullet,3}/n = 287/1372 = 0.20918$. L'intervallo di confidenza (asintotico) per q di livello γ è invece

$$\left(\hat{q} \pm z_{\frac{1+\gamma}{2}} \sqrt{\frac{\hat{q}(1-\hat{q})}{n}} \right)\,.$$

Con i dati a disposizione e con $\gamma = 90\%$ si ha che l'intervallo richiesto è

$$\begin{gathered} \left(0.20918 \pm 1.645 \cdot \sqrt{\frac{0.20918 \cdot (1 - 0.20918)}{1372}} \right) \\ = (19.112\%\,,\, 22.725\%)\,. \end{gathered}$$

3. Se per ogni $i = 1, \ldots, n$ definiamo

$$Y_i = \text{scuola di provenienza dell'}i\text{-esimo studente}\,,$$

allora Y_i è una variabile aleatoria discreta a valori nell'insieme $\{\mathrm{LS}, \mathrm{LC}, \mathrm{IT}\}$. (In realtà, chiamare Y_i *variabile aleatoria* è leggermente improprio, in quanto le variabili aleatorie per definizione possono prendere soltanto valori numerici; ci si riconduce tuttavia facilmente al caso numerico sostituendo per esempio LS $\to$ 1, LC $\to$ 2 e IT $\to$ 3.) Inoltre, $Y_1, \ldots, Y_n$ è un campione aleatorio. Indicando con p la densità da cui sono estratte le Y_i, possiamo riformulare la domanda dell'esercizio usando le ipotesi statistiche

$$H_0 : p = p_0 \qquad \text{vs.} \qquad H_1 : H_0 \text{ è falsa}\,,$$

dove

$$p_0(\text{LS}) = 0.7 \quad p_0(\text{LC}) = 0.1 \quad p_0(\text{IT}) = 0.2\,.$$

L'esercizio chiede se i dati di quest'anno sono compatibili con H_0 oppure no. Dobbiamo quindi fare un test di buon adattamento alla densità completamente specificata p_0. La statistica test da usare è

$$\begin{aligned} t_0 &= \sum_{h=1}^{3} \frac{o_{\bullet,h}^2}{np_0(h)} - n = \frac{960^2}{1372 \cdot 0.7} + \frac{125^2}{1372 \cdot 0.1} + \frac{287^2}{1372 \cdot 0.2} - 1372 \\ &= 1.6636\,, \end{aligned}$$

che va confrontata con il quantile

$$\chi^2_{0.95}(3-1) = \chi^2_{0.95}(2) = 5.9915\,.$$

Poiché $t_0 < \chi^2_{0.95}(2)$, non possiamo rifiutare l'ipotesi nulla al livello di significatività del 5%. A tale livello, non possiamo quindi escludere che anche quest'anno gli studenti siano ripartiti tra le diverse scuole di provenienza come negli anni passati.

Esercizio 9.10: Il corso di statistica viene insegnato dallo stesso docente in 3 diversi corsi di laurea: fisica, matematica e ingegneria. I risultati dei 3 corsi sono riassunti nella seguente tabella:

	fisica	matematica	ingegneria
promossi	50	15	30
bocciati	37	8	40

Sulla base di questi dati, possiamo affermare che ci sia dipendenza tra il corso di laurea e il livello di preparazione degli studenti?

Soluzione

Definiamo le classi nel modo seguente:

	1	2	3
1	$o_{1,1} = 50$	$o_{1,2} = 15$	$o_{1,3} = 30$
2	$o_{2,1} = 37$	$o_{2,2} = 8$	$o_{2,3} = 40$

Completiamo la tabella aggiungendo sotto e a destra le rispettive numerosità marginali, ottenute sommando sulle relative colonne e righe:

	1	2	3	
1	$o_{1,1} = 50$	$o_{1,2} = 15$	$o_{1,3} = 30$	$o_{1,\bullet} = 95$
2	$o_{2,1} = 37$	$o_{2,2} = 8$	$o_{2,3} = 40$	$o_{2,\bullet} = 85$
	$o_{\bullet,1} = 87$	$o_{\bullet,2} = 23$	$o_{\bullet,3} = 70$	

La numerosità del campione è

$$n = o_{1,\bullet} + o_{2,\bullet} = o_{\bullet,1} + o_{\bullet,2} + o_{\bullet,3} = 180.$$

Vogliamo decidere fra le ipotesi statistiche

$$H_0 : \text{corso di laurea e il livello di preparazione sono indipendenti}$$
$$H_1 : H_0 \text{ è falsa}\,.$$

Possiamo farlo impostando un test del chi-quadrato di indipendenza, in cui la regola è

$$\text{“rifiuto } H_0 \text{ se } T_0 = n\left(\sum_{h=1}^{r}\sum_{k=1}^{s}\frac{O_{h,k}^2}{O_{h,\bullet}O_{\bullet,k}} - 1\right) > \chi^2_{1-\alpha}((r-1)(s-1))\text{”}\,,$$

dove $r = 3$ e $s = 2$ indicano rispettivamente il numero di corsi e il numero di esiti possibili. Coi dati a disposizione troviamo la realizzazione

$$\begin{aligned} t_0 &= 180 \cdot \left(\frac{50^2}{87\cdot 95} + \frac{15^2}{23\cdot 95} + \frac{30^2}{70\cdot 95} + \frac{37^2}{87\cdot 85} + \frac{8^2}{23\cdot 85} + \frac{40^2}{70\cdot 85} - 1\right) \\ &\simeq 4.9613 \end{aligned}$$

(N.B.: Nel calcolo precedente, attenzione a non approssimare ciascun termine della somma in modo troppo grossolano, altrimenti si rischia di trovare un valore molto diverso per t_0!). I quantili della densità $\chi^2((r-1)(s-1)) = \chi^2(2)$ più vicini al valore di t_0 sono

$$\chi^2_{0.90}(2) = 4.6052\,, \qquad \chi^2_{0.95}(2) = 5.9915\,.$$

Pertanto, imponendo l'uguaglianza $t_0 \equiv \chi^2_{1-\alpha}((r-1)(s-1))$ nella regola di rifiuto, troviamo

$$0.90 < 1 - \alpha < 0.95 \quad \Rightarrow \quad 0.05 < \alpha < 0.10\,.$$

In altre parole, il p-value è compreso fra il 5% e il 10%. Non possiamo dunque rifiutare H_0 agli usuali livelli di significatività del 5%, 2.5% e 1%.

Attenzione: Per poter applicare il test di indipendenza, è necessario che $n\hat{p}_X(h)\hat{p}_Y(k) = o_{h,\bullet}o_{\bullet,k}/n \geq 1$ (rispettivamente, ≥ 5) per tutte le h, k (risp., per almeno l'80% delle h, k). Si può facilmente (e tediosamente...) verificare che entrambe le condizioni sono soddisfatte, in quanto il valore di $n\hat{p}_X(h)\hat{p}_Y(k)$ più piccolo si ottiene per $(h, k) = (2, 2)$ ed è 10.861. Perciò, tutti i valori di $n\hat{p}_X(h)\hat{p}_Y(k)$ sono ≥ 5 e quindi a maggior ragione ≥ 1. La condizione di applicabilità del test è quindi soddisfatta.