I appello di Probabilità e Statistica per l'Informatica

F. Bassetti, I. Epifani, L. Ladelli

14.06.2022

Cognome e Nome:
Codice persona: **Docente:**

© I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.
Giustificare adeguatamente tutte le risposte.

1 Domande di teoria

D 1 Siano X e Y due variabili aleatorie.

(a) Dare la definizione di covarianza di X e Y, ossia $\mathrm{Cov}(X,Y)$.

(b) Discutere la veridicità delle seguenti affermazioni

- X e Y sono indipendenti se e solo se $\mathrm{Cov}(X,Y)=0$.
- Se X e Y sono indipendenti allora $\mathrm{Cov}(X,Y)=0$.
- Se $\mathrm{Cov}(X,Y)=\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}$ allora $P(Y=aX+b)=1$ per opportuni a,b.
- Se X,Y sono congiuntamente gaussiane e $\mathrm{Cov}(X,Y)=0$, allora X e Y sono indipendenti.

Soluzione

(a) Si veda la Definizione 4.8.1 pag. 96 degli Appunti di calcolo delle probabilità di Epifani, Ladelli, Posta, AA 2019/20.

(b) X,Y sono indipendenti se e solo se ammettono una densità congiunta che può essere scritta come prodotto delle densità marginali, allora

$$\mathrm{E}(XY)=\iint_{\mathbb{R}^2} st f_{X,Y}(s,t)dsdt=\iint_{\mathbb{R}^2} st f_X(s)f_Y(t)dsdt=\int_{\mathbb{R}} sf_X(s)ds\times\int_{\mathbb{R}} tf_Y(t)dt=\mathrm{E}(X)\,\mathrm{E}(Y)$$

(I conti precedenti sono tutti leciti se $\mathrm{Cov}(X,Y)$ esiste). Quindi la seconda affermazione è vera.
La prima affermazione è invece falsa: come controesempio si veda l'Esempio 4.8.5 pag. 97 degli Appunti di calcolo delle probabilità di Epifani, Ladelli, Posta, AA 2019/20.
La terza affermazione è vera infatti,

$$\mathrm{Cov}(X,Y)=\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}\ \text{ sse }\ \rho=\rho(X,Y)=\frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}=1$$

allora X,Y sono linearmente positivamente dipendenti con probabilità uno (si veda la proprietà 6 della Proposizione 4.8.2 pag. 96 degli Appunti di calcolo delle probabilità di Epifani, Ladelli, Posta, AA 2019/20 che non abbiamo dimostrato). Infine, anche la quarta affermazione è vera dal momento che se $\mathrm{Cov}(X,Y)=0$ ogni densità gaussiana bivariata fattorizza nel prodotto delle due densità marginali, gaussiane anche esse. ∎

D 2
Sia $T_n=g_n(X_1,\dots,X_n)$ uno stimatore di $\tau=\tau(\vartheta)$ basato sul campione $(X_1,\dots,X_n)$ per cui

$$\mathrm{E}_\vartheta(T_n)=\tau(\vartheta)\times\left(1+\frac{2}{n}\right)\ \text{ e }\ \mathrm{Var}_\vartheta(T_n)=\frac{\vartheta^2+1}{n+3}\qquad\forall\vartheta,\ \forall n$$

(a) Definire le proprietà di non distorsione, non distorsione asintotica e consistenza (in media quadratica).

(b) $\{T_n\}_n$ è una successione di stimatori asintoticamente non distorta per τ? È consistente in media quadratica? Rispondere motivando la risposta.

Soluzione

(a) Si vedano appunti/lucidi del proprio docente.

(b) Si ha $\lim_{n\to\infty} \mathrm{E}_\vartheta(T_n) = \lim_{n\to\infty} \tau(\vartheta) \times (1 + 2/n) = \tau(\vartheta)\ \forall\vartheta$, quindi $\{T_n\}_n$ è asintoticamente non distorta.
Segue dalla decomposizione dell'errore quadratico medio in varianza di T_n e quadrato della sua distorsione che $\{T_n\}_n$ è consistente in media quadratica per τ se e solo $\{T_n\}_n$ è asintoticamente non distorta per τ e $\mathrm{Var}_\vartheta(T_n) \to 0$ per $n \to \infty$, $\forall\vartheta \in \Theta$. Resta da verificare la seconda condizione:

$$\lim_{n\to\infty} \mathrm{Var}_\vartheta(T_n) = \lim_{n\to\infty} \frac{\vartheta^2 + 1}{n + 3} = 0 \qquad \forall\vartheta \in \Theta$$

Si conclude che $\{T_n\}_n$ è anche consistente in media quadratica. ∎

D 3

(a) Dare la definizione di livello di significatività di un test di ipotesi.

(b) In un test d'ipotesi il p-value è 0.043. Indicare quali delle seguenti tre affermazioni sono vere e quali false, motivando la scelta:

- rifiuto l'ipotesi nulla con significatività 0.043;
- con livello di significatività $\alpha = 0.05$ rifiuto l'ipotesi nulla;
- con livello di significatività $\alpha = 0.05$ accetto l'ipotesi nulla.

Soluzione

(a) Per la definizione di significatività si veda pagina 293 (righe 16-21) della Sezione 8.2 di S. Ross, *Probabilità e Statistica per l'Ingegneria e le Scienze*, 2015, Maggioli o gli appunti di lezione.

(b) Il p-value rappresenta il *"valore di significatività critico, scendendo al di sotto del quale la decisione cambia da rifiuto ad accettazione"* (da Ross (2015) ultime tre righe di pag. 296) per i dati arrivati. Segue che se p-value= 0.043 allora la prima e la seconda affermazione sono vere e la terza è falsa. ∎

2 Esercizi

Esercizio 1 Con un certo protocollo di trasmissione si trasmette un numero X e si riceve il numero Y. Si supponga che $X \sim \mathbf{Be}(0.8)$ e che la trasmissione sia soggetta ad errore. In particolare, se $X = 1$ allora il risultato della trasmissione è $Y = 1$ con probabilità 0.9 (non c'è errore di trasmissione) e $Y = 0$ con probabilità 0.1 (c'è errore di trasmissione). Analogamente, se $X = 0$ allora con probabilità 0.8 il segnale è trasmesso correttamente cioè $Y = 0$, mentre con probabilità 0.2 si ha $Y = 1$.

(a) Determinare la probabilità che il segnale venga trasmesso correttamente.

(b) Determinare la probabilità di ricevere il segnale $Y = 0$.

(c) Determinare la probabilità che il segnale sia stato trasmesso correttamente avendo ricevuto $Y = 0$.

Soluzione

(a) Sia C l'evento il segnale viene trasmesso correttamente. Allora

$$C = \{X = 0, Y = 0\} \cup \{X = 1, Y = 1\}$$

quindi

$$\begin{aligned} P(C) &= P\{X = 0, Y = 0\} + P\{X = 1, Y = 1\} \\ &= P\{Y = 0|X = 0\}P\{X = 0\} + P\{Y = 1|X = 1\}P\{X = 1\} \\ &= 0.8 \cdot 0.2 + 0.9 \cdot 0.8 = 0.88. \end{aligned}$$

(b) Per la formula delle probabilità totali

$$P\{Y = 0\} = P\{Y = 0|X = 0\}P\{X = 0\} + P\{Y = 0|X = 1\}P\{X = 1\} = 0.8 \cdot 0.2 + 0.1 \cdot 0.8 = 0.24.$$

(c) $P\{C|Y = 0\} = P\{X = 0|Y = 0\}$ e per il Teorema di Bayes

$$P\{X = 0|Y = 0\} = \frac{P\{Y = 0|X = 0\}P\{X = 0\}}{P\{Y = 0\}} = \frac{0.8 \cdot 0.2}{0.24} = 0.666\bar{7}. \quad \blacksquare$$

Esercizio 2 Sia (X, Y) un vettore con legge assolutamente continua con densità

$$f(x, y) = 4x^2 \mathbf{1}\{0 < y \leq x < 1\}.$$

(a) Determinare la densità marginale di X e la densità condizionale di Y dato X: le variabili X e Y sono indipendenti?

(b) Calcolare $P\Big(Y \leq \dfrac{5}{27}X\Big)$.

(c) Si supponga che $(X_1, Y_1) \dots (X_{100}, Y_{100})$ siano indipendenti e identicamente distribuite con comune densità $f(x, y)$. Calcolare un valore approssimato della probabilità che almeno 20 volte $Y \leq \dfrac{5}{27}X$.

Soluzione

(a) Si ha per x in $(0, 1)$

$$f_X(x) = \int_{\mathbb{R}} f(x, y)dy = 4\int_0^x x^2 dy = 4x^3,$$

ed altrove $f_X(x) = 0$.
Per x in $(0, 1)$ si ha

$$f(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{1}{x}\mathbf{1}\{0 < y \leq x\},$$

ossia $Y|X = x$ ha legge uniforme su $(0, x)$. Dal momento che la densità condizionale di Y dato X dipende da X le variabili non possono essere indipendenti.

(b) Si ha

$$\begin{aligned} P\Big(Y \leq \frac{5}{27}X\Big) &= \int_0^1 \int_0^1 \mathbf{1}\Big\{0 < y \leq \frac{5}{27}x\Big\} f(x, y)dxdy \\ &= \int_0^1 \int_0^1 \mathbf{1}\Big\{0 < y \leq \frac{5}{27}x\Big\} 4x^2 \mathbf{1}\Big\{0 < y \leq x < 1\Big\} dxdy \\ &= \int_0^1 \int_0^{\frac{5}{27}x} 4x^2 dydx = \frac{5}{27}\int_0^1 4x^3 dx = \frac{5}{27} \end{aligned}$$

(c) Sia $W =$ "n^0 di volte in cui $Y < 5X/27$ nel campione". Allora W rappresenta il numero di successi in $n = 100$ prove di Bernoulli con probabilità di successo $p = P(Y \leq 5X/27) = 5/27$, quindi $W \sim \mathbf{Bi}(100, 5/27)$ e la probabilità cercata è $P(W \geq 20)$. Poiché $n(1-p) > np = 100 \times 5/27 \simeq 18.52 > 5$, si usa l'approssimazione gaussiana del t.c.l. con la correzione di continuità:

$$\begin{aligned} P(W \geq 20) &= 1 - P(W \leq 19.5) = 1 - P\left(\frac{W - np}{\sqrt{np(1-p)}} \leq \frac{19.5 - 100 \times 5/27}{\sqrt{100 \times 5/27 \times 22/27}}\right) \\ &\simeq 1 - \Phi(0.25) = 1 - 0.5987 = 0.4013. \end{aligned}$$

Senza la correzione di continuità si ha $P(W \geq 20) \simeq 0.4483$; infine il valore esatto di $P(W \geq 20)$ arrotondato alla quarta cifra decimale è $P(W \geq 20) \simeq 0.3906$. ∎

Esercizio 3 [1] Sono stati raccolti i seguenti 400 dati relativi a età della madre e peso alla nascita del figlio:

	Peso del neonato < 2500 g	Peso del neonato ≥ 2500 g
Età della madre ≤ 30 anni	20	80
Età della madre > 30 anni	30	270

(a) Il peso di un bambino alla nascita è indipendente dall'età della madre? Rispondere usando un opportuno test di ipotesi.

(b) Si restringa ora l'attenzione alle madri di età ≤ 30 anni. Fornire una stima puntuale e una stima intervallare bilatera di confidenza approssimata pari al 92% per la probabilità p che un bambino pesi alla nascita meno di 2500 gr.

SOLUZIONE

(a) Le ipotesi da verificare sono H_0: *"peso del bambino alla nascita ed età della madre sono indipendenti"* e H_1: *"H_0 è falsa"*. La statistica test X^2_* del test di indipendenza del chi quadrato è

$$X^2_* = \sum_{i=1}^{r}\sum_{j=1}^{s} \frac{(N_{ij} - n\hat{p}_i\hat{q}_j)^2}{n\hat{p}_i\hat{q}_j} = n\sum_{i=1}^{r}\sum_{j=1}^{s} \frac{N^2_{ij}}{N_{i\cdot}N_{\cdot j}} - n$$

con

$$N_{i\cdot} = \sum_{j=1}^{c} N_{ij}, \quad N_{\cdot j} = \sum_{i=1}^{r} N_{ij}, \quad n\widehat{p}_i\widehat{q}_j = \frac{1}{n}\sum_{i=1}^{r} N_{ij} \times \sum_{j=1}^{c} N_{ij} \qquad \text{per } r = c = 2,\ n = 400$$

quindi

N_{ij}	$j=1$	$j=2$	$N_{i\cdot}$
$i=1$	20	80	$=100$
$i=2$	30	270	$=300$
$N_{\cdot j}$	$=50$	$=350$	$n=400$

e

$n\widehat{p}_i\widehat{q}_j$	$j=1$	$j=2$
$i=1$	12.5	87.5
$i=2$	37.5	262.5

X^2_* vale $x^2_* \simeq 6.857$ e si rifiuta H_0 con significatività α se $x^2_* \geq \chi^2_\alpha\left((r-1)\times(c-1)\right) = \chi^2_\alpha(1)$. Dalle tavole si ricava $\chi^2_{0.01}(1) \simeq 6.635$ e $\chi^2_{0.005}(1) \simeq 7.880$. Ne segue che il p-value del test è compreso fra 0.5% e 1% e dunque a tutti gli usuali livelli di significatività si può rifiutare l'indipendenza fra età della madre e peso del bambino alla nascita.

(b) Sia p la probabilità che il neonato pesi meno di 2500 gr, se la mamma ha ≤ 30 anni. Allora una stima di p è

$$\hat{p} = \frac{20}{100} = 0.2$$

Un IC di confidenza approssimata $1-\alpha = 92\%$ per la proporzione p di una popolazione bernoulliana, con un campione numeroso $n = 100$ ha estremi

$$p \in \widehat{p} \pm z_{\alpha/2}\sqrt{\frac{\widehat{p}\,(1-\widehat{p})}{n}} \simeq 0.2 \pm 1.75\sqrt{\frac{0.2\times 0.8}{100}} = 0.2 \pm 0.07$$

cioè con confidenza 92% si ritiene che $0.13 < p < 0.27$. ∎

[1] Tratto da: S. Ross, *Probabilità e Statistica per l'Ingegneria e le Scienze,* 2015, Maggioli.

Esercizio 4 Sia $X_1, \ldots, X_n$ un campione aleatorio di dimensione n estratto da una popolazione di densità

$$f_\vartheta(x) = \vartheta x^{-(\vartheta+1)} \mathbf{1}_{(1,+\infty)}(x)$$

con $\vartheta > 0$ incognito.

1. Determinare lo stimatore di massima verosimiglianza di ϑ e dedurre lo stimatore di massima verosimiglianza $\widehat{T}_n$ di $\kappa(\vartheta) = \dfrac{1}{\vartheta}$.
2. Determinare la densità di $Y_i = \ln(X_i)$ e riconoscerla.
3. Determinare la distorsione e l'errore quadratico medio di $\widehat{T}_n$ come stimatore di $k(\vartheta) = \dfrac{1}{\vartheta}$. Quali proprietà ha tale stimatore? Qual è la sua distribuzione asintotica?

SOLUZIONE

1. La funzione di verosimiglianza è

$$L(\vartheta) = \prod_{i=1}^n f_\vartheta(x_i) = \prod_{i=1}^n \vartheta x_i^{-(\vartheta+1)} \mathbf{1}_{(1,+\infty)}(x_i) = \vartheta^n \prod_{i=1}^n x_i^{-(\vartheta+1)}$$

   e la log-verosimiglianza è

$$\ell(\vartheta) = n \ln(\vartheta) - (\vartheta + 1) \sum_{i=1}^n \ln(x_i)$$

   Si cerca il punto di massimo:

$$\ell'(\vartheta) = \frac{n}{\vartheta} - \sum_{i=1}^n \ln(x_i) \geq 0 \qquad \Longleftrightarrow \qquad \vartheta \leq \frac{n}{\sum_{i=1}^n \ln(x_i)},$$

   quindi l'M.L.E. di ϑ è $\widehat{\Theta}_n = \dfrac{n}{\sum_{i=1}^n \ln(X_i)}$ e per il Principio di invarianza l'M.L.E. di $k(\vartheta) = \dfrac{1}{\vartheta}$ è $\widehat{T}_n = \dfrac{\sum_{i=1}^n \ln(X_i)}{n}$.

2. $P(Y_i = \ln(X_i) > 0) = 1$ poiché $P(X_i > 1) = 1$. Quindi $F_{Y_i}(t) = P(Y_i \leq t) = 0$ per $t < 0$. Se $t \geq 0$

$$F_{Y_i}(t) = P(\ln(X_i) \leq t) = P(X_i \leq \mathrm{e}^t) = \int_1^{\mathrm{e}^t} \vartheta x^{-(\vartheta+1)} dx = 1 - \mathrm{e}^{-\vartheta t}.$$

   Quindi $\ln(X_i) \sim \mathcal{E}(\vartheta)$.

3. $\mathrm{E}_\vartheta(\widehat{T}_n) = \mathrm{E}_\vartheta(\ln(X_1)) = 1/\vartheta$ per il punto precedente e quindi lo stimatore è non distorto per $1/\vartheta$. Inoltre, per la non distorsione $MSE_\vartheta(\widehat{T}_n) = \mathrm{Var}_\vartheta(\widehat{T}_n) = \mathrm{Var}_\vartheta(\ln(X_1))/n = 1/n\vartheta^2 \to 0$ per $n \to +\infty$. Quindi la successione di stimatori $(\widehat{T}_n)_n$ è consistente in media quadratica. Infine per il t.c.l. asintoticamente $\widehat{T}_n \approx \mathcal{N}(1/\vartheta, 1/n\vartheta^2)$. ∎