II Appello di PSI del 02.07.2022, **Studenti Ing Inf (L),** **Docente L.Ladelli**

Cognome e Nome	Matr.

Il compito va svolto su questi fogli. Potete usare anche il retro dei fogli.

Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.
Scrivere le soluzioni in modo ordinato e con grafia leggibile.

Tempo: 2 ore e 30 minuti.

1 Domande di teoria

D 1

(a) Enunciare e dimostrare la formula delle probabilità totali

(b) Se ad un esame scritto a distanza, l'80% degli studenti è promosso e fra gli studenti promossi il 21% copiano, mentre fra i bocciati copia il 13%, qual è la probabilità che uno studente scelto a caso copi?

Soluzione

(a) Si veda la Proposizione 1.5.9 pag. 18 degli Appunti di calcolo delle probabilità di Epifani, Ladelli, Posta, AA 2019/20.

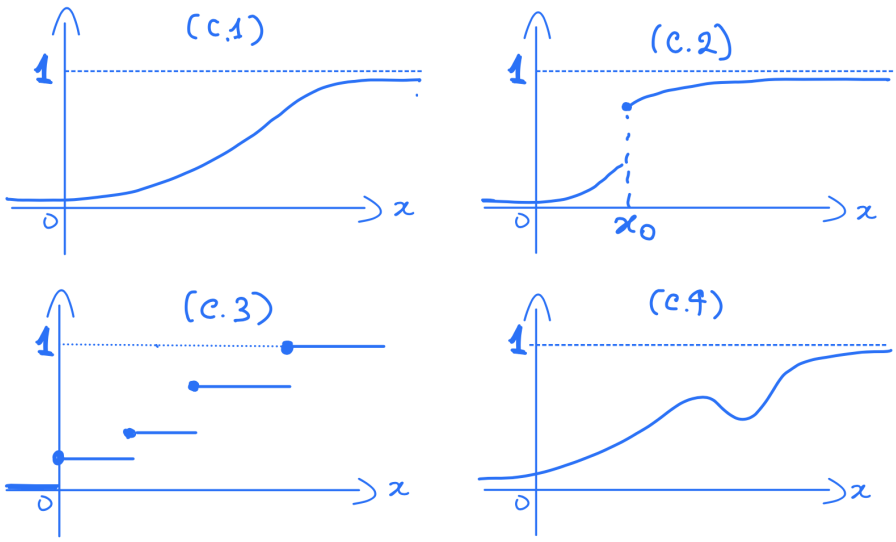
(b) Sia C l'evento "lo studente copia" e B l'evento "lo studente è bocciato". Applicando la formula delle probabilità totali si ottiene

$$P(C) = P(C|B)P(B) + P(C|B^c)P(B^c) = 0.13 \times 0.20 + 0.21 \times 0.80 = 0.1940 \quad \blacksquare$$

D 2

(a) Fornire la definizione di funzione di ripartizione e le proprietà della funzione di ripartizione F_X di una variabile aleatoria X.

(b) Stabilire per ciascuna delle seguenti funzioni graficate se sono funzioni di ripartizione di una variabile aleatoria X oppure no e perché. Dire quali di queste corrispondono ad una variabile aleatoria discreta.



Soluzione

(a) Si vedano: la Definizione 2.1.7 pag. 30 e la Proposizione 2.1.10 pag. 32 degli Appunti di calcolo delle probabilità di Epifani, Ladelli, Posta, AA 2019/20.

(b) (c.1) e (c.2) sono funzioni di ripartizione perchè godono delle proprietà che le caratterizzano (vedi punto (a); (c.3) è una funzione di ripartizione di una v.a. discreta perchè oltre ad avere le proprietà caratterizzanti le funzioni di ripartizione è costante a tratti; (c.4) NON è una f.d.r. perché non è monotona non decrescente. ∎

D 3 Siano $x_1, \ldots, x_n$ i valori osservati del campione aleatorio $X_1, \ldots, X_n$ estratto dalla popolazione f_ϑ con $\vartheta \in \Theta$ parametro incognito.

(a) Fornire la definizione di stimatore di massima verosimiglianza $\hat{\Theta}_{ML}$ di ϑ.

(b) Sia ora $\hat{\vartheta}_{ML}$ la stima di massima verosimiglianza di ϑ e $L_\vartheta(x_1, \ldots, x_n)$ la funzione di verosimiglianza. Segnare le affermazioni sempre vere con V e le altre con F:

- ☐ se il campione è numeroso $\hat{\vartheta}_{ML} \simeq \dfrac{\sum_{j=1}^n \ln x_j}{n}$
- ☐ $\hat{\vartheta}_{ML}$ è un punto di massimo assoluto di $L_\vartheta(x_1, \ldots, x_n)$
- ☐ $\hat{\vartheta}_{ML}$ è il punto in cui si annulla la derivata prima (rispetto a ϑ) del logaritmo della verosimiglianza
- ☐ Se $\hat{\Theta}_{ML} = \dfrac{\sum_{j=1}^n X_j}{n}$ con $\mathrm{E}_\vartheta(X_1) = \vartheta$ e $\mathrm{Var}_\vartheta(X_1) = 1 + \vartheta^2$, la successione di stimatori $\{\hat{\Theta}_{ML}\}_n$ è asintoticamente gaussiana.

Soluzione

(a) Dati $x_1, \ldots, x_n$ la corrispondente stima di massima verosimiglianza è un qualunque $\hat{\vartheta}_{ML} = \hat{\vartheta}_{ML}(x_1, \ldots, x_n)$ tale che

$$\hat{\vartheta}_{ML}(x_1, \ldots, x_n) \in \mathrm{argmax}_\Theta L_\vartheta(x_1, \ldots, x_n).$$

La stimatore di massima verosimiglianza è $\hat{\Theta}_{ML} = \hat{\vartheta}_{ML}(X_1, \ldots, X_n)$.

(b)
- [F] se il campione è numeroso $\hat{\vartheta}_{ML} \simeq \dfrac{\sum_{j=1}^n \ln x_j}{n}$
- [V] $\hat{\vartheta}_{ML}$ è un punto di massimo assoluto di $L_\vartheta(x_1, \ldots, x_n)$
- [F] $\hat{\vartheta}_{ML}$ è il punto in cui si annulla la derivata prima (rispetto a ϑ) del logaritmo della verosimiglianza
- [V] Se $\hat{\Theta}_{ML} = \dfrac{\sum_{j=1}^n X_j}{n}$ con $\mathrm{E}_\vartheta(X_1) = \vartheta$ e $\mathrm{Var}_\vartheta(X_1) = 1 + \vartheta^2$, la successione di stimatori $\{\hat{\Theta}_{ML}\}_n$ è asintoticamente gaussiana. ∎

2 Esercizi

Esercizio 1 Un'urna contiene palline rosse e nere nelle proporzioni di $\frac{1}{3}$ e $\frac{2}{3}$, rispettivamente. Si estraggono con reimmissione 3 palline dall'urna (in sequenza) e sia X la v.a. che conta il numero delle palline rosse tra le prime due estratte e Y la v.a. che conta il numero delle palline nere tra le ultime due estratte.

(a) Determinare le densità discrete congiunta e marginali di X e Y (riportarle in forma di tabella).

(b) Calcolare $\mathrm{E}(X), \mathrm{E}(Y), \mathrm{Var}(X), \mathrm{Var}(Y)$ e $\mathrm{Cov}(X, Y)$.

(c) Posto $W = X - Y$ mostrare che $\mathrm{Var}(W) = 4/3$.

(d) Determinare il minimo numero n di osservazioni $W_1, \ldots, W_n$ i.i.d. che bisogna estrarre dalla popolazione W affinchè sia maggiore di 0.9 la probabilità che la distanza (in modulo) fra la media campionaria $\overline{W}_n$ di questo campione e la media teorica $\mathrm{E}(W) = \mu$ non superi 0.11, cioè che risulti soddisfatta la disuguaglianza $P(|\overline{W}_n - \mu| \leq 0.11) > 0.9$.

Soluzione

(a)

$X \setminus Y$	Y=0	Y= 1	Y=2	p_X
$X = 0$	0	4/27	8/27	12/27
$X = 1$	2/27	6/27	4/27	12/27
$X = 2$	1/27	2/27	0	3/27
p_Y	3/27	12/27	12/27	1

Infatti

$$
\begin{aligned}
&P(X = 0, Y = 0) = P(X = 2, Y = 2) = 0 \\
&P(X = 0, Y = 1) = P(NNR) = \frac{1}{3} \times \frac{4}{9} = \frac{4}{27} \\
&P(X = 0, Y = 2) = P(NNN) = \frac{8}{27} \\
&P(X = 1, Y = 0) = P(NRR) = \frac{2}{27} \\
&P(X = 1, Y = 1) = P(NRN \cup RNR) = \frac{4}{27} + \frac{2}{27} = \frac{6}{27} \\
&P(X = 1, Y = 2) = P(RNN) = \frac{4}{27} \\
&P(X = 2, Y = 0) = P(RRR) = \frac{1}{27} \\
&P(X = 2, Y = 1) = P(RRN) = \frac{2}{27}
\end{aligned}
$$

(b) Si osservi che Y ha la stessa distribuzione di $2 - X$ e quindi

$$\mathrm{Var}(Y) = \mathrm{Var}(X) = \mathrm{E}(X^2) - (\mathrm{E}(X))^2 = \frac{4}{9}$$

in quanto:

$$
\begin{aligned}
\mathrm{E}(X) &= \frac{12}{27} + 2 \times \frac{3}{27} = \frac{18}{27} = \frac{2}{3} \\
\mathrm{E}(X^2) &= 1 \times \frac{12}{27} + 4 \times \frac{3}{27} = \frac{24}{27} = \frac{8}{9}
\end{aligned}
$$

Poi

$$\mathrm{Cov}(X,Y) = \mathrm{E}(XY) - \mathrm{E}(X)\,\mathrm{E}(Y) = \frac{2}{3} - \frac{8}{9} = -\frac{2}{9}$$

in quanto

$$\mathrm{E}(XY) = \frac{1\times 6}{27} + \frac{2\times 4}{27} + \frac{2\times 2}{27} = \frac{2}{3} \quad \mathrm{E}(X) = \frac{2}{3} \quad \mathrm{E}(Y) = 2 - \mathrm{E}(X) = \frac{4}{3}$$

(c) Usando il punto precedente si ha

$$\mathrm{Var}(W) = \mathrm{Var}(X) + \mathrm{Var}(Y) - 2\,\mathrm{Cov}(X,Y) = 2\Big(\frac{4}{9} + \frac{2}{9}\Big) = \frac{4}{3}$$

(d) Per il teorema centrale del limite, per $n >> 0$ e posto $\sigma^2 = \mathrm{Var}(W)$, si ha

$$P(|\overline{W} - \mu| \le 0.11) \simeq 2\Phi\Big(\sqrt{n}\frac{0.11}{\sigma}\Big) - 1$$

quindi si cerca l'n tale che

$$2\Phi\Big(\sqrt{n}\frac{0.11}{\sigma}\Big) - 1 > 0.9 \text{ ossia } \Phi\Big(\sqrt{n}\frac{0.11}{\sigma}\Big) > 0.95 \text{ ossia } \sqrt{n}\frac{0.11}{\sigma} > z_{0.05}$$

ossia

$$\sqrt{n} > \frac{\sigma z_{0.05}}{0.11} \simeq \frac{2/\sqrt{3}\times 1.645}{0.11}$$

Si ottiene $n > (4/3)\times 1.645^2/0.11^2 \simeq 298.1846$, cioè l'$n$ cercato è $n^* = 299$.

Nota Se si risolve il problema con la diseguaglianza di Chebychev

$$P(|\overline{W} - \mu| \le 0.11) \ge 1 - \frac{\mathrm{Var}(W)/n}{0.11^2}$$

si ottiene

$$n > \frac{\mathrm{Var}(W)}{0.11^2\times(1-0.9)} \simeq 1101.928 \quad \text{quindi} \quad n^{**} = 1102 \qquad \blacksquare$$

Esercizio 2 Il tempo di vita (espresso in ore) di un componente elettronico può essere rappresentato dalla variabile aleatoria $T = X^2$ e X ha densità:

$$f_X(x;\vartheta) = \begin{cases} \frac{5\vartheta^5}{x^6} & \text{se } x > \vartheta \\ 0 & \text{se } x \le \vartheta \end{cases} \qquad \text{con } \vartheta > 0$$

(a) Determinare la media $\mathrm{E}_\vartheta(T)$ di T, la varianza $\mathrm{Var}_\vartheta(T)$ di T e la standardizzata di T

(b) Se $\vartheta = 12$ e si sa che il componente sta funzionando ininterrottamente da 169 ore, quanto vale la probabilità che continuerà a funzionare per almeno altre 27 ore?

In realtà ϑ è incognito ma abbiamo le osservazioni

$$t_1 = 652.6, \;\; t_2 = 552.8, \;\; t_3 = 52.9, \;\; t_4 = 132.4$$

di un campione aleatorio $T_1, \ldots, T_n \overset{\text{i.i.d.}}{\sim} T$ dei tempi di vita di $n = 4$ componenti elettronici.

(c) Determinare lo stimatore dei momenti di ϑ e la relativa stima per le osservazioni fornite.

Soluzione

(a) $\mathrm{E}_\vartheta(T) = \mathrm{E}_\vartheta(X^2) = \displaystyle\int_\vartheta^{+\infty} x^2 \times \frac{5\vartheta^5}{x^6}\, dx = \ldots = \frac{5}{3}\vartheta^2$

$\mathrm{Var}_\vartheta(T) = \mathrm{E}_\vartheta(T^2) - (\mathrm{E}_\vartheta(T))^2 = \dfrac{20}{9}\vartheta^4$

in quanto

$\mathrm{E}_\vartheta(T^2) = \mathrm{E}(X^4) = \displaystyle\int_\vartheta^{\infty} x^4 \times \frac{5\vartheta^5}{x^6}\, dx = \ldots = 5\vartheta^4.$

Infine la standardizzata di T è

$$Z := \frac{T - \frac{5}{3}\vartheta^2}{\sqrt{\frac{20}{9}\vartheta^4}} = \frac{3T/\vartheta^2 - 5}{2\sqrt{5}}$$

(b) Si tratta di calcolare

$$P(T > 169+27 | T > 169) = \frac{P(T > 196)}{P(T > 169)} = \frac{P(X^2 > 196)}{P(X^2 > 169)} = \frac{P(X > 14)}{P(X > 13)} = \ldots = \frac{\frac{\vartheta^5}{14^5}}{\frac{\vartheta^5}{13^5}} = \frac{13^5}{14^5} \simeq 0.6904$$

(c) Per le osservazioni $t_1, \ldots, t_n$ l'equazione

$$\bar{t}_n = \mathrm{E}_\vartheta(T) = \frac{5}{3}\vartheta^2$$

ha soluzione

$$\hat{\vartheta}_n = \sqrt{\frac{3}{5}\bar{t}_n}$$

Segue che lo stimatore dei momenti di ϑ esiste, è unico ed è dato da $\widehat{\Theta}_n = \sqrt{\frac{3}{5}\overline{T}_n}$. In corrispondenza dei tempi di vita dei 4 componenti elettronici che ci sono stati forniti, abbiamo $\bar{t}_4 = 347.675$ e quindi $\hat{\vartheta}_4 \simeq \sqrt{208.605} \simeq 14.4432$. ∎

Esercizio 3 Per confrontare la complessità temporale degli algoritmi di ordinamento `Merge Sort` e `Tim Sort`, sono stati registrati i tempi di esecuzione in **decimi di secondi** di `Merge Sort` e `Tim Sort`, per due dataset distinti entrambi di $m = n = 100$ array. Su questi due dataset sono state ottenute le seguenti statistiche:

$$\sum_{i=1}^{100} x_i = 262.0, \qquad \sum_{i=1}^{100} x_i^2 = 687.6666 \qquad \text{(per il dataset } \texttt{Merge Sort}\text{)}$$
$$\sum_{i=1}^{100} y_i = 261.3, \qquad \sum_{i=1}^{100} y_i^2 = 689.3950 \qquad \text{(per il dataset } \texttt{Tim Sort}\text{)}$$

(a) Stimare il tempo di esecuzione medio μ_X dell'algoritmo `Merge Sort`, il tempo di esecuzione medio μ_Y dell'algoritmo `Tim Sort` e le relative varianze; quindi fornire una stima intervallare bilatera di confidenza approssimata del 90% per la differenza media fra i tempi di esecuzione $\mu_X - \mu_Y$.

(b) Impostare un opportuno test per stabilire se il tempo di esecuzione medio dell'algoritmo `Merge Sort` è maggiore di quello di `Tim Sort`; verificare il problema di ipotesi con significatività 10%.

(c) Si può rifiutare ad un livello di significatività del 5% l'ipotesi che i due algoritmi abbiano complessità temporale media uguale?

SOLUZIONE Si considerano i dati come realizzazioni di due campioni indipendenti da popolazioni di medie μ_X e μ_Y e varianze σ_X^2 e σ_Y^2 incognite.

(a) Le stime puntuali richieste sono date da:

$$\bar{x}_{100} = \frac{262.0}{100} = 2.620 \qquad s_X^2 = \frac{1}{99}\left(687.6666 - 100 \times 2.620^2\right) \simeq 0.0124$$
$$\bar{y}_{100} = \frac{261.3}{100} = 2.613 \qquad s_Y^2 = \frac{1}{99}\left(689.3950 - 100 \times 2.613^2\right) \simeq 0.0668$$

Poiché i due campioni sono entrambi numerosi, la formula di un intervallo bilatero asintotico di confidenza approssimata 90% per $\mu_X - \mu_Y$ è

$$\left(\bar{x}_{100} - \bar{y}_{100} - z_{5\%}\sqrt{\frac{s_x^2}{100} + \frac{s_y^2}{100}}\ ,\ \bar{x}_{100} - \bar{y}_{100} + z_{5\%}\sqrt{\frac{s_x^2}{100} + \frac{s_y^2}{100}}\right)$$

sostituendo i dati si ha $-0.0393 < \mu_X - \mu_Y < 0.0533$.

(b) Avendo due campioni indipendenti e numerosi, si imposta un test asintotico z di confronto fra medie per verificare:

$$H_0 \colon \mu_X \leq \mu_Y \qquad \text{contro} \qquad H_1 \colon \mu_X > \mu_Y$$

La statistica test e il valore assunto in corrispondenza delle osservazioni sono dati da

$$t = \frac{\bar{x}_{100} - \bar{y}_{100}}{\sqrt{\dfrac{s_X^2}{100} + \dfrac{s_Y^2}{100}}} \simeq \frac{10(2.620 - 2.613)}{\sqrt{0.0124 + 0.0668}} \simeq 0.2487$$

e si rifiuta H_0 a livello $\alpha = 10\%$ se $0.2487 \geq z_{0.1} \simeq 1.28$. Poiché questa richiesta non è soddisfatta allora al 10% non si può concludere che mediamente la complessità temporale dell'algoritmo di ordinamento `Merge Sort` sia maggiore di quella dell'algoritmo `Tim Sort`, cioè si accetta H_0.

(c) Per la dualità fra VI ed IC, poiché lo zero cade nell'IC bilatero di confidenza 90% costruito al punto (a) allora $H_0 \colon \mu_X - \mu_Y = 0$ è accettata (contro $H_1 \colon \mu_X - \mu_Y \neq 0$) con significatività $\alpha = 1 - 0.9 = 0.10$; inoltre, continua ad essere accettata per ogni $\alpha \leq 10\%$, $\alpha = 5\%$ compreso. In conclusione, la risposta è no, ad un livello di significatività del 5% non si può rifiutare l'ipotesi che i due algoritmi abbiano complessità temporale media uguale. ∎