II Appello di PSI del 19.07.2024 ING. INF. **Docenti: Andreis, Ladelli, Toigo**

Cognome e Nome	Matr.

Il compito va svolto su questi fogli. Potete usare anche il retro dei fogli.

Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.
Scrivere le soluzioni in modo ordinato e con grafia leggibile.

Tempo: 2 ore e 30 minuti

Domande di teoria

Domanda 1. Sia $(\Omega, \mathcal{F}, \mathbb{P})$ uno spazio di probabilità.

(a) Siano $A, B \in \mathcal{F}$ due eventi con $\mathbb{P}(A) = 0.2$ e $\mathbb{P}(B) = 0.6$. Calcolare la probabilità $\mathbb{P}(A \cup B)$ nei due casi in cui

(i) A e B sono *incompatibili*;

(ii) A e B sono *indipendenti*.

(b) Siano $A, B, C \in \mathcal{F}$ tre eventi. Dare la definizione di indipendenza per la tripla A, B, C.

(c) Sia $\Omega = \{a_1, a_2, \dots\}$ uno spazio campionario numerabile e sia $\mathcal{F} = \mathcal{P}(\Omega)$ il suo insieme delle parti. Sia $\{p_i\}_{i=1,2,\dots}$ una successione di numeri reali. Se $\mathbb{P}(\{a_i\}) = p_i$ per ogni $i = 1, 2, \dots$, quali condizioni deve soddisfare $\{p_i\}_{i=1,2,\dots}$ in modo che $\mathbb{P}$ sia una probabilità? Fare un esempio di successione $\{p_i\}_{i=1,2,\dots}$ che soddisfa queste condizioni.

SOLUZIONE.

(a) In generale per due eventi qualsiasi A e B si ha che

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) .$$

(i) Se A e B sono *incompatibili*, allora $A \cap B = \emptyset$ e quindi

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) = 0.2 + 0.6 - 0 = 0.8 .$$

(ii) Se A e B sono *indipendenti*, allora $\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B)$ e quindi

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A)\,\mathbb{P}(B) = 0.2 + 0.6 - 0.12 = 0.68 .$$

(b) A, B, C sono eventi indipendenti se e solo se valgono tutte le condizioni seguenti:

(i) $\mathbb{P}(A \cap B) = \mathbb{P}(A)\,\mathbb{P}(B)$;

(ii) $\mathbb{P}(A \cap C) = \mathbb{P}(A)\,\mathbb{P}(C)$;

(iii) $\mathbb{P}(C \cap B) = \mathbb{P}(C)\,\mathbb{P}(B)$;

(iv) $\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\,\mathbb{P}(B)\,\mathbb{P}(C)$.

Confrontare con Definizione 1.5.19 a pag. 22 degli *Appunti di calcolo delle probabilità*.

(c) Affinchè $\mathbb{P}$ sia una probabilità si deve avere:

(i) $p_i \geq 0$ per ogni $i = 1, 2, \dots$;

(ii) $\sum_{i=1}^{\infty} p_i = 1$.

Confrontare con il capitolo 1.4 a pag. 12 degli *Appunti di calcolo delle probabilità* (in particolare equazione (1.4.1)). L'esempio più semplice che si può fare è la successione in cui $p_1 = 1$ e $p_i = 0$ per ogni $i \geq 2$.

∎

Domanda 2.

(a) Dare la definizione di variabile aleatoria assolutamente continua e della sua densità di probabilità.

(b) Definire la funzione di ripartizione di una variabile aleatoria X generica ed elencare almeno tre proprietà della funzione di ripartizione di X assumendo che X sia assolutamente continua.

(c) Enunciare e dimostrare la proprietà di assenza di memoria per una variabile aleatoria esponenziale.

SOLUZIONE.

(a) Confrontare con Definizione 2.4.1 a pag. 45 degli *Appunti di calcolo delle probabilità*.

(b) Confrontare con Definizione 2.1.7 a pag. 30, con Proposizione 2.1.10 a pag. 31 e Proposizione 2.4.4 a pag. 46 con degli *Appunti di calcolo delle probabilità*.

(c) Sia $X \sim \mathcal{E}(\lambda)$ con $\lambda > 0$. La proprietà di assenza di memoria dice che

$$\mathbb{P}(X > t + s \,|\, X > s) = \mathbb{P}(X > t)$$

per ogni $t, s \geq 0$.

Dimostrazione.
Siccome $X \sim \mathcal{E}(\lambda)$, si ha che $\mathbb{P}(X > t) = \mathrm{e}^{-\lambda t}$ per ogni $t \geq 0$. Per la definizione della probabilità condizionata si ha che

$$\mathbb{P}(X > t + s \,|\, X > s) = \frac{\mathbb{P}(X > t + s,\, X > s)}{\mathbb{P}(X > s)}\,.$$

Usando il fatto che "$X > t + s$" $\wedge$ "$X > s$" = "$X > t + s$", vediamo che $\mathbb{P}(X > t + s,\, X > s) = \mathbb{P}(X > t + s)$. Quindi

$$\frac{\mathbb{P}(X > t + s,\, X > s)}{\mathbb{P}(X > s)} = \frac{\mathbb{P}(X > t + s)}{\mathbb{P}(X > s)} = \frac{\mathrm{e}^{-\lambda(t+s)}}{\mathrm{e}^{-\lambda s}} = \mathrm{e}^{-\lambda t} = \mathbb{P}(X > t)\,,$$

che dimostra la tesi.

∎

Domanda 3. Sia $X_1, X_2, \ldots, X_{25}$ un campione gaussiano di valore atteso incognito μ, di varianza $\sigma^2 = 4$ e di taglia $n = 25$. Sia $\bar{X}_{25}$ la media campionaria e sia $\bar{x}_{25} = 21.5$ la sua realizzazione. Apporre i corretti valori di verità a ognuna delle seguenti affermazioni.

[F] $\bar{X}_{25}$ ha distribuzione gaussiana di valore atteso 21.5 e di varianza $\frac{4}{5}$.

[V] $(20.716, 22.284)$ è un intervallo di confidenza al 95% per il valore atteso μ.

[F] Si consideri il test d'ipotesi con ipotesi nulla $H_0 \colon \mu = 21$ e ipotesi alternativa $H_1 \colon \mu \neq 21$. Al livello di significatività $\alpha = 5\%$ si deve rifiutare H_0.

[F] In generale, se aumenta la taglia n del campione, a parità del livello di confidenza aumenta anche l'ampiezza dell'intervallo di confidenza per il valore atteso μ.

Esercizi

Esercizio 1. Nelle bische clandestine sta avendo successo un nuovo gioco d'azzardo con queste regole:

- si prende un'urna vuota e ci si mettono 2 palline bianche;
- si lancia un dado equilibrato a 4 facce numerate da 1 a 4 e si osserva il valore X uscito nel lancio;
- si aggiungono X palline nere alle 2 palline bianche già presenti nell'urna;
- si estrae una pallina a caso dall'urna;
- si vince se la pallina estratta è nera, altrimenti si perde.

Sia Y la variabile aleatoria che vale 1 quando si vince e 0 quando si perde.

(a) Determinate la densità condizionata di Y dato $X = x$ per ogni $x = 1, \dots, 4$ e riconoscetela. Calcolate inoltre il valore atteso condizionato $\mathbb{E}[Y \mid X]$.
$\Big($*Se non ci riuscite, continuate assumendo* $\mathbb{E}[Y \mid X] = \frac{3(X-1)}{2(X+1)}$.$\Big)$

(b) Determinate la densità di Y e riconoscetela.

Fare una singola giocata costa 0.60€. Quando si vince si ottiene indietro 1.00€, mentre quando si perde non si ottiene indietro nulla. Inoltre giocate diverse sono tutte indipendenti fra loro.

(c) Calcolate in modo approssimato la probabilità di essere in guadagno dopo 50 giocate, cioè la probabilità che a conclusione della 50ma giocata i soldi vinti complessivamente siano più di quelli spesi per giocare.

SOLUZIONE.

(a) Se $X = x$ con $x = 1, \dots, 4$ fissato, allora nell'urna ci sono in tutto $2+x$ palline di cui 2 sono le bianche e x sono le nere. La probabilità di estrarre una pallina nera è perciò $q_x = x/(2+x)$. Condizionatamente a $X = x$ la densità di Y è bernoulliana $B(1, q_x) = B\big(1, x/(2+x)\big)$. Segue che $\mathbb{E}[Y \mid X] = X/(2+X)$.

(b) Anche la densità incondizionata di Y è bernoulliana $B(1, q)$. La regola del doppio valore atteso fornisce

$$q = \mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]] = \mathbb{E}\left[\frac{X}{2+X}\right] = \sum_{x\in\{1,\dots,4\}} \frac{x}{2+x}\, p_X(x) = \sum_{x\in\{1,\dots,4\}} \frac{x}{2+x}\,\frac{1}{4} = \frac{21}{40}\,,$$

dove la densità p_X di X è l'uniforme discreta $\mathcal{U}(\{1, \dots, 4\})$. Col valore di $\mathbb{E}[Y \mid X]$ dato invece nel suggerimento abbiamo

$$q = \sum_{x\in\{1,\dots,4\}} \frac{3(x-1)}{2(x+1)}\,\frac{1}{4} = \frac{43}{80}\,.$$

(c) Indicando con Y_i la variabile aleatoria che vale 1 quando si vince all'i-esima giocata e 0 nel caso contrario, le variabili $Y_1, \dots, Y_{50}$ sono indipendenti con $Y_i \sim B(1, 21/40)$ per ogni $i = 1, \dots, 50$. Gli euro vinti complessivamente dopo 50 giocate sono la somma $S_{50} = Y_1 + \ldots + Y_{50}$, mentre quelli spesi per giocare sono $50 \cdot 0.60 = 30$. La probabilità di essere in guadagno è pertanto

$$\mathbb{P}(S_{50} > 30) = \mathbb{P}\left(\underbrace{\frac{S_{50} - 50\cdot\mathbb{E}[Y]}{\sqrt{50\cdot \operatorname{Var} Y}}}_{\approx N(0,1)} > \frac{30 - 50\cdot\frac{21}{40}}{\sqrt{50\cdot\frac{21}{40}\cdot\left(1-\frac{21}{40}\right)}}\right) \simeq 1 - \Phi\left(\frac{30 - 50\cdot\frac{21}{40}}{\sqrt{50\cdot\frac{21}{40}\cdot\left(1-\frac{21}{40}\right)}}\right)$$
$$= 1 - \Phi(1.062) = 1 - 0.85543 = 14.457\%\,.$$

dove abbiamo usato l'approssimazione $S_{50} \approx N\big(50\,\mathbb{E}\,[Y]\,,\,50\,\mathrm{var}\,[Y]\,\big)$ data dal TCL. Con la correzione di continuità

$$\mathbb{P}\,(S_{50} > 30) = \mathbb{P}\,(S_{50} \geq 30.5) = \ldots = \simeq 1 - \Phi\left(\frac{30.5 - 50 \cdot \frac{21}{40}}{\sqrt{50 \cdot \frac{21}{40} \cdot \left(1 - \frac{21}{40}\right)}}\right)$$
$$= 1 - \Phi(1.204) = 1 - 0.88493 = 11.507\%\,.$$

Col valore di $\mathbb{E}\,[Y \,|\, X]$ dato nel suggerimento

$$\mathbb{P}\,(S_{50} > 30) \simeq \begin{cases} 1 - \Phi\left(\frac{30 - 50 \cdot \frac{43}{80}}{\sqrt{50 \cdot \frac{43}{80} \cdot \left(1 - \frac{43}{80}\right)}}\right) = 1 - \Phi(0.886) = 1 - 0.81327 = 18.673\% \\ \qquad (\text{senza la correzione di continuità})\,, \\ 1 - \Phi\left(\frac{30.5 - 50 \cdot \frac{43}{80}}{\sqrt{50 \cdot \frac{43}{80} \cdot \left(1 - \frac{43}{80}\right)}}\right) = 1 - \Phi(1.028) = 1 - 0.84849 = 15.151\% \\ \qquad (\text{con la correzione di continuità})\,. \end{cases}$$

Esercizio 2. Sia $\begin{pmatrix} X \\ Y \end{pmatrix}$ un vettore aleatorio bidimensionale con distribuzione normale multivariata di media $\begin{pmatrix} 0 \\ 1 \end{pmatrix}$ e matrice di covarianza

$$C = \begin{pmatrix} 1 & a \\ a & 4 \end{pmatrix},$$

con $a \in \mathbb{R}$. Considerare le variabili aleatorie $U = bX + Y - 1$ e $V = bX - Y + 1$, con $b \in \mathbb{R}$.

(a) Trovare per quali valori di a si ha $\mathbb{E}\left[X(2X - Y)\right] = 2$.

(b) Trovare per quali valori di b le variabili aleatorie U e V sono indipendenti. Giustificare il risultato.

(c) Si fissino $a = 0$ e b tale che le variabili aleatorie U e V siano indipendenti. Calcolare la probabilità $\mathbb{P}\left(\max(U, V) \geq \sqrt{b^2 + 4}\right)$.

SOLUZIONE.

(a) Deve essere

$$\begin{aligned} 2 = \mathbb{E}[X(2X - Y)] &= 2\mathbb{E}[X^2] - \mathbb{E}[XY] \\ &= 2(\mathrm{Var}(X) + \mathbb{E}[X]^2) - (\mathrm{Cov}(X, Y) + \mathbb{E}[X]\mathbb{E}[Y]) \\ &= 2(1 + 0^2) - (a + 0 \cdot 1) = 2 - a\,, \end{aligned}$$

da cui si deduce $a = 0$.

(b) Il vettore $\begin{pmatrix} U \\ V \end{pmatrix}$, essendo una trasformazione affine di un vettore normale multivariato, ha distribuzione normale multivariata. Infatti:

$$\begin{pmatrix} U \\ V \end{pmatrix} = \begin{pmatrix} b & 1 \\ b & -1 \end{pmatrix} \begin{pmatrix} X \\ Y \end{pmatrix} + \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Per le proprietà delle variabili aleatorie normali multivariate, U e V sono independenti se e solo se $\mathrm{Cov}(U, V) = 0$, ovvero

$$\begin{aligned} 0 = \mathrm{Cov}(U, V) &= \mathrm{Cov}(bX + Y - 1, bX - Y + 1) = \mathrm{Cov}(bX + Y, bX - Y) \\ &= b^2 \,\mathrm{Var}(X) + b\,\mathrm{Cov}(Y, X) - b\,\mathrm{Cov}(X, Y) - \mathrm{Var}(Y) = b^2 - 4, \end{aligned}$$

da cui si ricava $b = \pm 2$.

(c) Per l'indipendenza di U e V, si ha che

$$\begin{aligned} \mathbb{P}\left(\max(U, V) \geq \sqrt{b^2 + 4}\right) &= 1 - \mathbb{P}\left(\max(U, V) < \sqrt{b^2 + 4}\right) \\ &= 1 - \mathbb{P}\left(U < \sqrt{b^2 + 4}, V < \sqrt{b^2 + 4}\right) \\ &= 1 - \mathbb{P}\left(U < \sqrt{b^2 + 4}\right) \mathbb{P}\left(V < \sqrt{b^2 + 4}\right). \end{aligned}$$

Per $a = 0$ si vede subito che $\mathrm{Cov}(X, Y) = 0$, dunque X e Y sono indipendenti in quanto congiuntamente gaussiane. Segue che $\mathbb{E}[U] = \mathbb{E}[V] = 0$, $\mathrm{Var}(U) = \mathrm{Var}(V) = b^2 + 4$, da cui $U \sim \mathcal{N}(0, b^2 + 4)$ e $V \sim \mathcal{N}(0, b^2 + 4)$. Allora, si ha che

$$\begin{aligned} \mathbb{P}\left(U < \sqrt{b^2 + 4}\right) &= \mathbb{P}\left(\frac{U - 0}{\sqrt{b^2 + 4}} < 1\right) = \Phi(1) \simeq 0.841345\,, \\ \mathbb{P}\left(V < \sqrt{b^2 + 4}\right) &= \mathbb{P}\left(\frac{V - 0}{\sqrt{b^2 + 4}} < 1\right) = \Phi(1) \simeq 0.841345\,. \end{aligned}$$

Di conseguenza, si ha che

$$\mathbb{P}\left(\max(U, V) \geq \sqrt{b^2 + 4}\right) \simeq 1 - \Phi(1)^2 \simeq 0.292139\,.$$

∎

Esercizio 3. Quando vado dal barbiere a tagliarmi i capelli, il numero dei clienti che trovo in coda davanti a me si può modellizzare con una variabile aleatoria X che ha la seguente densità di probabilità discreta p:

$$p(0) = 1 - (a+b)\,, \qquad p(1) = a\,, \qquad p(2) = 3b - a\,, \qquad p(3) = a - 2b\,.$$

Nelle espressioni precedenti, a e b sono due parametri reali di cui non conosco i valori. Per poter fare inferenza su a e su b, le prossime 4 volte che andrò dal barbiere prenderò nota del numero dei clienti in coda, in modo da ottenere un campione aleatorio $X_1, \ldots, X_4$ estratto da p.

(a) Calcolate i valori attesi $\mathbb{E}\left[X\right]$ e $\mathbb{E}\left[X^2\right]$ in funzione dei due parametri a e b. Basandovi sul campione $X_1, \ldots, X_4$ determinate poi gli stimatori $\hat{A}$ di a e $\hat{B}$ di b col metodo dei momenti.
$\Big($*Se non ci riuscite, continuate usando* $\hat{A} = \frac{1}{6}\,(X_2 + X_3 + X_4)$ *e* $\hat{B} = \frac{1}{2}\,X_1 + X_2 - \frac{1}{4}\left[(X_3)^2 + (X_4)^2\right].\Big)$

(b) Calcolate in funzione di a e di b la distorsione dei due stimatori $\hat{A}$ e $\hat{B}$ determinati al punto precedente. Limitandovi al solo stimatore $\hat{A}$, calcolate anche l'errore quadratico medio.

A me interessa stimare soprattutto la probabilità $p(1) = a$ di trovare in coda un solo cliente. Il barbiere – che dice di aver studiato Statistica fra un taglio di capelli e l'altro – mi consiglia di usare questo stimatore:

$$\hat{A}' = \frac{1}{4}\,(4\,X_4 - 3\,X_3 + 2\,X_2 - X_1)\ .$$

(c) Determinate la distorsione e l'errore quadratico medio dello stimatore $\hat{A}'$ del parametro a. Quale fra i due stimatori $\hat{A}$ e $\hat{A}'$ è il migliore? Giustificate la risposta.

SOLUZIONE.

(a) Notiamo che $p(0)+p(1)+p(2)+p(3) = 1$ e quindi per la variabile aleatoria discreta X non sono possibili altri valori oltre a quelli nell'insieme $S = \{0, 1, 2, 3\}$. Abbiamo

$$\begin{aligned}
\mathbb{E}\left[X\right] &= \sum_{x \in S} x\,p(x) = 0 \cdot [1 - (a+b)] + 1 \cdot a + 2 \cdot (3b - a) + 3 \cdot (a - 2b) = 2a\,, \\
\mathbb{E}\left[X^2\right] &= \sum_{x \in S} x^2 p(x) = 0^2 \cdot [1 - (a+b)] + 1^2 \cdot a + 2^2 \cdot (3b - a) + 3^2 \cdot (a - 2b) = 6(a-b)\,.
\end{aligned}$$

Per trovare gli stimatori di a e di b col metodo dei momenti dobbiamo innanzitutto risolvere rispetto a a e a b il sistema

$$\begin{cases} \mathbb{E}\left[X\right] = \mu_1 \\ \mathbb{E}\left[X^2\right] = \mu_2 \end{cases} \quad \Rightarrow \quad \begin{cases} 2a = \mu_1 \\ 6(a-b) = \mu_2 \end{cases} \quad \Rightarrow \quad \begin{cases} a = \frac{1}{2}\,\mu_1 \\ b = \frac{1}{6}(3\mu_1 - \mu_2) \end{cases}$$

dopodiché dobbiamo sostituire al posto dei parametri μ_1 e μ_2 le loro versioni campionarie $\overline{X} = \frac{1}{4}\sum_{i=1}^4 X_i$ e $\overline{X^2} = \frac{1}{4}\sum_{i=1}^4 X_i^2$. Otteniamo così gli stimatori

$$\hat{A} = \frac{1}{2}\,\overline{X}\,, \qquad \hat{B} = \frac{1}{6}\left(3\overline{X} - \overline{X^2}\right)\ .$$

(b) Per quanto riguarda le distorsioni abbiamo

$$\begin{aligned}
\mathbb{E}[\hat{A}] &= \mathbb{E}\left[\frac{1}{2}\,\overline{X}\right] = \frac{1}{2}\,\mathbb{E}\left[\overline{X}\right] = \frac{1}{2}\,\mathbb{E}\left[X_i\right] = \frac{1}{2} \cdot 2a = a\,, \\
\mathbb{E}[\hat{B}] &= \mathbb{E}\left[\frac{1}{6}\left(3\overline{X} - \overline{X^2}\right)\right] = \frac{1}{2}\,\mathbb{E}\left[\overline{X}\right] - \frac{1}{6}\,\mathbb{E}[\overline{X^2}] = \frac{1}{2}\,\mathbb{E}\left[X_i\right] - \frac{1}{6}\,\mathbb{E}\left[X_i^2\right] = \frac{1}{2} \cdot 2a - \frac{1}{6} \cdot 6(a-b) \\
&= b\,.
\end{aligned}$$

Perciò

$$\mathrm{bias}\big(\hat{A};a\big) = \mathbb{E}\big[\hat{A}\big] - a = 0\,, \qquad \mathrm{bias}\big(\hat{B};b\big) = \mathbb{E}\big[\hat{B}\big] - b = 0\,,$$

cioè né $\hat{A}$ né $\hat{B}$ sono distorti. Per quanto riguarda invece l'errore quadratico medio di $\hat{A}$ abbiamo

$$\begin{aligned}\mathrm{mse}\big(\hat{A};a\big) &= \mathrm{var}\big[\hat{A}\big] + \mathrm{bias}\big(\hat{A};a\big)^2 = \mathrm{var}\left[\frac{1}{2}\,\overline{X}\right] + 0^2 = \left(\frac{1}{2}\right)^2 \mathrm{var}\left[\overline{X}\right] = \left(\frac{1}{2}\right)^2 \frac{\mathrm{var}\big[X_i\big]}{4} \\ &= \frac{1}{16}\,\mathrm{var}\left[X_i\right] = \frac{1}{16}\left(\mathbb{E}\left[X_i^2\right] - \mathbb{E}\left[X_i\right]^2\right) = \frac{1}{16}\left[6(a-b) - (2a)^2\right] = \frac{3(a-b)-2a^2}{8}\,.\end{aligned}$$

Calcolando le stesse quantità per gli stimatori dati nel suggerimento troviamo

$$\begin{aligned}\mathbb{E}\big[\hat{A}\big] &= \mathbb{E}\left[\frac{1}{6}\,(X_2 + X_3 + X_4)\right] = \frac{1}{6}\left(\mathbb{E}\left[X_2\right] + \mathbb{E}\left[X_3\right] + \mathbb{E}\left[X_4\right]\right) = \frac{1}{6}\,(2a + 2a + 2a) = a \\ &\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad\qquad \Rightarrow \quad \mathrm{bias}\big(\hat{A};a\big) = 0\,, \\ \mathbb{E}\big[\hat{B}\big] &= \mathbb{E}\left[\frac{1}{2}\,X_1 + X_2 - \frac{1}{4}\left(X_3^2 + X_4^2\right)\right] = \frac{1}{2}\,\mathbb{E}\left[X_1\right] + \mathbb{E}\left[X_2\right] - \frac{1}{4}\left(\mathbb{E}\left[X_3^2\right] + \mathbb{E}\left[X_4^2\right]\right) \\ &= \frac{1}{2}\cdot 2a + 2a - \frac{1}{4}\left[6(a-b) + 6(a-b)\right] = 3b \qquad\qquad \Rightarrow \quad \mathrm{bias}\big(\hat{B};b\big) = 2b\,, \\ \mathrm{mse}\big(\hat{A};a\big) &= \mathrm{var}\big[\hat{A}\big] + \mathrm{bias}\big(\hat{A};a\big)^2 = \mathrm{var}\left[\frac{1}{6}\,(X_2 + X_3 + X_4)\right] + 0^2 \\ &= \left(\frac{1}{6}\right)^2 \left(\mathrm{var}\left[X_2\right] + \mathrm{var}\left[X_3\right] + \mathrm{var}\left[X_4\right]\right) = \frac{3}{36}\,\mathrm{var}\left[X_i\right] = \frac{3(a-b)-2a^2}{6}\,.\end{aligned}$$

(c) Per lo stimatore $\hat{A}'$ abbiamo

$$\begin{aligned}\mathbb{E}\big[\hat{A}'\big] &= \mathbb{E}\left[\frac{1}{4}\,(4\,X_4 - 3\,X_3 + 2\,X_2 - X_1)\right] = \frac{1}{4}\left(4\,\mathbb{E}\left[X_4\right] - 3\,\mathbb{E}\left[X_3\right] + 2\,\mathbb{E}\left[X_2\right] - \mathbb{E}\left[X_1\right]\right) \\ &= \frac{1}{4}\,(4\cdot 2a - 3\cdot 2a + 2\cdot 2a - 2a) = a \qquad\qquad \Rightarrow \quad \mathrm{bias}\big(\hat{A}';a\big) = 0\,, \\ \mathrm{mse}\big(\hat{A}';a\big) &= \mathrm{var}\big[\hat{A}'\big] + \mathrm{bias}\big(\hat{A};a\big)^2 = \mathrm{var}\left[\frac{1}{4}\,(4\,X_4 - 3\,X_3 + 2\,X_2 - X_1)\right] + 0^2 \\ &= \left(\frac{1}{4}\right)^2 \left[4^2\mathrm{var}\left[X_4\right] + (-3)^2\mathrm{var}\left[X_3\right] + 2^2\mathrm{var}\left[X_2\right] + (-1)^2\mathrm{var}\left[X_1\right]\right] \\ &= \frac{30}{16}\,\mathrm{var}\left[X_i\right] = \frac{15}{4}\big[3(a-b) - 2a^2\big]\,.\end{aligned}$$

Sia lo stimatore $\hat{A}$ sia lo stimatore $\hat{A}'$ sono non distorti, ma

$$\mathrm{mse}\big(\hat{A};a\big) = \frac{1}{16}\,\mathrm{var}\left[X_i\right] < \frac{30}{16}\,\mathrm{var}\left[X_i\right] = \mathrm{mse}\big(\hat{A}';a\big)\,.$$

Segue pertanto che $\hat{A}$ è lo stimatore migliore dei due. Lo stesso ragionamento porta alla medesima conclusione anche usando lo stimatore $\hat{A}$ dato nel suggerimento.

∎

Esercizio 4. Secondo il professor Farnsworth, il 60% delle consegne del Planet Express viene effettuato all'interno del Sistema Solare, il 30% fuori dal Sistema Solare ma comunque all'interno della Galassia, e solo per il rimanente 10% la destinazione è fuori dalla Galassia. Fry e Leela dubitano però che le cose stiano veramente come dice il professore, e per questo motivo hanno preso nota delle ultime 100 consegne effettuate dal Planet Express. I loro dati sono riassunti nella tabella seguente.

	all'interno del Sistema Solare	fuori dal Sistema Solare ma all'interno della Galassia	fuori dalla Galassia
numero di consegne	43	37	20

Si può assumere che consegne diverse abbiano destinazioni tutte indipendenti fra loro.

(a) Impostate un opportuno test al livello di significatività α per stabilire se i dati sono in accordo con la distribuzione dichiarata dal professor Farnsworth oppure se c'è evidenza del contrario, come sospettano invece Fry e Leela.

(b) Determinate il p-value del test precedente o almeno fornite un intervallo in cui cade tale p-value. Cosa concludete in base al valore trovato?

Per una consegna qualsiasi indicate con q la probabilità che la sua destinazione sia fuori dalla Galassia.

(c) Fry e Leela ritengono che la probabilità q sia maggiore del 10% dichiarato dal professore. C'è evidenza dai dati che sia effettivamente così? Decidetelo impostando e svolgendo un opportuno test al livello di significatività fissato del 5%. Fate in modo che l'errore più grave sia concludere che q è maggiore del 10% quando in realtà ciò non è vero.

SOLUZIONE.

(a) Per una consegna qualunque, siano $p(1)$, $p(2)$ e $p(3)$ le probabilità che la destinazione sia all'interno del Sistema Solare, fuori dal Sistema Solare e fuori dalla Galassia, rispettivamente. Dobbiamo fare un test per le ipotesi statistiche

$$H_0 : p = p_0 \qquad \text{vs.} \qquad H_1 : p \neq p_0 \,,$$

in cui $p_0(1) = 60\%$, $p_0(2) = 30\%$ e $p_0(3) = 10\%$ sono le probabilità dichiarate dal professor Farnsworth. Possiamo usare un test del chi-quadrato di buon adattamento a una densità discreta completamente specificata, che al livello di significatività α ha la regola

$$\text{“ rifiuto } H_0 \text{ se } T_0 := \sum_{\ell=1}^{k} \frac{\big(O_\ell - np_0(\ell)\big)^2}{np_0(\ell)} > \chi^2_{1-\alpha}(k-1) \text{”} \,,$$

dove $k = 3$ sono le classi e $n = 100$ è la numerosità del campione.

(b) La tabella delle numerosità è

classi (ℓ)	1	2	3
freq. teoriche ($p_0(\ell)$)	0.60	0.30	0.10
num. teoriche ($np_0(\ell)$)	60	30	10
num. empiriche (o_ℓ)	43	37	20

Tutte numerosità teoriche sono maggiori di 5, quindi non c'è bisogno di accorpare classi diverse. Dalla tabella ricaviamo la realizzazione

$$t_0 = \frac{(43-60)^2}{60} + \frac{(37-30)^2}{30} + \frac{(20-10)^2}{10} = 16.45 \,.$$

Per determinare il p-value, imponiamo l'uguaglianza nella regola di rifiuto e otteniamo α di conseguenza

$$\begin{aligned} t_0 \equiv \chi^2_{1-\alpha}(k-1) = \chi^2_{1-\alpha}(2) \quad &\Rightarrow \quad \chi^2_{1-\alpha}(2) = 16.45 > 15.2014 = \chi^2_{0.9995}(2) \\ &\Rightarrow \quad 1-\alpha > 0.9995 \quad \Rightarrow \quad \alpha < 0.0005 = 0.5\% \,. \end{aligned}$$

Con un p-value $< 0.5\%$ c'è forte evidenza contro l'ipotesi nulla H_0. Sono quindi confermati i sospetti di Fry e di Leela.

(c) Si richiede ora di fare un test per le ipotesi statistiche

$$H_0 : q \leq 10\% \qquad \text{vs.} \qquad H_1 : q > 10\% \,.$$

Solo scegliendo H_0 e H_1 in questo modo, infatti, l'errore di I tipo (cioè quello più grave del test) diventa concludere che q è maggiore del 10% ($\Leftrightarrow$ rifiutare H_0) quando in realtà ciò non è vero ($\Leftrightarrow$ H_0 è vera). La regola di un test al livello di significatività α per le ipotesi statistiche precedenti è

$$\text{“ rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X} - q_0}{\sqrt{q_0(1-q_0)}}\sqrt{n} > z_{1-\alpha} \text{ ”} \,,$$

dove $q_0 = 10\%$ e $n = 100$ come nel punto precedente. Dai dati otteniamo la realizzazione

$$\bar{x} = \frac{20}{100} = 0.20 \quad \Rightarrow \quad z_0 = \frac{0.20 - 0.10}{\sqrt{0.10 \cdot (1-0.10)}}\sqrt{100} = 3.333 \,.$$

Al livello $\alpha = 5\%$ abbiamo $z_{1-\alpha} = z_{0.95} = 1.645$ e quindi $z_0 = 3.333 > 1.645 = z_{0.95}$. Segue pertanto che dobbiamo rifiutare H_0 al livello del 5%.

∎