IV Appello di PSI del 16.01.2023 **Docente**

Cognome e Nome	Matr.

Il compito va svolto su questi fogli. Potete usare anche il retro dei fogli.

Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.
Scrivere le soluzioni in modo ordinato e con grafia leggibile.

Tempo: 2 ore e 30 minuti

1 Domande di teoria

D 1 Sia (X, Y) un vettore aleatorio assolutamente continuo di densità $f_{X,Y}$ e densità marginali f_X e f_Y.

(a) Come è definita la densità condizionata $f_{X|Y}(x|y)$ di X, dato $Y = y$?

(b) Ricavare la formula della densità marginale f_Y di Y a partire da $f_{X,Y}$.

(c) Ricavare la formula della densità condizionata $f_{Y|X}(y|x)$ di Y in funzione di $f_{X|Y}$ e f_Y.

Soluzione Vedi lucidi su WeBeep. ∎

D 2 Siano $X_1, \ldots, X_n, \overset{\text{i.i.d.}}{\sim} \Gamma(2, \vartheta)$ con $\vartheta > 0$ parametro incognito, $\kappa(\vartheta) = \dfrac{1}{\vartheta}$ e

$$\widehat{K} = \sum_{j=1}^{n} a_j X_j$$

uno stimatore di $\kappa(\vartheta)$.

(a) Calcolare il valore atteso $\mathrm{E}_\vartheta(\widehat{K})$ di $\widehat{K}$ e stabilire per quali valori di $\{a_j\}_{j=1}^n$, $\widehat{K}$ è stimatore non distorto di $\kappa(\vartheta)$.

(b) Determinare la varianza dei seguenti due stimatori di $\kappa(\vartheta) = \dfrac{1}{\vartheta}$

$$\widehat{K}_1 = \frac{X_1 + X_2}{4} \qquad \text{e} \qquad \widehat{K}_2 = \frac{3X_1 + 6X_2}{18}$$

e stabilire fra $\widehat{K}_1, \widehat{K}_2$ quale è preferibile e perché.

Soluzione

(a) Per la proprietà di linearità del valore atteso e ricordando che il valore atteso di $X \sim \Gamma(2, \vartheta)$ è $\mathrm{E}_\vartheta(X) = 2/\vartheta = 2\kappa(\vartheta)$ (si confronti il formulario), si ha

$$\mathrm{E}_\vartheta(\widehat{K}) = \sum_{j=1}^{n} a_j \,\mathrm{E}_\vartheta(X_j) = 2\sum_{j=1}^{n} a_j \kappa(\vartheta) = \kappa(\vartheta)\ \forall \vartheta > 0 \quad \text{se e solo se} \quad \sum_{j=1}^{n} a_j = \frac{1}{2}$$

(b) Dalle proprietà della varianza della somma di v.a. indipendenti e ricordando che la varianza di $X \sim \Gamma(2, \vartheta)$ è $\mathrm{Var}_\vartheta(X) = 2/\vartheta^2 = 2\kappa^2(\vartheta)$ (si confronti il formulario), deriva quanto segue

$$\mathrm{Var}_\vartheta(\widehat{K}_1) = \frac{\mathrm{Var}_\vartheta(X_1) + \mathrm{Var}_\vartheta(X_2)}{16} = \frac{2 \times 2\kappa^2(\vartheta)}{16} = \frac{\kappa^2(\vartheta)}{4}$$
$$\mathrm{Var}_\vartheta(\widehat{K}_2) = \frac{9\,\mathrm{Var}_\vartheta(X_1) + 36\,\mathrm{Var}_\vartheta(X_2)}{324} = \frac{45 \times 2\kappa^2(\vartheta)}{324} = \frac{5\kappa^2(\vartheta)}{18}$$

$\widehat{K}_1$ è preferibile a $\widehat{K}_2$ in quanto essendo entrambi non distorti il loro MSE coincide con la corrispondente varianza e $\mathrm{Var}(\widehat{K}_1)$ è strettamente minore di $\mathrm{Var}(\widehat{K}_2)$. ∎

D 3 È stato estratto un campione casuale $X_1, \ldots, X_n$ dalla densità f_ϑ nota a meno del parametro incognito $\vartheta \in \Theta = (0, \infty)$ per verificare l'ipotesi nulla $H_0 \colon \vartheta \leq 3$ contro l'alternativa $H_1 \colon \vartheta > 3$, usando una regione critica C con significatività α.

(a) Dare la definizione di curva OC $\beta(\vartheta)$ del test.

(b) Si conoscono i seguenti due valori di questa $\beta(\vartheta)$:

$$\beta(2.2) = 0.92 \qquad \text{e} \qquad \beta(6.2) = 0.05$$

Segnare le affermazioni vere con V e le false con F, motivare le scelte

☐ Se $\vartheta = 6.2$, la probabilità di accettare H_0 vale 0.95;

☐ Se $\vartheta = 2.2$ la probabilità dell'errore di I tipo vale 0.08;

☐ $\alpha \geq 0.08$;

☐ sicuramente p-value ≥ 0.08.

Soluzione

(a) la curva OC è

$$\beta(\vartheta) = P_\vartheta(\text{“si accetta } H_0\text{”}) = P_\vartheta((X_1, \ldots, X_n) \notin C) \qquad \vartheta \in \Theta$$

(b) [F] La probabilità di accettare H_0 se $\vartheta = 6.2$ vale 0.95; (è falsa perché probabilità di accettare H_0 se $\vartheta = 6.2$ è proprio $\beta(6.2) = 0.05$)

[V] La probabilità dell'errore di I tipo se $\vartheta = 2.2$ vale 0.08; (è vera perché $\vartheta = 2.2$ è compatibile con H_0 (in quanto $2.2 < 3$) allora $1 - \beta(2.2) = 0.08$ è la probabilità di un errore di I tipo)

[V] $\alpha \geq 0.08$; (è vera perché la significatività α di un test è l'estremo superiore dell'errore di I tipo quindi necessariamente $\alpha \geq 0.08$)

[F] sicuramente p-value ≥ 0.08. (È falsa perché il p-value è una statistica cioè dipende dalle realizzazioni del campione aleatorio e può assumere un qualunque valore in $(0, 1)$, e questo valore non dipende dal valore della curva OC in qualche ϑ). ∎

2 Esercizi

Esercizio 1 [1] Un test d'esame a risposta multipla ha 5 risposte alternative di cui solo una è corretta. Dall'esperienza passata sappiamo che uno studente conosce la risposta con probabilità $p = 0.6$ e in tal caso risponde alla domanda correttamente, oppure con probabilità 0.4 non conosce la riposta, nel qual caso sceglie a caso, sperando di indovinare la risposta corretta. Inoltre gli studenti che partecipano al test d'esame rispondono in modo indipendente.

(a) Calcolare la probabilità che uno studente risponda correttamente al test.

(b) Calcolare la probabilità condizionata che uno studente che ha risposto correttamente al test, conoscesse effettivamente la risposta.

(c) Calcolare la probabilità che almeno 66 dei 102 studenti che partecipano al test rispondano correttamente al test.

SOLUZIONE Siano E="Lo studente sceglie la risposta esatta" ed H="Lo studente conosce la risposta esatta", allora si deduce dal testo che $P(H) = 0.6$, $P(E|H) = 1$ e $P(E|H^c) = 1/5 = 0.2$.

(a) Segue dalla regola delle probabilità totali che la probabilità $P(E)$ cercata è

$$P(E) = P(E|H)P(H) + P(E|H^c)P(H^c) = 1 \times 0.6 + 0.2 \times 0.4 = 0.68$$

(b) Segue dalla regola di Bayes che la probabilità $P(H|E)$ cercata è

$$P(H|E) = \frac{P(E|H)P(H)}{P(E|H)P(H) + P(E|H^c)P(H^c)} = \frac{1 \times 0.6}{0.68} = \frac{15}{17} \simeq 0.8824$$

(c) Assumendo che tutti gli studenti lavorino indipendentemente l'uno dall'altro e che per ognuno valga lo stesso modello di risposta, allora la v.a. $S =$ "numero di studenti che rispondono correttamente al test su 102 partecipanti" ha densità binomiale $\mathbf{Bi}(n, p)$ con $n = 102$ e $p = P(E) = 0.68$. La probabilità cercata è $P(S \geq 66) = 1 - F_S(65)$. Essendo la classe degli studenti numerosa (102) ed $102 \times 0.68 \times 0.32 = 22.1952 > 10$ approssimiamo la probabilità cercata usando il teorema centrale del limite con la correzione di continuità:

$$1 - F_S(65) = 1 - F_S(65.5) \simeq 1 - \Phi\left(\frac{65.5 - 102 \times 0.68}{\sqrt{22.1952}}\right) = 1 - \Phi\left(\frac{65.5 - 69.36}{\sqrt{22.1952}}\right) \simeq 1 - \Phi(-0.82) = \Phi(0.82) \simeq 0.7939 \blacksquare$$

[1] Si confronti l'Esempio 26 pag. 38 di Mood A.M., Graybill F.A., Boes D.C. (1991) Introduzione alla statistica, McGraw-Hill Education

Esercizio 2 L'intensità di pioggia (misurata in cm / h) di un certo tipo di fenomeno temporalesco nella città di Ottavia è modellizzabile dalla v.a. $T = \mathrm{e}^X$ con $X \sim \mathcal{E}(3)$.

(a) Calcolare, se esistono, il valore atteso e la varianza dell'intesità di pioggia (ossia $\mathrm{E}[T]$ e $\mathrm{Var}(T)$).

(b) Determinare funzione di ripartizione F_T e densità di probabilità f_T di T.

(c) Sapendo che l'intensità di pioggia supera 1.5 cm / h, determinare la probabilità che non superi i 2 cm $/h$.

SOLUZIONE

(a) $\mathrm{E}(T) = 3\int_0^{+\infty} \mathrm{e}^x \mathrm{e}^{-3x} dx = 3\int_0^{+\infty} \mathrm{e}^{-2x} dx = \frac{3}{2}$.
$\mathrm{E}(T^2) = 3\int_0^{+\infty} \mathrm{e}^{2x} \mathrm{e}^{-3x} dx = 3\int_0^{+\infty} \mathrm{e}^{-x} dx = 3$. Quindi T ammette varianza e vale
$\mathrm{Var}(T) = \mathrm{E}(T^2) - (\mathrm{E}(T))^2 = 3 - \frac{9}{4} = \frac{3}{4}$.

(b) Poiché $P(X \in (0, +\infty)) = 1$ segue che $P(\mathrm{e}^X \in (1, +\infty)) = 1$ e nessun intervallo di valori di X più piccolo di $(0, +\infty)$ e quindi nessun intervallo di valori di T più piccolo di $(1, +\infty)$ ha questa proprietà. Ne segue che, indicata con F_T la f.d.r. di T, $F_T(t) = 0$ per $t \leq 1$. Se $t > 1$ vale:
$F_T(t) = P(T \leq t) = P(\mathrm{e}^X \leq t) = P(X \leq \ln(t)) = 1 - \mathrm{e}^{-3\ln(t)} = 1 - \frac{1}{t^3}$.
Quindi
$F_T(t) = (1 - \frac{1}{t^3})\mathbf{1}_{(1,+\infty)}(t)$. Poichè la f.d.r. è continua ovunque e differenziabile con continuità tranne in $t = 0$, T è assolutamente continua di densità $f_T(t) = \frac{3}{t^4}\mathbf{1}_{(1,+\infty)}(t)$.

(c) Si tratta di calcolare $P(T \leq 2 | T > 1.5)$. Ovviamente non c'è mancanza di memoria perchè T non è una v.a. esponenziale. Quindi

$$\begin{aligned} P(T \leq 2 | T > 1.5) &= P(X \leq \ln(2) | X > \ln(1.5)) = 1 - P(X > \ln(2) | X > \ln(1.5)) \\ &= 1 - P(X > \ln(2) - \ln(1.5)) = P\left(X \leq \ln(\frac{2}{1.5})\right) \\ &= 1 - \mathrm{e}^{-3\ln(\frac{4}{3})} = 1 - (\frac{3}{4})^3 = 1 - \frac{27}{64} \simeq 0.5781, \end{aligned}$$

dove la terza uguaglianza è dovuta al fatto che X è esponenziale e quindi vale la mancanza di memoria.
∎

Esercizio 3 [2] Per vedere se i terremoti hanno maggiori probabilità di verificarsi in determinati giorni della settimana piuttosto che in altri, sono stati analizzati i dati di $N = 1100$ terremoti della California meridionale di magnitudo ≥ 4.4 sulla scala Richter ottenendo quanto segue:

Giorno	Lunedì	Martedì	Mercoledì	Giovedì	Venerdì	Sabato	Domenica
Numero di Terremoti N_i	144	170	158	172	148	152	156

(a) Verificare con $\alpha = 5\%$ l'ipotesi nulla che un terremoto abbia la stessa probabilità di verificarsi in uno qualsiasi dei 7 giorni della settimana.

(b) Determinare un intervallo dove cade il p-value del test usato nel punto precedente.

Soluzione

(a) Si osserva che il campione di dati raggruppati in 7 classi è numeroso (1100 eventi di terremoto di magnitudo ≥ 4.4 sulla scala Richter) e si imposta un test di buon adattamento asintotico chi-quadrato di Pearson per verificare

$$H_0 \colon p_1 = \cdots = p_7 = \frac{1}{7} \quad \text{contro} \quad H_1 \colon \text{“}H_0 \text{ } \textit{è falsa}\text{”}$$

dove $p_i := P(\text{“un terremoto di magnitudo} \geq 4.4 \text{ sulla scala Richter accade nel giorno } i \text{ della settimana”})$. Per ogni giorno i, si ha $Np_{0i} = 1100/7 \simeq 157.1 > 5$, quindi al fine della costruzione della statistica non c'è bisogno di raggruppare ulteriormente le classi; la statistica test è

$$X_0^2 = \sum_{i=1}^{7} \frac{(N_i - 1100/7)^2}{1100/7} = \frac{7}{1100} \sum_{i=1}^{7} N_i^2 - 1100$$

e sul campione fornito vale

$$x_0^2 = \frac{7}{1100}(144^2 + \cdots + 156^2) - 1100 \simeq 4.269$$

Poiché H_0 specifica completamente la distribuzione su cui si sta investigando, allora $X_0^2 \approx \chi^2(7-1) = \chi^2(6)$ se H_0 è vera, e il quantile asintotico di coda destra di ordine $\alpha = 5\%$ vale $\chi^2_{0.05,6} \simeq 12.592$. Essendo $4.269 < 12.592$, allora al 5% l'ipotesi nulla che un terremoto abbia la stessa probabilità di verificarsi in uno qualsiasi dei 7 giorni della settimana non è rifiutata.

(b) Usando le tavole dei quantili della f.d.r. χ^2 (per esempio quelli forniti nell'Appendice degli eserciziari del corso), per il p-value asintotico $P(\chi_6^2 \geq x_0^2)$ si ha

$$50\% = P(\chi_6^2 \geq 5.384) < p\text{-value} = P(\chi_6^2 \geq x_0^2) < P(\chi_6^2 \geq 4.074) = 66.7\%$$

(il p-value asintotico esatto, arrotondato alla quarta cifra decimale e calcolato con `R`, è 0.6403). Si conclude che non c'è nessuna evidenza empirica contro H_0. ∎

[2] Si confronti l'Esercizio 10 pagina 513 di Ross S.M. (2015) Probabilità e Statistica per l'Ingegneria e le Scienze, Terza Edizione, Apogeo

Esercizio 4 La v.a. $X \in (0,1)$ modellizza la proporzione di pezzi difettosi in un lotto e $X_1, \ldots, X_n$ è un campione casuale dalla popolazione X per n lotti. Un controllo di qualità su $n = 90$ lotti ha fornito le seguenti statistiche

$$\sum_{j=1}^{90} x_j = 4.1217, \qquad \sum_{j=1}^{90} x_j^2 = 0.2364$$

(a) Calcolare media e varianza campionarie, quindi fornire una stima intervallare asintotica bilatera di confidenza 95% per la proporzione media $\mu = \mathrm{E}(X)$ di pezzi difettosi in un lotto.

Successivamente, in base ad uno studio statistico di buon adattamento, si è scoperto che si può assumere per X il seguente modello parametrico $\mathbf{Beta}(\vartheta, 84)$:

$$f_\vartheta(x) = \frac{\Gamma(\vartheta+84)}{\Gamma(\vartheta)\Gamma(84)} x^{\vartheta-1}(1-x)^{83}\mathbf{1}_{(0,1)}(x) \quad \text{per cui} \quad \mathrm{E}_\vartheta(X) = \frac{\vartheta}{\vartheta+84}$$

con $\vartheta > 0$ incognito.

(b) Determinare lo stimatore dei momenti ϑ e la corrispondente stima per il campione dei 90 lotti per cui si è osservato $\sum_{j=1}^{90} x_j = 4.1217$.

Soluzione

(a) $\bar{x} = \dfrac{\sum_{j=1}^{90} x_j}{90} = \dfrac{4.1217}{90} \simeq 0.0458, \quad s_X^2 = \dfrac{\sum_{j=1}^{90} x_j^2 - 90\bar{x}^2}{89} \simeq \dfrac{0.2364 - \frac{4.1217^2}{90}}{89} \simeq 0.0005$

Avendo un campione numeroso ($n = 90$) con varianza incognita, la formula dell'$IC(\mu)$ di confidenza 95% è

$$\bar{x} - z_{2.5\%}\sqrt{\frac{s_X^2}{90}} < \mu < \bar{x} + z_{2.5\%}\sqrt{\frac{s_X^2}{90}}$$

e $z_{2.5\%} \simeq 1.96$. Quindi con i dati a disposizione la stima intervallare richiesta è $0.0412 < \mu < 0.0504$.

(b) Una stima di ϑ ottenuta con il metodo dei momenti soddisfa l'equazione in ϑ: $\mu(\vartheta) = \bar{x}$ che qui è

$$\frac{\vartheta}{\vartheta+84} = \bar{x}$$

ed ammette l'unica soluzione

$$\hat{\vartheta} = \frac{84\bar{x}}{1-\bar{x}}$$

Allora $\widehat{\Theta} = 84\overline{X}/(1-\overline{X})$ è lo stimatore ottenuto con il metodo dei momneti per ϑ e la corrispondente stima vale $\hat{\vartheta} = \frac{3462228}{858783} \simeq 4.032$. ∎