IV Appello di PSI del 08.01.2025 per ING INF **Docenti: L. Andreis, L. Ladelli, A. Toigo**

Cognome e Nome	Matr.

Il compito va svolto su questi fogli. Potete usare anche il retro dei fogli.

Importante: nelle soluzioni non basta scrivere i risultati finali, ma si devono riportare i passaggi principali e fornire adeguate spiegazioni.
Scrivere le soluzioni in modo ordinato e con grafia leggibile.

Tempo: 2 ore e 30 minuti

Domande di teoria

Domanda 1. Siano Ω uno spazio campionario e $\mathcal{F}$ una famiglia di sottoinsiemi di Ω (l'insieme degli eventi).

(a) Dare la definizione assiomatica di **probabilità** su $(\Omega, \mathcal{F})$.

(b) Enunciare almeno 3 proprietà della probabilità che derivano dagli assiomi e dimostrarne una.

(c) Si consideri ora $\Omega = \mathbb{N}$, cioè l'insieme dei numeri naturali, e sia $\mathcal{F}$ l'insieme delle parti di Ω. Fornire un esempio di successione di numeri reali $(p_k)_{k\in\mathbb{N}}$ tale che la relazione

$$\mathbb{P}(E) = \sum_{k\in E} p_k \qquad \forall E \in \mathcal{F}$$

definisca una probabilità $\mathbb{P}$ su $(\Omega, \mathcal{F})$.

SOLUZIONE.

(a) Si veda la Definizione 1.2.16 (pag. 7) delle dispense "Appunti di calcolo delle probabilità".

(b) Si vedano la Proposizione 1.2.17 e la Sezione 1.3 (da pag. 7) delle dispense "Appunti di calcolo delle probabilità".

(c) Si veda la Sezione 1.4 (da pag. 11) delle dispense "Appunti di calcolo delle probabilità" (in particolare l'esempio 1.4.3).

Domanda 2. Sia X una variabile aleatoria assolutamente continua.

(a) Dare la definizione di **funzione di ripartizione** e di **densità** di X.

(b) Enunciare almeno 3 proprietà della funzione di ripartizione di X.

(c) Dare la definizione di **valore atteso** di X. Enunciare e dimostrare la proprietà di linearità del valore atteso per una variabile aleatoria assolutamente continua.

SOLUZIONE.

(a) Si vedano la Definizione 2.1.7 (pag. 30) e la Definizione 2.4.1 (pag. 45) delle dispense "Appunti di calcolo delle probabilità".

(b) Si vedano la Proposizione 2.1.10 (pag. 31), l'Esercizio 2.1.13 (pag. 32) e il punto 2) della Proposizione 2.4.4 (pag. 46) delle dispense "Appunti di calcolo delle probabilità".

(c) Si vedano la Definizione 3.1.6 (pag. 61) e il punto 3) e 4) della Proposizione 3.1.14 (pag. 63) delle dispense "Appunti di calcolo delle probabilità".

∎

Domanda 3. Sia $X_1, \dots, X_n$ un campione gaussiano di taglia n con valore atteso $\mathbb{E}[X_i] = \mu$ incognito e varianza $\mathrm{Var}[X_i] = 9$ nota. Sia inoltre $\bar{X}_n = (X_1 + \cdots + X_n)/n$ la media campionaria e $\gamma \in (0,1)$.

(a) Dimostrare che $\bar{X}_n$ è uno stimatore non distorto di μ per ogni $n \geq 1$ e che $(\bar{X}_n)_{n\geq 1}$ è una successione di stimatori di μ consistente in media quadratica.

(b) Dare la definizione in generale di **intervallo di confidenza** bilatero di livello γ per μ.

(c) Dimostrare che, se $z_{(1+\gamma)/2}$ è il quantile sinistro di ordine $(1+\gamma)/2$ della densità normale standard, allora
$$\left(\bar{X}_n - z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}},\, \bar{X}_n + z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}}\right)$$
è un intervallo di confidenza bilatero di livello γ per μ.

SOLUZIONE.

(a) Lo stimatore $\bar{X}_n$ di μ si dice *non distorto* (o *corretto*) se
$$\mathbb{E}_\mu\left[\bar{X}_n\right] = \mu\,.$$
Per la linearità del valore atteso e dato che $\mathbb{E}_\mu[X_1] = \cdots = \mathbb{E}_\mu[X_n] = \mu$, si ha che
$$\mathbb{E}_\mu\left[\bar{X}_n\right] = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}_\mu[X_i] = \frac{1}{n} n\mu = \mu\,,$$
quindi $\bar{X}_n$ è non distorto per ogni $n \geq 1$. Una successione $(\bar{X}_n)_{n\geq 1}$ di stimatori di μ si dice *consistente in media quadratica* se
$$\lim_{n\to\infty} \mathbb{E}_\mu\left[(\bar{X}_n - \mu)^2\right] = 0\,.$$
Siccome $\bar{X}_n$ è non distorto per ogni $n \geq 1$, si ha che $\mathbb{E}_\mu\left[(\bar{X}_n - \mu)^2\right] = \mathrm{Var}_\mu\left[\bar{X}_n\right]$. Visto che $\mathrm{Var}_\mu\left[\bar{X}_n\right] = \mathrm{Var}_\mu[X_1]/n = 9/n \to 0$ se $n \to \infty$, si ha che $\lim_{n\to\infty} \mathbb{E}_\mu\left[(\bar{X}_n - \mu)^2\right] = 0$ e quindi la successione di stimatori è consistente in media quadratica.

(b) Siano $L = \ell(X_1, \dots, X_n)$ e $U = u(X_1, \dots, X_n)$ due statistiche che soddisfano la relazione $L < U$. Allora (L, U) è detto *intervallo di confidenza* di livello γ per μ se vale l'equazione
$$\mathbb{P}_\mu(L < \mu < U) = \gamma$$
per ogni $\mu \in \mathbb{R}$.

(c) Dato che $X_1, \dots, X_n$ è un campione gaussiano di taglia n con valore atteso $\mathbb{E}_\mu[X_i] = \mu$ e varianza $\mathrm{Var}_\mu[X_i] = 9$, per la media campionaria $\bar{X}_n$ abbiamo
$$\bar{X}_n \sim N\left(\mathbb{E}_\mu[X_i], \frac{\mathrm{Var}_\mu[X_i]}{n}\right) = N\left(\mu, \frac{9}{n}\right) \quad \Rightarrow \quad \frac{\bar{X}_n - \mu}{\sqrt{\frac{9}{n}}} = \frac{\bar{X}_n - \mu}{3}\sqrt{n} \sim N(0,1)\,.$$
Perciò, scegliendo le statistiche
$$L = \bar{X}_n - z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}}, \qquad U = \bar{X}_n + z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}}$$
nel punto precedente, abbiamo
$$\begin{aligned}
\mathbb{P}_\mu(L < \mu < U) &= \mathbb{P}_\mu\left(\bar{X}_n - z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}} < \mu < \bar{X}_n + z_{\frac{1+\gamma}{2}} \frac{3}{\sqrt{n}}\right) = \mathbb{P}_\mu\left(-z_{\frac{1+\gamma}{2}} < \frac{\bar{X}_n - \mu}{3}\sqrt{n} < z_{\frac{1+\gamma}{2}}\right) \\
&= \Phi\left(z_{\frac{1+\gamma}{2}}\right) - \Phi\left(-z_{\frac{1+\gamma}{2}}\right) = \frac{1+\gamma}{2} - \left(1 - \frac{1+\gamma}{2}\right) \\
&= \gamma
\end{aligned}$$
come richiesto dalla definizione di intervallo di confidenza di livello γ per μ.

∎

Esercizi

Esercizio 1. Siano X, Y e Z tre variabili aleatorie indipendenti e identicamente distribuite, ciascuna con densità bernoulliana con lo stesso parametro $q \in (0,1)$, cioè $X \sim B(1,q)$, $Y \sim B(1,q)$ e $Z \sim B(1,q)$. Siano U e V le due variabili aleatorie

$$U = X + Y\,, \qquad V = X + Z\,.$$

(a) Scrivere la tabella della densità congiunta del vettore aleatorio (U,V). Le variabili aleatorie U e V sono indipendenti?

(b) Calcolare la covarianza $\mathrm{Cov}\,[U,\,V]$ in funzione di q.

(c) Supponiamo ora $q = 2/3$. Siano $U_1, U_2, \ldots, U_{35}$ una successione di 35 variabili aleatorie indipendenti e identicamente distribuite, tutte con la stessa densità di U, e sia $S = U_1 + U_2 + \ldots + U_{35}$ la loro somma. Calcolare un valore approssimato della probabilità $\mathbb{P}\,(S \geq 50)$.

SOLUZIONE.

(a) Abbiamo

$$\begin{aligned}
\mathbb{P}\,(U=0,\,V=0) &= \mathbb{P}\,(X=0,\,Y=0,\,Z=0)\\
&= (1-q)^3\\
\mathbb{P}\,(U=1,\,V=0) &= \mathbb{P}\,(X+Y=1,\,X=0,\,Z=0) = \mathbb{P}\,(X=0,\,Y=1,\,Z=0)\\
&= q(1-q)^2\\
\mathbb{P}\,(U=2,\,V=0) &= \mathbb{P}\,(X=1,\,Y=1,\,X+Z=0) = \mathbb{P}\,(\emptyset)\\
&= 0\\
\mathbb{P}\,(U=1,\,V=1) &= \mathbb{P}\,(X=1,\,Y=0,\,X+Z=1) + \mathbb{P}\,(X=0,\,Y=1,\,X+Z=1)\\
&= \mathbb{P}\,(X=1,\,Y=0,\,Z=0) + \mathbb{P}\,(X=0,\,Y=1,\,Z=1)\\
&= q(1-q)^2 + q^2(1-q) = q(1-q)\\
\mathbb{P}\,(U=2,\,V=1) &= \mathbb{P}\,(X=1,\,Y=1,\,X+Z=1) = \mathbb{P}\,(X=1,\,Y=1,\,Z=0)\\
&= q^2(1-q)\\
\mathbb{P}\,(U=2,\,V=2) &= \mathbb{P}\,(X=1,\,Y=1,\,Z=1)\\
&= q^3\,.
\end{aligned}$$

in quanto si ha l'uguaglianza di eventi

$$\begin{aligned}
&\{U=0\} = \{X=0,\,Y=0\} \qquad\qquad \{U=2\} = \{X=1,\,Y=1\}\\
&\{U=1\} = \{X=1,\,Y=0\} \cup \{X=0,\,Y=1\} \quad \text{(unione disgiunta)}\,,
\end{aligned}$$

e similmente per V. Inoltre, $\mathbb{P}\,(U=h,\,V=k) = \mathbb{P}\,(U=k,\,V=h)$ per ogni $h,k \in \{0,1,2\}$ per simmetria. La tabella della densità congiunta (estesa con le marginali) è pertanto

$U\backslash V$	0	1	2	p_U
0	$(1-q)^3$	$q(1-q)^2$	0	$(1-q)^2$
1	$q(1-q)^2$	$q(1-q)$	$q^2(1-q)$	$2q(1-q)$
2	0	$q^2(1-q)$	q^3	q^2
p_V	$(1-q)^2$	$2q(1-q)$	q^2	

Dalla tabella si vede che (per esempio) $0 = p_{U,V}(0,2) \neq p_U(0)p_V(2) = q^2(1-q)^2$, e quindi U e V *non* sono indipendenti.

(b) Per la bilinearità della covarianza e per l'indipendenza di X, Y, Z,

$$\begin{aligned}\mathrm{Cov}\,[U,\,V] &= \mathrm{Cov}\,[X+Y,\,X+Z] = \mathrm{Cov}\,[X,\,X] + \cancel{\mathrm{Cov}\,[X,\,Z]} + \cancel{\mathrm{Cov}\,[Y,\,X]} + \cancel{\mathrm{Cov}\,[Y,\,Z]} = \mathrm{Var}\,[X] \\ &= q(1-q)\,.\end{aligned}$$

(c) Ciascuna variabile aleatoria U_i ha densità $B(2, 2/3)$, dunque per l'indipendenza $S \sim B(35 \times 2, 2/3) = B(70, 2/3)$. Poiché $n = 70 > 20$, $nq = 70 \times 2/3 = 46.67 > 5$ e $n(1-q) = 70 \times (1 - 2/3) = 23.33 > 5$, possiamo usare l'approssimazione gaussiana della densità binomiale $B(n, q) \simeq N(nq, nq(1-q))$. Si ha pertanto

$$\begin{aligned}\mathbb{P}\,(S \geq 50) &= 1 - \mathbb{P}\,(S \leq 49) = 1 - \mathbb{P}\Bigg(\underbrace{\frac{S - \mathbb{E}\,[S]}{\sqrt{\mathrm{Var}\,[S]}}}_{\approx N(0,1)} \leq \frac{49 - nq}{\sqrt{nq(1-q)}}\Bigg) \simeq 1 - \Phi\Bigg(\frac{49 - nq}{\sqrt{nq(1-q)}}\Bigg) \\ &= 1 - \Phi\left(\frac{49 - 70 \times \frac{2}{3}}{\sqrt{70 \times \frac{2}{3} \times \left(1 - \frac{2}{3}\right)}}\right) \simeq 1 - \Phi(0.5916) \simeq 1 - 0.72240 \\ &= 27.760\%\,.\end{aligned}$$

Con la correzione di continuità

$$\begin{aligned}\mathbb{P}\,(S \geq 50) &= 1 - \mathbb{P}\,(S \leq 49.5) = \ldots \simeq 1 - \Phi\left(\frac{49.5 - 70 \times \frac{2}{3}}{\sqrt{70 \times \frac{2}{3} \times \left(1 - \frac{2}{3}\right)}}\right) \simeq 1 - \Phi(0.7184) \simeq 1 - 0.76424 \\ &= 23.576\%\,.\end{aligned}$$

∎

Esercizio 2. La ditta SpaceZ produce due diversi tipi di propulsori per navicelle aerospaziali: il tipo A e il tipo B. I loro tempi di vita, espressi in anni, sono descritti dalle rispettive variabili aleatorie positive X_A e X_B. Il propulsore di tipo A ha un'intensità di guasto data da

$$\lambda_A(t) = \frac{1}{2}\,\mathrm{e}^{\frac{t}{2}} \qquad \forall t > 0\,.$$

Il propulsore di tipo B invece non è soggetto né a rodaggio né a usura e ha un tempo di vita il cui valore atteso è pari a 3 anni.

(a) Determinate le densità di probabilità di X_A e di X_B. Stabilite inoltre se il propulsore di tipo A è soggetto a usura, giustificando la risposta.

(b) Un propulsore di tipo A è entrato in funzione un anno esatto fa e da allora non si è ancora guastato. Qual è la probabilità che si guasti entro un anno a partire da oggi? Quale sarebbe la risposta se il propulsore fosse di tipo B invece che di tipo A?

Ogni navicella aerospaziale è dotata sia di un propulsore di tipo A sia di uno di tipo B, che operano in modo indipendente uno dall'altro e in serie. In altre parole, i tempi di vita dei due propulsori sono indipendenti, la navicella funziona finché funzionano tutti e due i propulsori, e si guasta appena se ne guasta almeno uno. Sia T il tempo di vita di una navicella aerospaziale qualsiasi.

(c) Esprimete T come opportuna funzione di X_A e di X_B. Determinate poi la funzione di ripartizione di T.

SOLUZIONE.

(a) Chiaramente si ha $X_B \sim \mathcal{E}(1/3)$. Per quanto riguarda X_A, per $t > 0$ la sua funzione di ripartizione è

$$F_A(t) = 1 - \exp\left(-\int_0^t \lambda_A(s)\,\mathrm{d}s\right) = 1 - \exp\left(-\left[\mathrm{e}^{\frac{s}{2}}\right]_{s=0}^{s=t}\right) = 1 - \exp\left(1 - \mathrm{e}^{\frac{t}{2}}\right)\,,$$

da cui segue che la densità di X_A è data da

$$f_A(t) = \frac{1}{2}\,\mathrm{e}^{\frac{t}{2}} \exp\left(1 - \mathrm{e}^{\frac{t}{2}}\right) \mathbb{1}_{[0,+\infty)}(t)\,.$$

La funzione λ_A è crescente, dunque la componente A si usura nel tempo.

(b) Per quanto riguarda la componente A, si ha che

$$\begin{aligned}\mathbb{P}\left(X_A < 1+1 \,|\, X_A > 1\right) &= 1 - \mathbb{P}\left(X_A \geq 2 \,|\, X_A > 1\right) = 1 - \frac{\mathbb{P}\left(X_A \geq 2,\, X_A > 1\right)}{\mathbb{P}\left(X_A > 1\right)} = 1 - \frac{\mathbb{P}\left(X_A \geq 2\right)}{\mathbb{P}\left(X_A > 1\right)} \\ &= 1 - \frac{1 - F_A(2)}{1 - F_A(1)} = 1 - \exp\left(\mathrm{e}^{\frac{1}{2}} - \mathrm{e}\right) \simeq 65.684\%\,.\end{aligned}$$

L'analoga probabilità per la componente B, invece, è

$$\begin{aligned}\mathbb{P}\left(X_B < 1+1 \,|\, X_B > 1\right) &= 1 - \mathbb{P}\left(X_B \geq 1+1 \,|\, X_B > 1\right) = 1 - \mathbb{P}\left(X_B \geq 1\right) \\ &= F_B(1) = 1 - \mathrm{e}^{-\frac{1}{3}} \simeq 28.347\%\end{aligned}$$

per l'assenza di usura di tale componente.

(c) Il tempo di vita della navicella coincide col tempo di vita del componente che si guasta per primo, cioè $T = \min\{X_A, X_B\}$. Segue che T è una variabile aleatoria positiva, assolutamente continua e che per $t > 0$ verifica

$$\begin{aligned}F_T(t) &= 1 - \mathbb{P}\left(T > t\right) = 1 - \mathbb{P}\left(X_A > t, X_B > t\right) = 1 - \mathbb{P}\left(X_A > t\right)\mathbb{P}\left(X_B > t\right) \\ &= 1 - (1 - F_A(t))(1 - F_B(t)) = 1 - \exp\left(1 - \mathrm{e}^{\frac{t}{2}}\right)\mathrm{e}^{-\frac{t}{3}} = 1 - \exp\left(1 - \frac{t}{3} - \mathrm{e}^{\frac{t}{2}}\right)\,.\end{aligned}$$

∎

Esercizio 3. La ACME è un'azienda che produce batterie per automobili. Ogni batteria della ACME sviluppa una tensione aleatoria che è distribuita secondo una densità gaussiana centrata sul valore noto di 12 V. La deviazione standard σ, invece, è incognita e dipende dal livello di efficienza dell'impianto di produzione. Precisamente, tanto più σ è piccola, tanto maggiore è l'efficienza dell'impianto. Il valore di σ viene monitorato misurando periodicamente le tensioni di $n = 5$ batterie estratte a caso fra quelle di nuova produzione. I risultati $X_1, \ldots, X_5$ così trovati costituiscono un campione aleatorio con $X_i \sim N(12, \sigma^2)$. L'ultimo monitoraggio ha fornito le realizzazioni seguenti:

$$x_1 = 10.94 \qquad x_2 = 12.27 \qquad x_3 = 12.51 \qquad x_4 = 11.66 \qquad x_5 = 13.25\,.$$

(a) Fornite un limite inferiore al livello di confidenza del 95% per il valore della deviazione standard σ.

Gli standard di qualità della ACME richiedono che σ sia minore di 0.4 V. Se tale condizione non è rispettata, la produzione deve essere sospesa e l'intero impianto va revisionato.

(b) Impostate un test opportuno al livello di significatività α per decidere se gli standard di qualità della ACME sono rispettati oppure no sulla base dei dati ai dati a disposizione. Considerate che per l'azienda l'errore più grave è sospendere la produzione e revisionare l'impianto quando in realtà ciò non è necessario.

(c) Come si conclude il test precedente al livello di significatività $\alpha = 5\%$? In che intervallo cade il p-value dei dati e quali conclusioni ne traete?

SOLUZIONE.

(a) Si richiede di fornire un $IC_\sigma(95\%)$ unilatero sinistro, cioè del tipo $(c, +\infty)$. Poiché abbiamo a disposizione un campione di $n = 5$ misure gaussiane con valore atteso $\mu = 12$ noto, sul formulario troviamo che al livello di confidenza $\gamma = 95\%$ si ha

$$\sigma^2 \in \left(\frac{n\, s^2_{0,n}}{\chi^2_\gamma(n)}\,,\, +\infty \right),$$

dove

$$s^2_{0,n} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2 = \frac{(10.94 - 12)^2 + \ldots + (13.25 - 12)^2}{5} = 0.62694$$

e

$$\chi^2_\gamma(n) = \chi^2_{0.95}(5) = 11.0705\,.$$

Perciò,

$$\sigma^2 \in \left(\frac{5 \cdot 0.62694}{11.0705}\,,\, +\infty \right) = (0.28316\,,\, +\infty) \quad \Rightarrow \quad \sigma \in \left(\sqrt{0.28316}\,,\, \sqrt{+\infty} \right) = (0.53213\,,\, +\infty)\,.$$

Se invece avessimo considerato il caso in cui il valore atteso è incognito, con confidenza del 95% avremmo avuto

$$\sigma^2 \in \left(\frac{(n-1)\, s^2_n}{\chi^2_\gamma(n-1)}\,,\, +\infty \right),$$

dove

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{10.94 + \ldots + 13.25}{5} = 12.12600\,,$$

$$s^2_n = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x}_n)^2 = \frac{(10.94 - 12.12600)^2 + \ldots + (13.25 - 12.12600)^2}{5-1} = 0.76383$$

e

$$\chi^2_\gamma(n-1) = \chi^2_{0.95}(4) = 9.4877\,.$$

Perciò,

$$\sigma^2 \in \left(\frac{(5-1)\cdot 0.7638}{9.4877}\,,\,+\infty\right) = (0.32203\,,\,+\infty) \quad \Rightarrow \quad \sigma \in \left(\sqrt{0.32203}\,,\,\sqrt{+\infty}\right) = (0.56748\,,\,+\infty)\,.$$

In questo modo, però, non avremmo utilizzato tutte le informazioni date nel problema.

(b) Dobbiamo fare un test per le ipotesi statistiche

$$H_0 : \sigma \leq 0.4 \qquad \text{vs.} \qquad H_1 : \sigma > 0.4\,.$$

Infatti, l'errore più grave è sempre quello di I tipo, e solo scegliendo H_0 e H_1 in questo modo tale errore consiste nel sospendere la produzione e revisionare l'impianto (cioè rifiutare H_0) quando in realtà ciò non è necessario (cioè H_0 è vera). La regola di un test al livello α per le ipotesi statistiche precedenti è

$$\text{“ rifiuto } H_0 \text{ se } X^2_0 := \frac{n\,S^2_{0,n}}{\sigma^2_0} \geq \chi^2_{1-\alpha}(n)\text{”}\,,$$

dove $\sigma^2_0 = 0.4^2$. Ignorando invece l'informazione $\mu = 12$, la regola precedente è sostituita da

$$\text{“ rifiuto } H_0 \text{ se } X^2_0 := \frac{(n-1)\,S^2_n}{\sigma^2_0} \geq \chi^2_{1-\alpha}(n-1)\text{”}\,.$$

(c) Coi dati trovati abbiamo la realizzazione

$$x^2_0 = \frac{5\cdot 0.62694}{0.4^2} = 19.5919\,.$$

Al livello di significatività $\alpha = 5\%$, questo valore va confrontato col quantile

$$\chi^2_{1-\alpha}(n) = \chi^2_{0.95}(5) = 11.0705\,.$$

Poiché $19.5919 > 11.0705$, si rifiuta H_0 al livello $\alpha = 5\%$. Lo stesso risultato si poteva ottenere usando la dualità test-IC e osservando che 0.4 non appartiene all'$IC_\sigma(95\%)$ ricavato al punto (a). Per trovare invece il p-value, bisogna imporre l'uguaglianza nella regola di rifiuto e risolvere rispetto ad α l'equazione risultante:

$$\begin{aligned} x^2_0 \equiv \chi^2_{1-\alpha}(5) \quad &\Rightarrow \quad \chi^2_{0.995}(5) = 16.7496 < \chi^2_{1-\alpha}(5) = 19.5919 < \chi^2_{0.999}(5) = 20.5147 \\ &\Rightarrow \quad 0.995 < 1-\alpha < 0.999 \quad \Rightarrow \quad 0.001 < \alpha < 0.005\,. \end{aligned}$$

Un p-value compreso fra lo 0.1% e lo 0.5% è ben al di sotto dell'usuale soglia del 5% per cui si accetta H_0. Concludiamo pertanto che c'è evidenza dai dati in favore di H_1, cioè del fatto che gli standard di qualità della ACME non sono rispettati (conclusione forte).
Ignorando l'informazione $\mu = 12$, troviamo invece

$$x^2_0 = \frac{(5-1)\cdot 0.76383}{0.4^2} = 19.0957$$

e

$$\begin{aligned} x^2_0 \equiv \chi^2_{1-\alpha}(4) \quad &\Rightarrow \quad \chi^2_{0.999}(4) = 18.4662 < \chi^2_{1-\alpha}(4) = 19.0957 < \chi^2_{0.9995}(4) = 19.9977 \\ &\Rightarrow \quad 0.999 < 1-\alpha < 0.9995 \quad \Rightarrow \quad 0.0005 < \alpha < 0.001\,. \end{aligned}$$

Valgono quindi le stesse conclusioni del caso con valore atteso noto.

∎

Esercizio 4. Nel centro di distribuzione di una catena di supermercati una macchina inscatolatrice caricata con un gran numero di peperoni gialli e rossi sta inscatolando confezioni da 3 peperoni ciascuna. Nell'ultimo quarto d'ora sono state realizzate 200 confezioni:

36 con 3 peperoni gialli;
89 con 2 peperoni gialli e 1 rosso;
60 con 2 peperoni rossi e 1 giallo;
15 con 3 peperoni rossi.

Sia q la proporzione dei peperoni rossi caricati nella macchina inscatolatrice.

(a) Sulla base del campione, fornire un intervallo di confidenza bilatero al livello approssimato del 90% per la proporzione q.

(b) Per quanto ne sappiamo, i peperoni gialli e quelli rossi dovrebbero essere ugualmente numerosi (cioè si dovrebbe avere $q = 1/2$). I dati sopra riportati consentono di rifiutare questa ipotesi? Per rispondere, si imposti e si svolga un opportuno test al livello di significatività dell'1%.

Sia Y la variabile aleatoria che conta il numero di peperoni rossi in una confezione.

(a) Sulla base dei dati a disposizione, possiamo rifiutare l'ipotesi che Y abbia densità binomiale $B(3, 2/5)$? Effettuare un test di adattamento, determinare un intervallo in cui cade il p-value e stabilire la conclusione al livello di significatività del 10%.

SOLUZIONE.

(a) Si tratta di trovare un $IC_q(90\%)$ per il parametro q di un campione bernoulliano numeroso $X_1, \dots, X_n$, con $X_i \sim B(1, q)$. Ogni peperone che viene inscatolato corrisponde infatti a una prova diversa, in cui si ottiene un successo se il peperone è rosso e un insuccesso se è giallo. Ci sono pertanto ben $n = 200 \times 3 = 600$ prove in tutto, in cui

$$X_i = \begin{cases} 1 & \text{se l'}i\text{-esimo peperone inscatolato è rosso}, \\ 0 & \text{altrimenti}. \end{cases}$$

La frequenza empirica dei successi, cioè dei peperoni rossi inscatolati dalla macchina, è

$$\hat{q} = \frac{36 \times 0 + 89 \times 1 + 60 \times 2 + 15 \times 3}{600} = \frac{254}{600}\,.$$

Al livello di confidenza approssimato $\gamma = 90\%$ abbiamo

$$\begin{aligned} q &\in \left(\hat{q} - z_{\frac{1+\gamma}{2}} \sqrt{\frac{\hat{q}(1-\hat{q})}{n}}\,,\ \hat{q} + \frac{1+\gamma}{2} \sqrt{\frac{\hat{q}(1-\hat{q})}{n}} \right) \\ &= \left(\frac{254}{600} - 1.645 \times \sqrt{\frac{\frac{254}{600}\left(1 - \frac{254}{600}\right)}{600}}\,,\ \frac{254}{600} + 1.645 \times \sqrt{\frac{\frac{254}{600}\left(1 - \frac{254}{600}\right)}{600}} \right) \\ &= (39.015\%\,,\ 45.651\%)\,, \end{aligned}$$

dove $z_{(1+\gamma)/2} = z_{0.95} = 1.645$.

(b) Consideriamo il problema di verifica d'ipotesi

$$H_0 : q = \frac{1}{2} \qquad \text{vs.} \qquad H_1 : q \neq \frac{1}{2}\,.$$

Un test di livello di significatività approssimato α è dato dalla regola

$$\text{“ rifiuto } H_0 \text{ se } |Z_0| > z_{1-\frac{\alpha}{2}} \text{ ”}\,,$$

dove

$$Z_0 := \frac{\hat{Q} - q_0}{\sqrt{q_0\,(1-q_0)}}\sqrt{n}$$

con $q_0 = 1/2$ e $n = 600$. Abbiamo già visto che i dati forniscono la realizzazione $\hat{q} = 254/600$, quindi

$$z_0 = \frac{\frac{254}{600} - \frac{1}{2}}{\sqrt{\frac{1}{2}\left(1-\frac{1}{2}\right)}}\sqrt{600} = -3.7559\,.$$

Al livello $\alpha = 1\%$ abbiamo $z_{1-\alpha/2} = z_{0.995} = 2.58$. Poiché $|z_0| = 3.7559 > 2.58 = z_{0.995}$, dobbiamo rifiutare H_0 al livello di significatività dell'1%.

(c) La densità $B(3, 2/5)$ è

$$p_0(\ell) = \binom{3}{\ell}\left(\frac{2}{5}\right)^{\ell}\left(1-\frac{2}{5}\right)^{3-\ell} \qquad \ell = 0, 1, 2, 3\,,$$

cioè

$$p_0(0) = \frac{27}{125}\,, \qquad p_0(1) = \frac{54}{125}\,, \qquad p_0(2) = \frac{36}{125}\,, \qquad p_0(3) = \frac{8}{125}\,.$$

In questo caso il campione aleatorio è costituito dalle quantità di peperoni rossi contenuti confezione per confezione, cioè da $n = 200$ diverse misure $Y_1, \ldots, Y_n$ ciascuna con densità p incognita. Dobbiamo dunque svolgere un test di buon adattamento alla densità p_0, cioè un test per le ipotesi statistiche

$$H_0 : p = p_0 \qquad \text{vs.} \qquad H_1 : H_0 \text{ è falsa}\,.$$

La regola di tale test al livello di significatività α è

$$\text{“ rifiuto } H_0 \text{ se } X_0^2 := \sum_{\ell=0}^{3}\frac{(O_\ell - np_0(\ell))^2}{np_0(\ell)} = \sum_{\ell=0}^{3}\frac{O_\ell^2}{np_0(\ell)} - n > \chi^2_{1-\alpha}(k-1)\text{ ”}\,.$$

Nell'espressione precedente, O_ℓ è il numero di variabili che prendono il valore ℓ fra quelle del campione $Y_1, \ldots, Y_n$, mentre $k = 4$ è il numero totale di possibili valori per le Y_i. È utile scrivere la tabella delle numerosità empiriche e teoriche, cioè

classi	0	1	2	3
freq. teoriche ($p_0(\ell)$)	27/125	54/125	36/125	8/125
num. teoriche ($p_0(\ell)$)	43.2	86.4	57.6	12.8
num. empiriche (o_ℓ)	36	89	60	15

In particolare, vediamo che le condizioni per poter svolgere il test di buon adattamento sono soddisfatte, in quanto $n = 200$ è grande e tutte numerosità teoriche sono maggiori di 5 (ne basterebbe l'80%). Dalla tabella troviamo la realizzazione

$$x_0^2 = \frac{36^2}{43.2} + \frac{89^2}{86.4} + \frac{60^2}{57.6} + \frac{15^2}{12.8} - 200 = 1.7564\,.$$

Per calcolare il p-value, imponiamo l'uguaglianza nella regola di rifiuto e risolviamo rispetto ad α l'equazione risultante:

$$\begin{aligned} x_0^2 \equiv \chi^2_{1-\alpha}(4-1) \quad &\Rightarrow \quad \chi^2_{0.25}(3) = 1.2125 < \chi^2_{1-\alpha}(3) = 1.7564 < \chi^2_{0.5}(3) = 2.3660 \\ &\Rightarrow \quad 0.25 < 1-\alpha < 0.50 \quad \Rightarrow \quad 0.50 < \alpha < 0.75\,. \end{aligned}$$

Un p-value compreso fra il 50% e il 75% è enorme e non è in nessun modo in contraddizione con H_0. In particolare, poiché p-value $> 10\%$, dobbiamo accettare H_0 al livello di significatività del 10%.

∎