

POLITECNICO
MILANO 1863



Introduzione alle Tecnologie di Interconnessione

Alberto Gatto

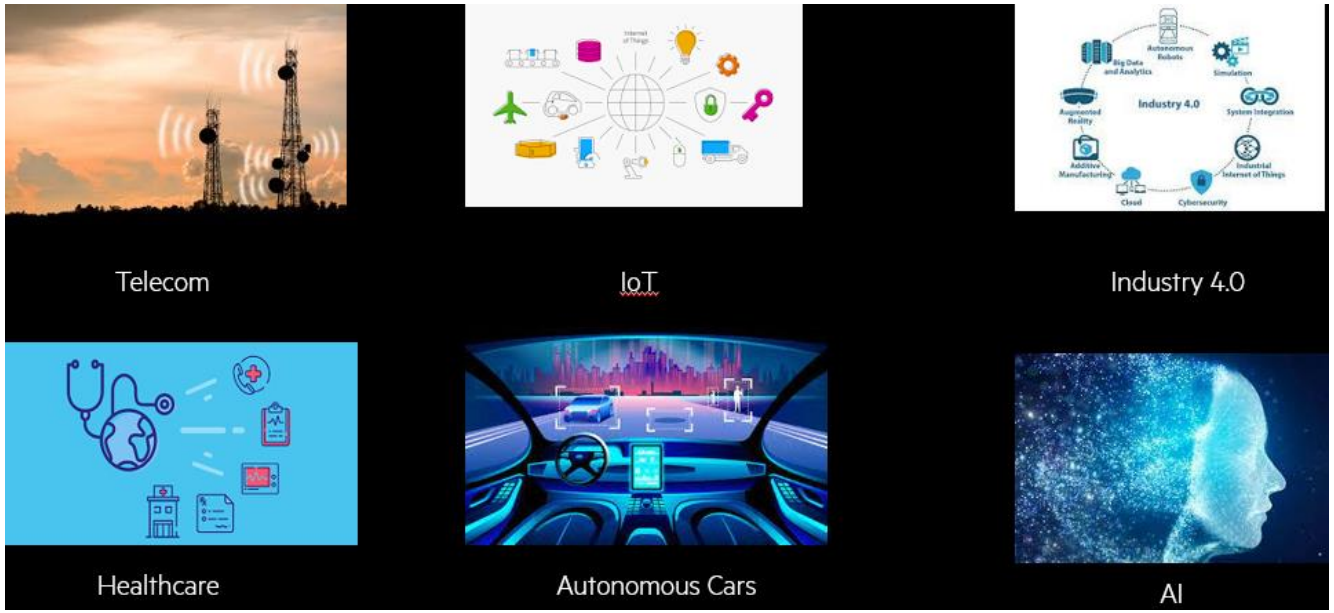


POLITECNICO
MILANO 1863



8 – Interconnessione inter e intra datacenter

Il traffico dati e i datacenter

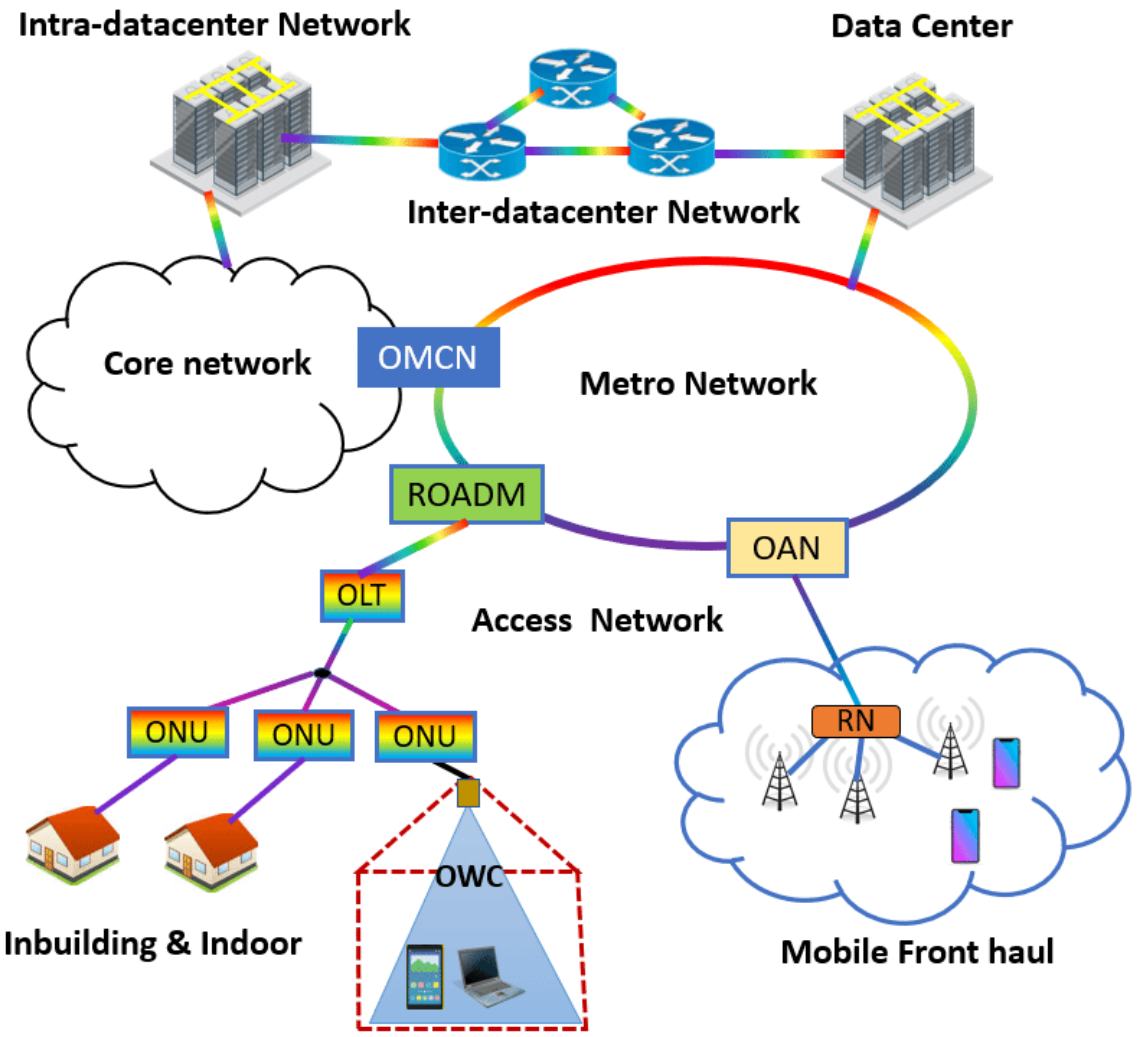




- Negli ultimi anni, si è registrato un aumento vertiginoso del traffico dati in Rete
  - Per l'introduzione di nuove tecnologie (AI, IoT, ecc)
  - Per nuovi servizi offerti agli end consumer (servizi di streaming, cloud computing and storing, ecc)
- La maggior parte di questo traffico viene generata all'interno dei datacenter per connettere diversi server operanti in parallelo: altissima capacità richiesta per questa tipologia di interconnessione

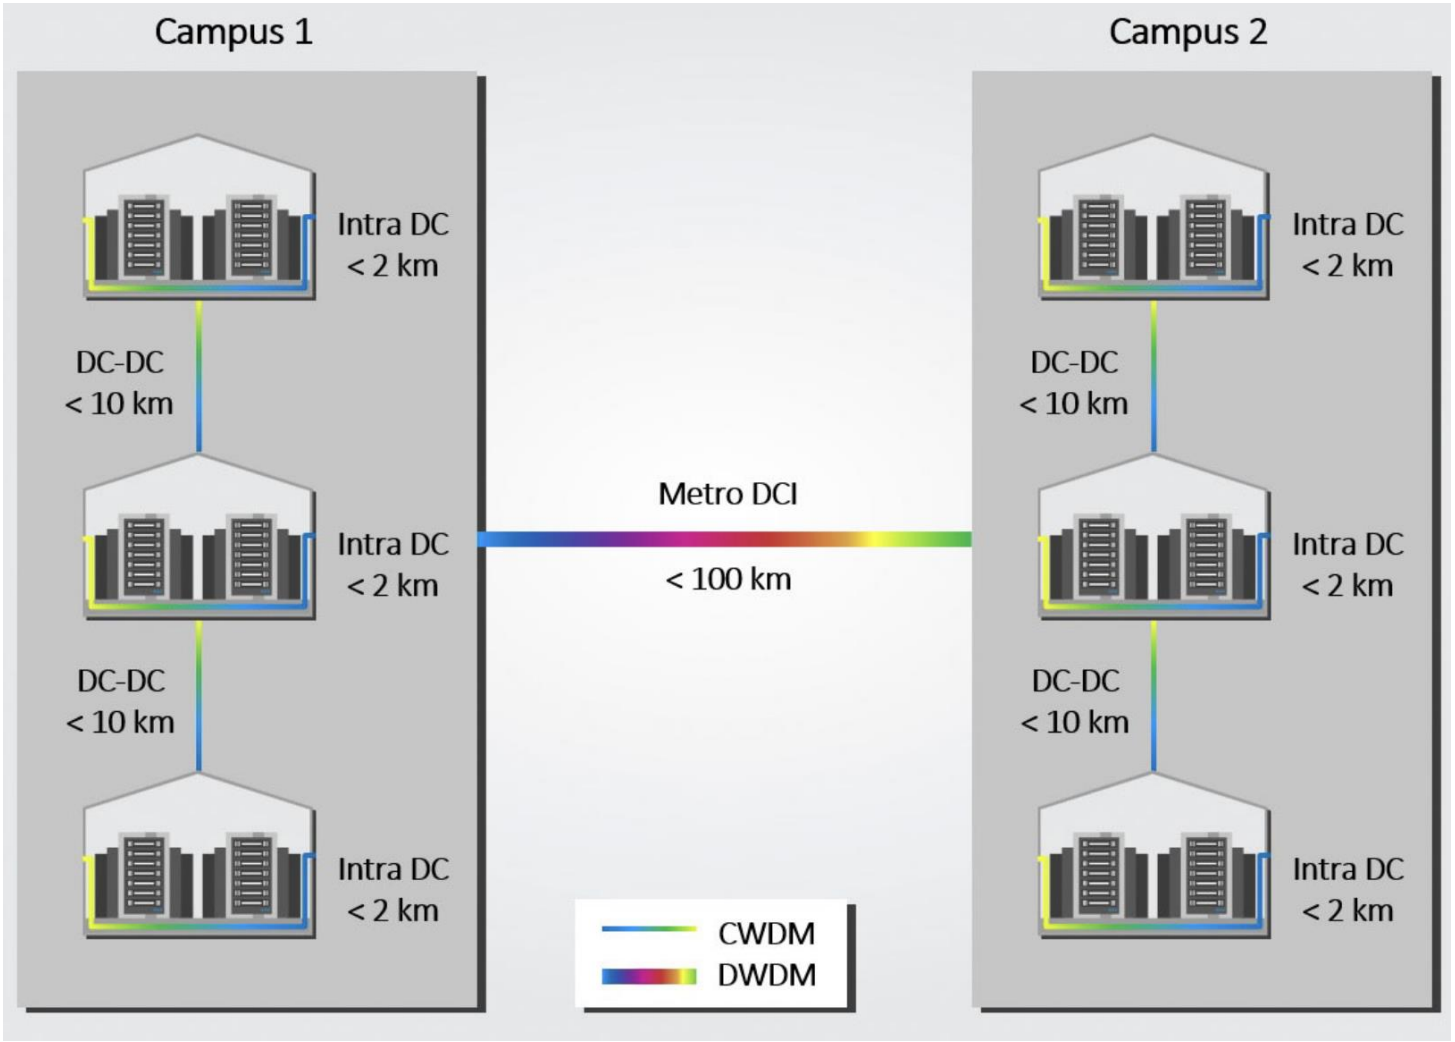
Sistemi di comunicazione ottica guidati

- Sistemi di trasmissione basati sulla propagazione guidata in fibra ottica
- Rete di accesso: trasmissioni a medio-corto raggio per connettere gli utenti al central office a cui afferiscono mediante una rete ad albero/stella ($\sim 0.5 - 20$ km)
- Rete metropolitana: trasmissioni a medio/lungo raggio per connettere i nodi di transito ad alta capacità in ambito metropolitano/regionale ($\sim 50 - 300$ km); topologia parzialmente magliata o ad anello
- Rete core: trasmissioni a lungo raggio per connettere nodi ad altissima capacità in ambito nazionale/intercontinentale ($\sim 300 - 10000$ km); topologia parzialmente magliata o punto-punto
- Rete tra datacenter: trasmissioni punto-punto a corto raggio ad alta capacità tra datacenter ($\sim 0.1 - 10$ km) o tra server di uno stesso datacenter ($\sim 0.1 - 2$ km)



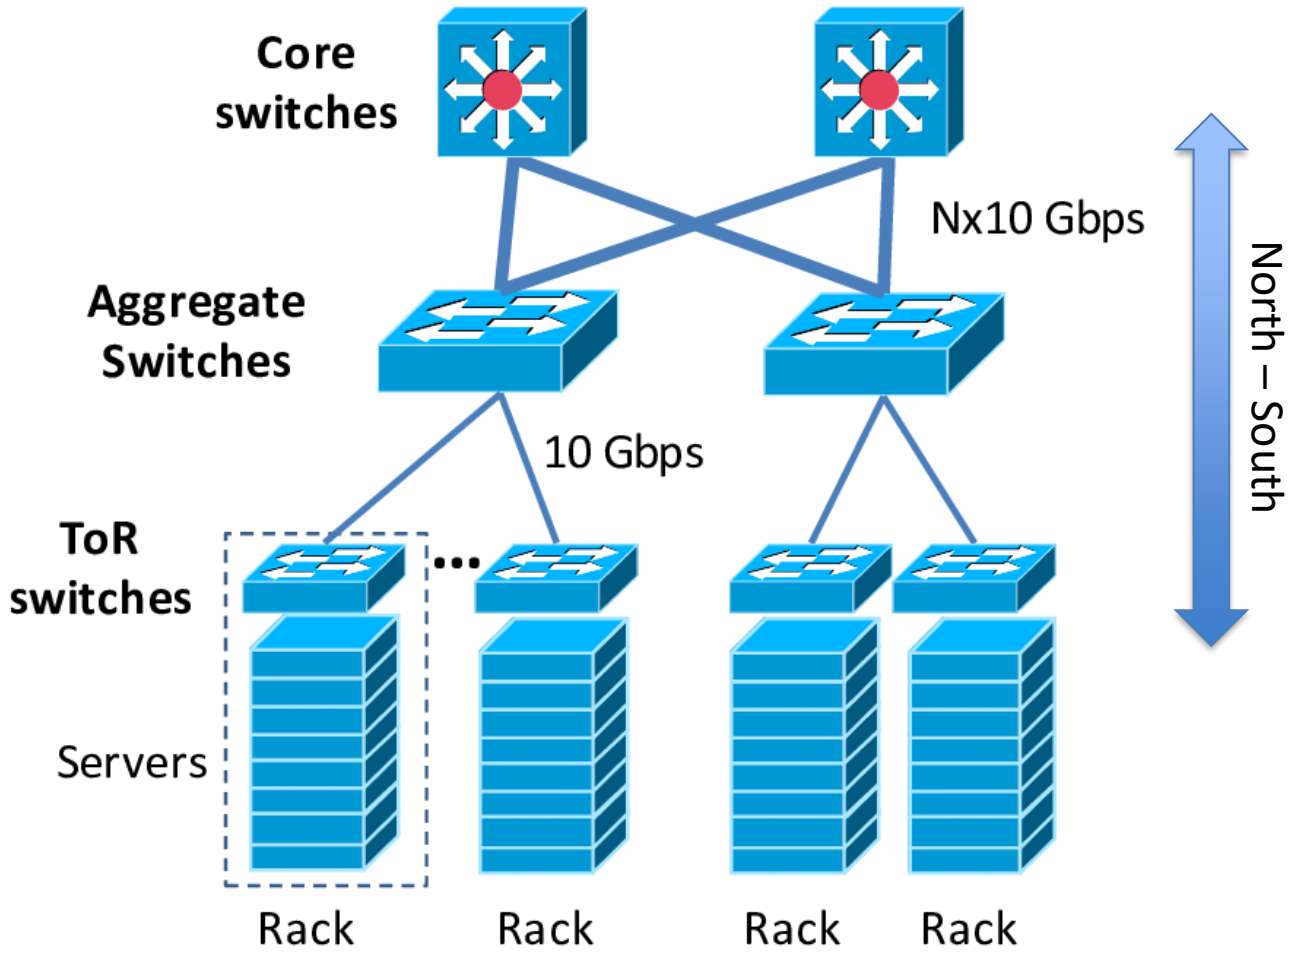
DCI: datacenter interconnections

- Inter-datacenter inter-campus: connessioni tra datacenter geograficamente distanti
  - Distanze > 10 km
  - Connessione punto-punto ad altissima capacità per trasferire una quantità elevata di dati
- Inter-datacenter intra-campus: interconnessione tra diversi datacenter
  - distanze dell'ordine di $\sim 1 - 10$ km
  - Connessione punto-punto ad alta capacità
- Intra-datacenter: connessioni tra server di uno stesso datacenter
  - Distanze ridotte dell'ordine di $\sim 0.1 - 2$ km
  - Bit-rate più contenuti
  - Numero di apparati e di interconnessioni elevatissimo



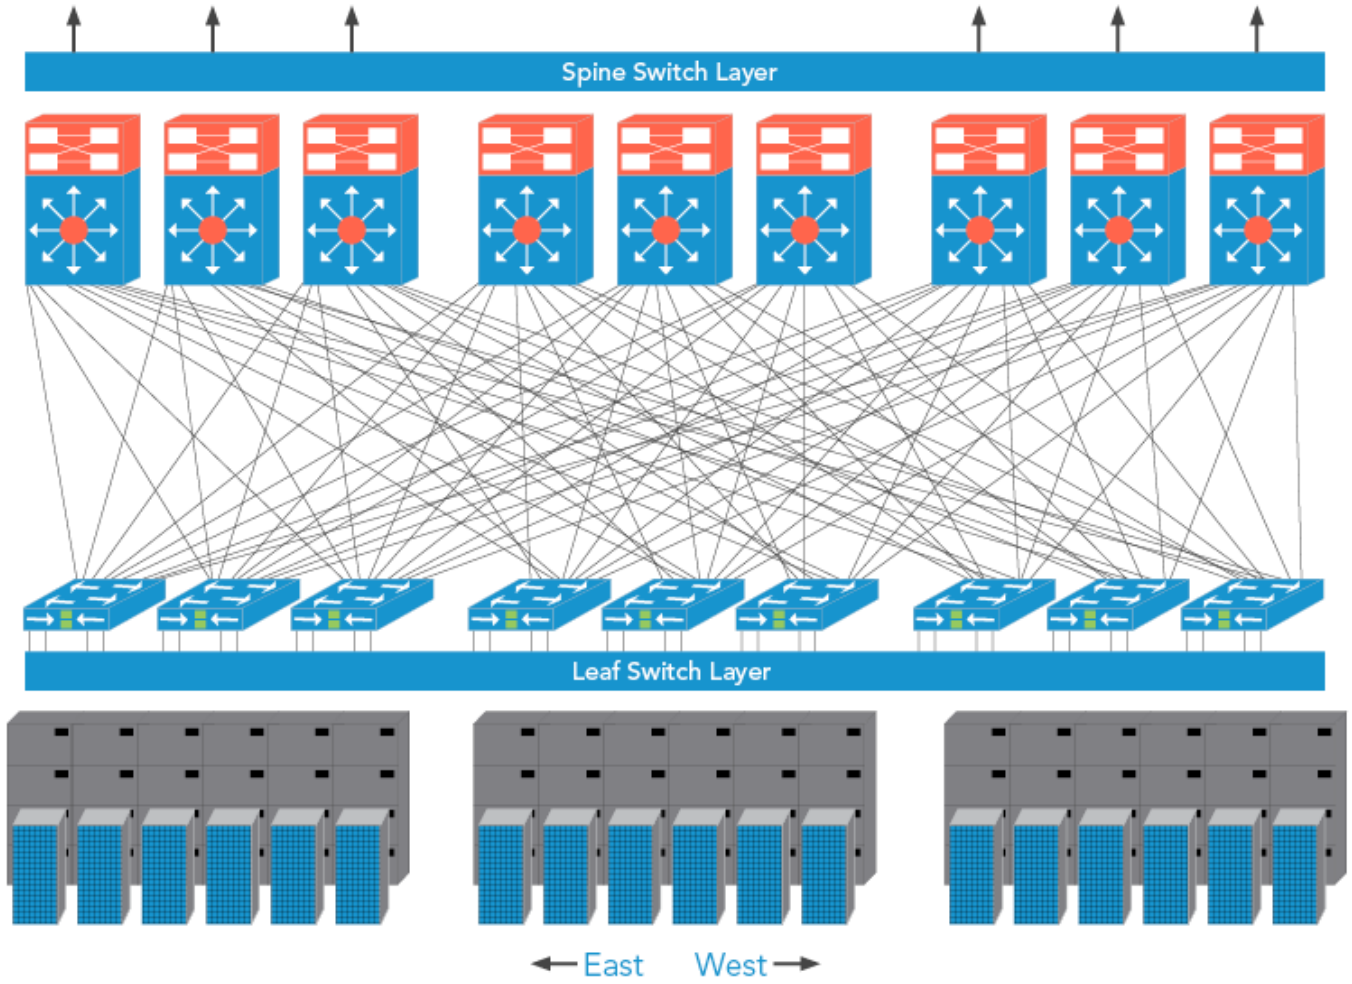
Modello tradizionale di datacenter

- Datacenter tradizionale basato su tre livelli di aggregazione
- Tipologia molto utile quando il traffico interno del datacenter è dominato da interazioni tra i server interni al datacenter e client locali
- Architettura di rete basata su una direzione del traffico prevalentemente nord – sud
- Quando un server deve comunicare con un altro server appartenente ad un altro segmento di rete, è necessario «scalare» tutta l'architettura per poi «ridiscendere»
- Modello non efficiente per servizi di tipo cloud computing, poiché consuma molte risorse (banda di comunicazione) e genera latenze molto alte

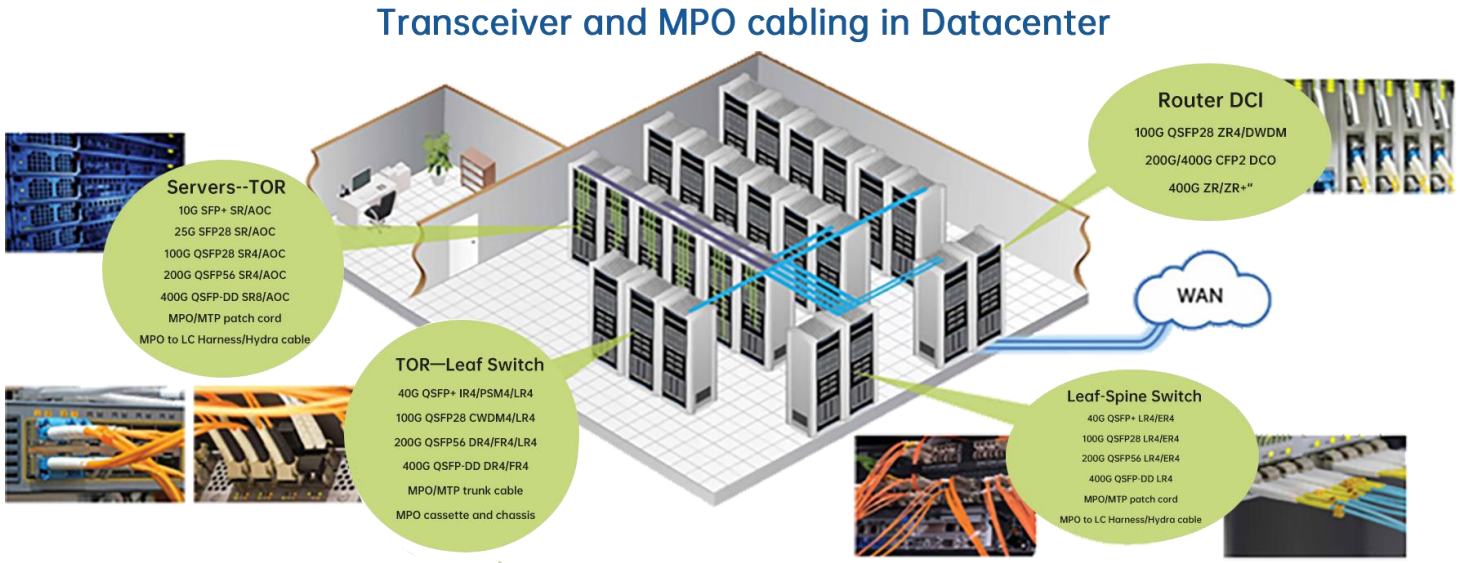


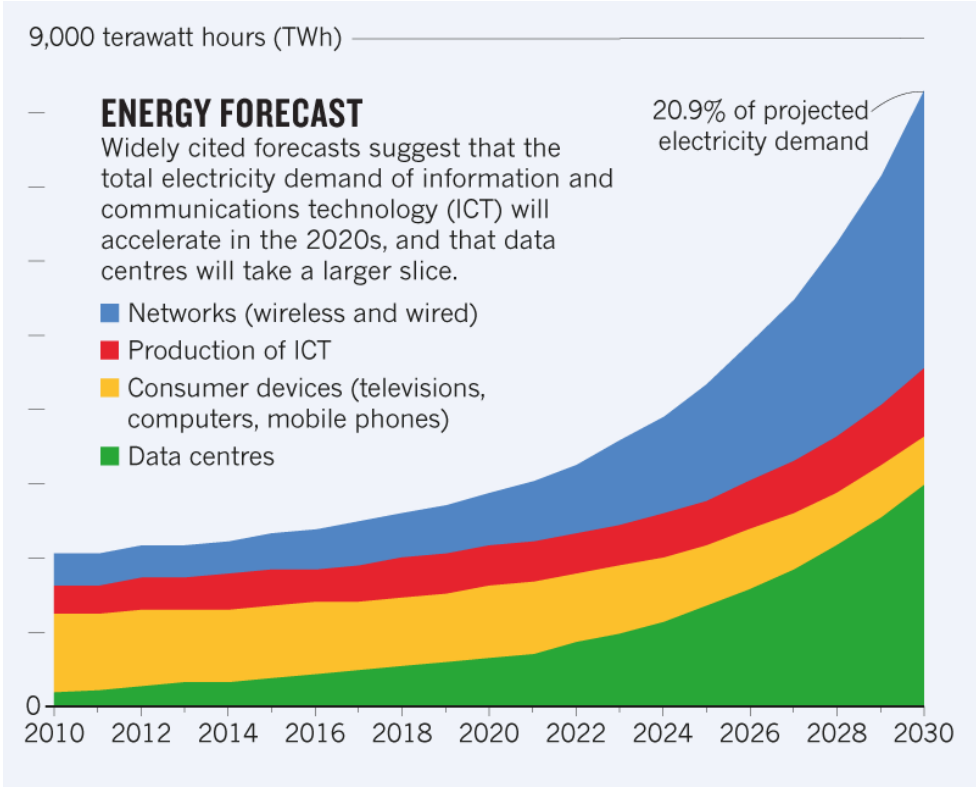
Modello attuale di datacenter

- Architettura **spine-leaf**: topologia di rete composta da due livelli di switch
- Livello leaf: composto da switch di accesso che aggregano il traffico dai server; si connettono direttamente agli switch spine o al core di rete
- Gli switch spine interconnettono tutti gli switch leaf in una topologia full-mesh
- Infrastrutture cloud e uso di container: traffico prevalente da server a server in direzione est – ovest, determinato da componenti distribuiti su più server o VM
- Migliore scalabilità. È possibile aggiungere ulteriori switch spine/leaf, aumentando così la capacità senza interruzione di servizio



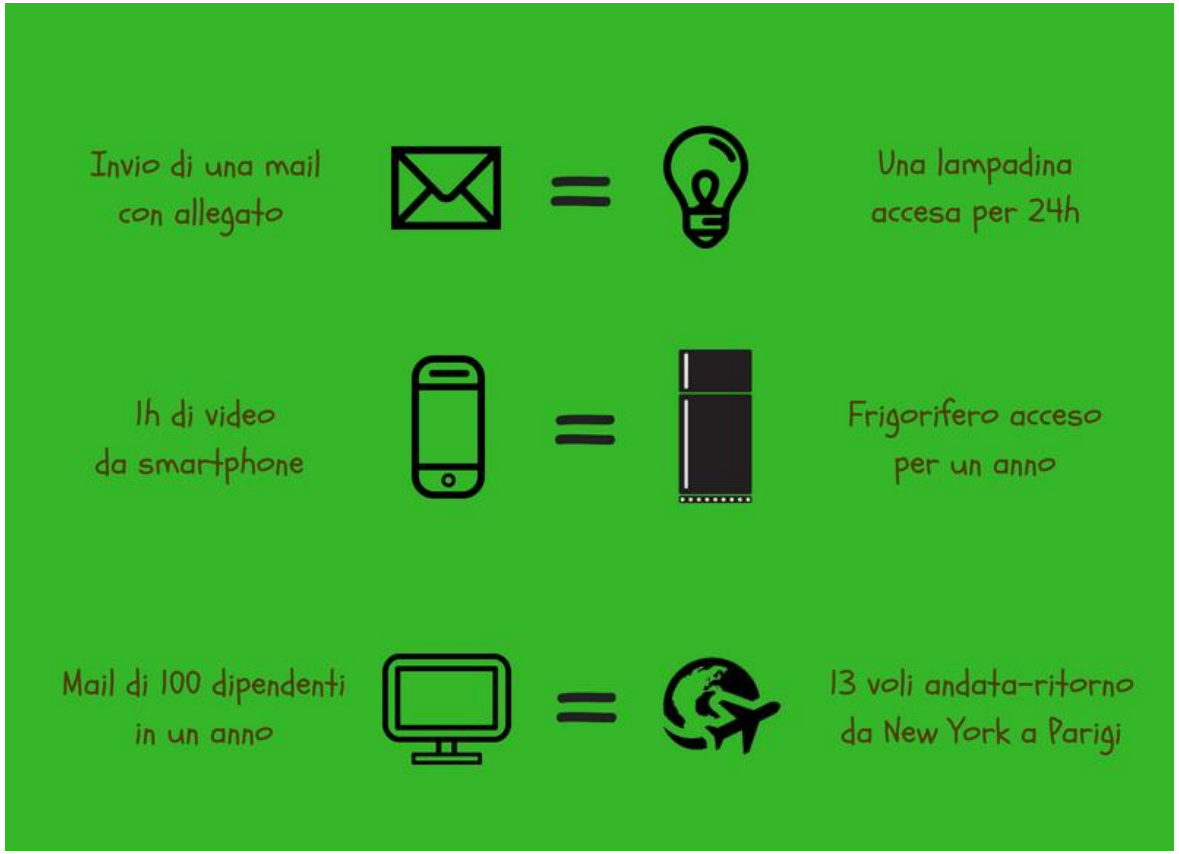
Tipologia di connessioni e consumo





- Server – Top-of-the-Rack (TOR): connessioni su fibra multimodo e singola λ ⇨ fibra singolo modo e Coarse WDM per il futuro ad alta capacità
- TOR – Leaf switch e Leaf – Spine switch: connessioni su fibra singolo modo a singola λ o multi-λ
- Soluzioni a basso consumo energetico per limitare l'impatto ambientale dovuto alla elevata quantità di dati scambiati all'interno dei datacenter

Quanto inquina Internet?





Quanto inquina il web?

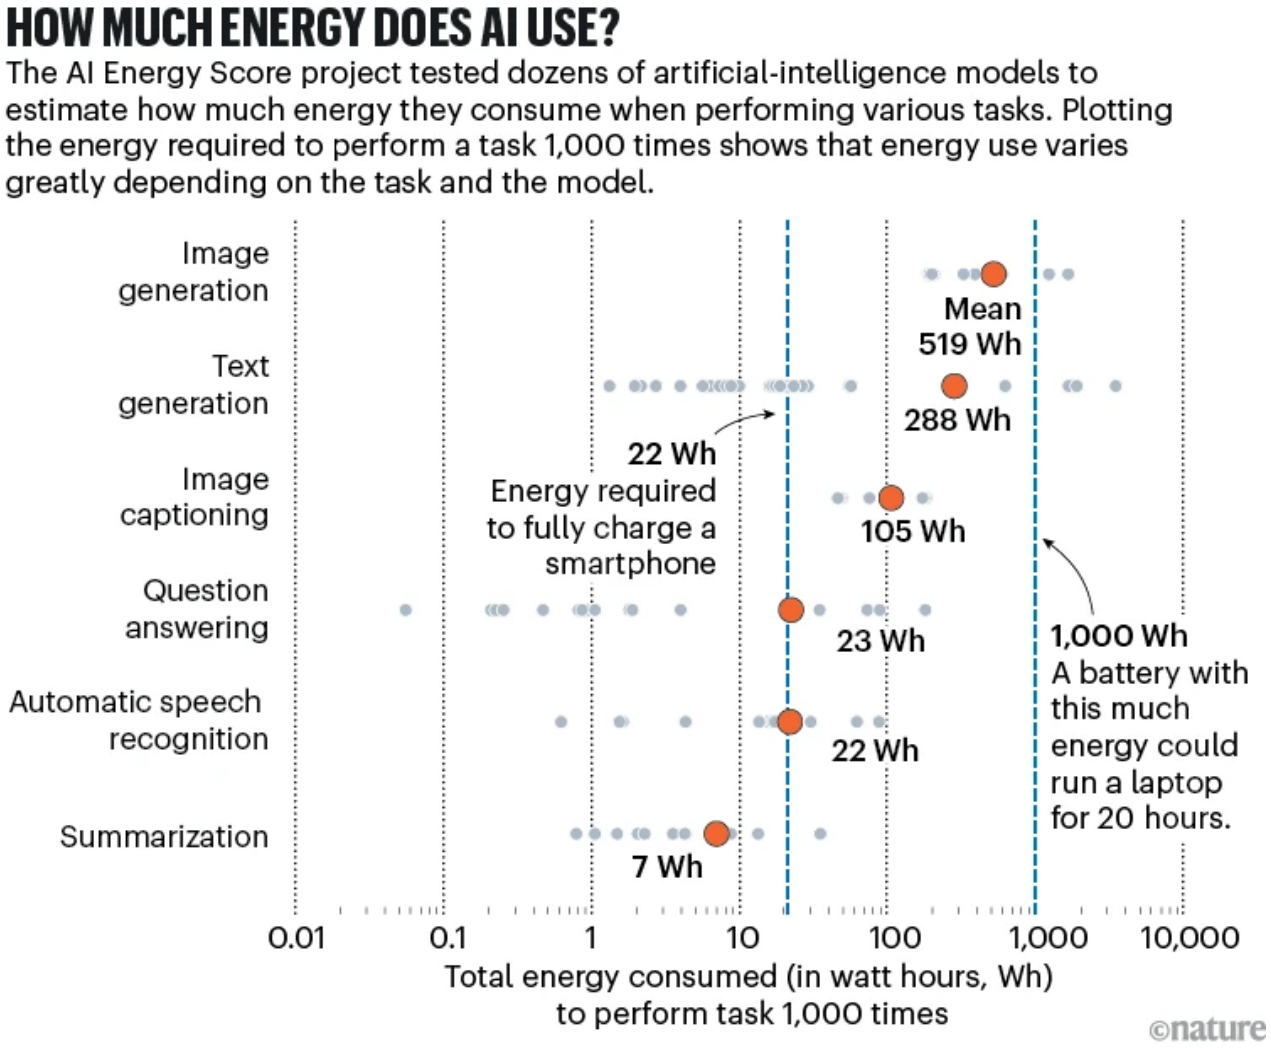
Il consumo energetico dei data center è pari a:

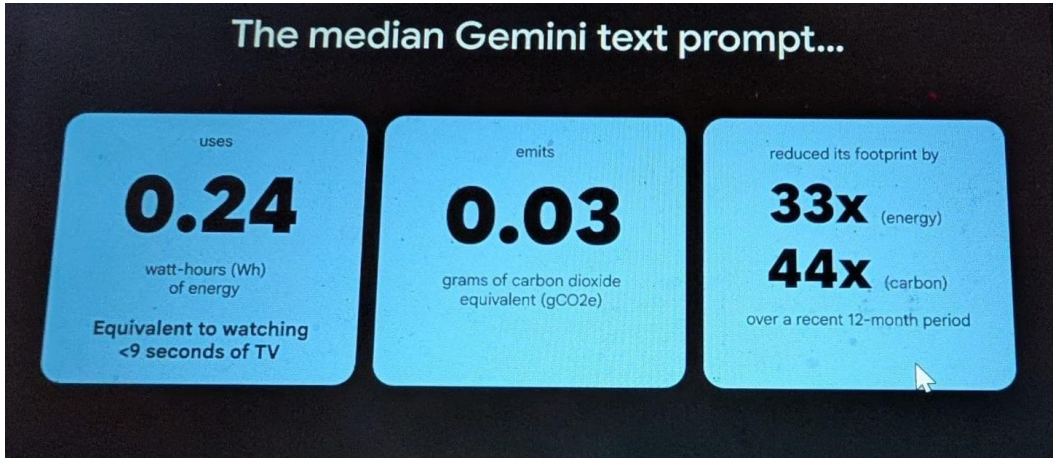
1%

della domanda globale di energia.



Quanto inquina l'AI?







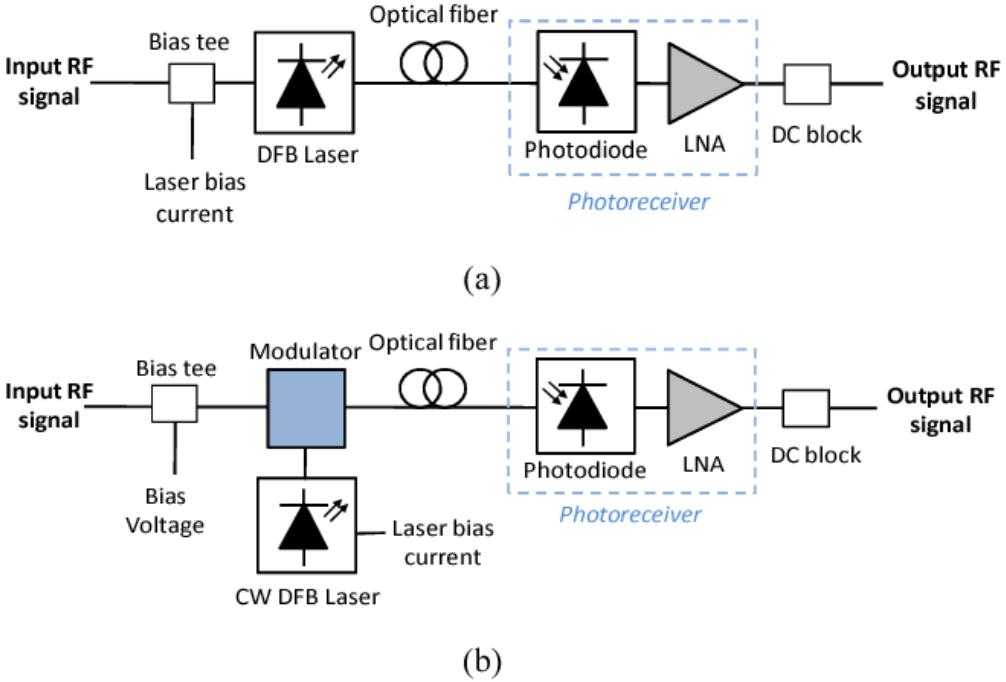
Energia necessaria ad «addestrare» modelli evoluti di elaborazione del linguaggio naturale → CO_2 **284** tonnellate di CO_2 → **5 volte** vita media auto produzione inclusa

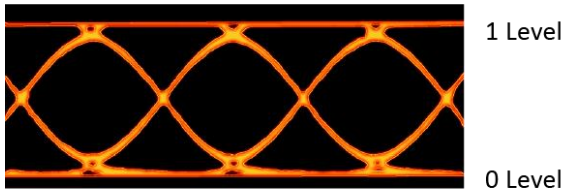
Requisiti di sistema (intra-datacenter)

	Attenuazione	Dispersione	Effetti non lineari	Crosstalk	Complessità	Costo
Interconnessione in datacenter						

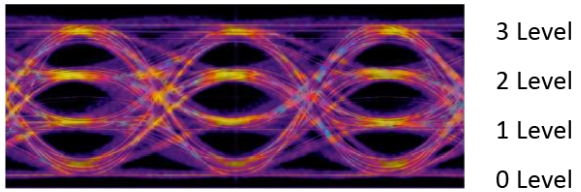
- Connessioni punto-punto a corto raggio: limitata attenuazione ed assenza di effetti non lineari
- Alta capacità su fibra monomodo o multimodo: impatto della dispersione cromatica e/o della dispersione modale
- Singola lunghezza d'onda su più fibre o coarse WDM: nessun effetto di crosstalk
- La complessità/footprint del sistema deve rimanere molto limitata, a causa del numero elevatissimo di connessioni da installare
- Il costo/consumo energetico della singola soluzione deve essere molto limitato, dato il numero consistente di connessioni da instaurare

Schema di interconnessione (IM/DD)



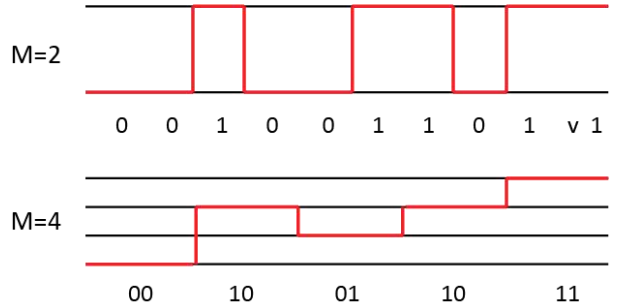


NRZ: 1 bit per clock cycle



PAM4: 2 bits per clock cycle

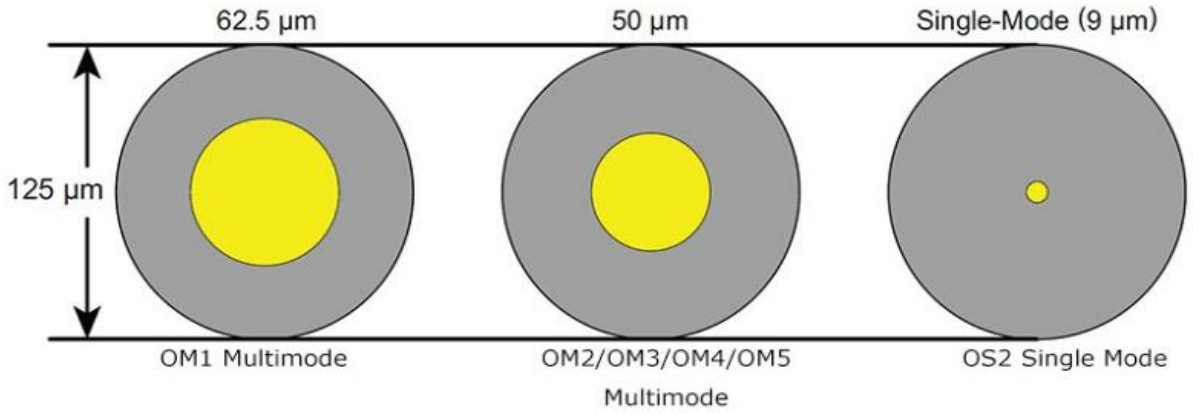




- **Intensity Modulation – Direct Detection (IM/DD)**: trasmissione del segnale attraverso la modulazione dell'intensità del campo ottico
- Il segnale è ricevuto attraverso un singolo fotodiodo, che trasforma l'intensità ottica in corrente elettrica
- Modulazione diretta della corrente di alimentazione del laser o utilizzo di modulatori esterni (costo e footprint maggiori) in base al bit-rate richiesto
- Modulazioni On-Off keying (**OOK**) o **4-PAM**

Fibra ottica multimodale MMF

- Distanza di trasmissione limitata dal fenomeno della dispersione modale
- Funzionamento in 1° finestra (850 nm)
- Utilizzo in connessioni tra server e TOR e tra TOR e Leaf switch
- Parametri fondamentali: prodotto banda – distanza e power budget

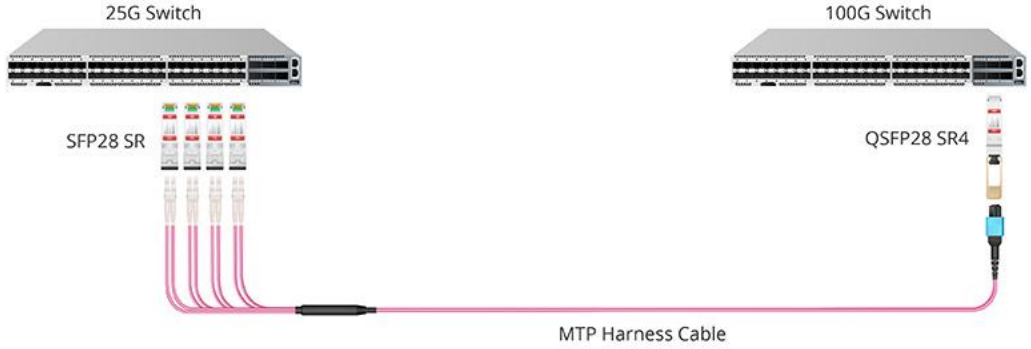


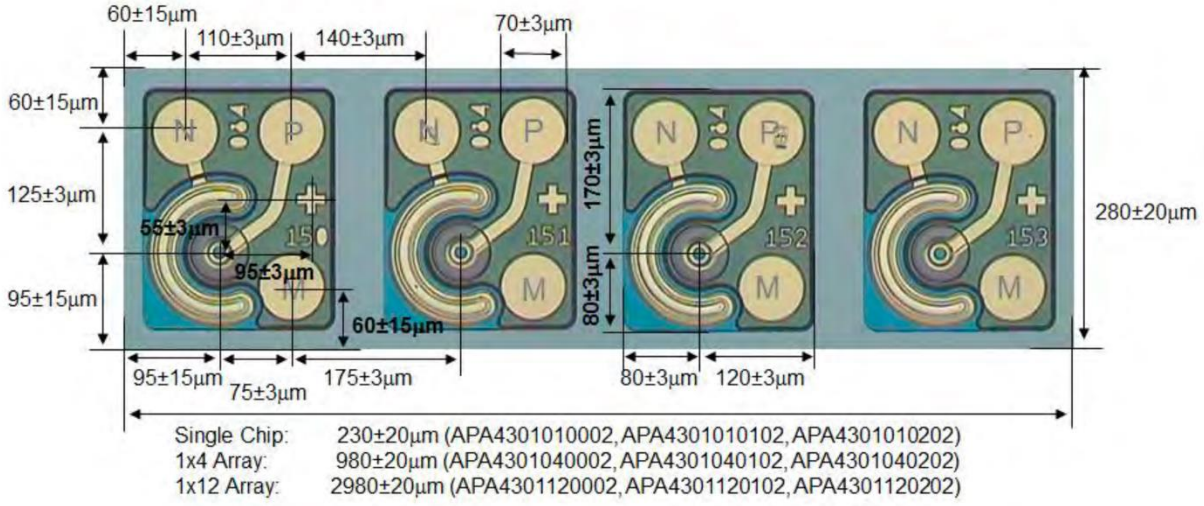
Fibra ottica monomodale SMF

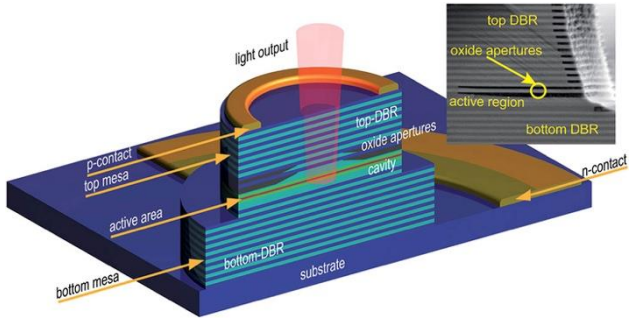
- Non si ha limite dovuto a dispersione modale.
- Presenza di dispersione cromatica
- La distanza di trasmissione può essere limitata dall'attenuazione
- Funzionamento nella 2° finestra (1300 nm) e in 3° finestra (1500 nm)
- Utilizzo per connessioni ad altissima capacità tra TOR e Leaf switch, tra Leaf e Spine switch e tra datacenter geograficamente distanti
- Possibile utilizzo di coarse WDM e di dense WDM (solo per connessioni tra datacenter distanti)

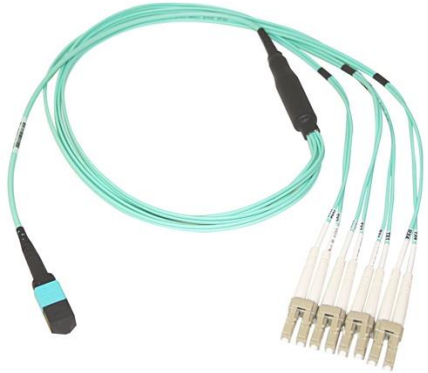
Bundle di fibre ottiche

- Per trasmettere più canali in parallelo ed ottenere una densità di trasmissione più elevata, si utilizzano cavi composti da più fibre ottiche
- Molto utilizzati per interconnessioni a 40 Gb/s o 100 Gb/s in fibra multimodo in prima finestra (850 nm)
- Laser di tipo VCSEL modulati direttamente a 10 Gb/s o 25 Gb/s (costo e dimensioni molto limitate $\sim 20 - 100\$$)
- Basso rapporto di estinzione ⇒ bassa qualità del segnale generato
- Evoluzione futura: utilizzo di modulazione 4-PAM per raggiungere un aggregato di 200 Gb/s
- Evoluzione futura: utilizzo di fibre speciali per space division multiplexing



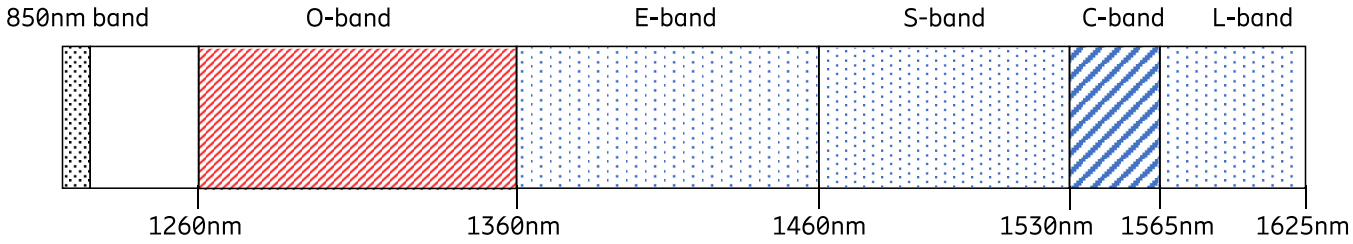


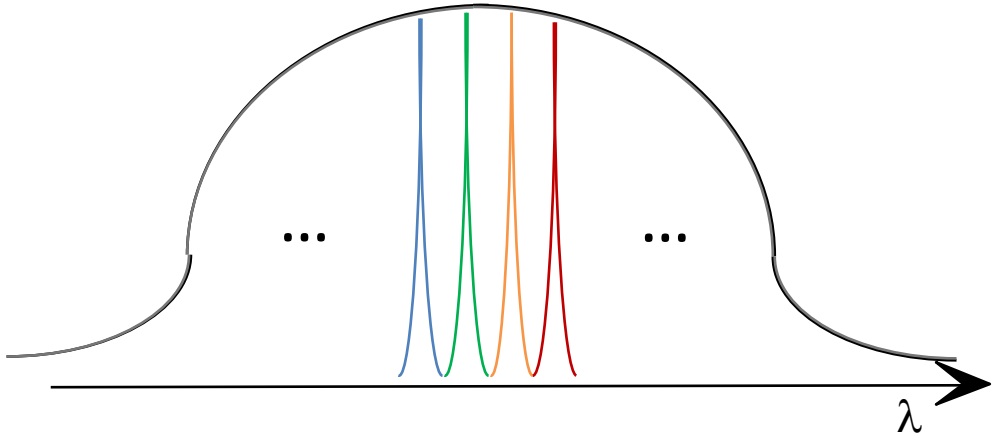


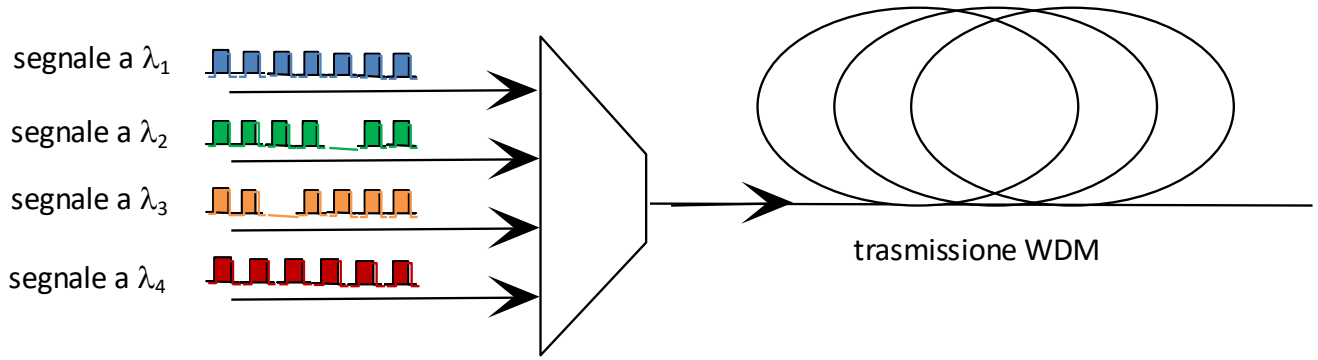


Coarse WDM

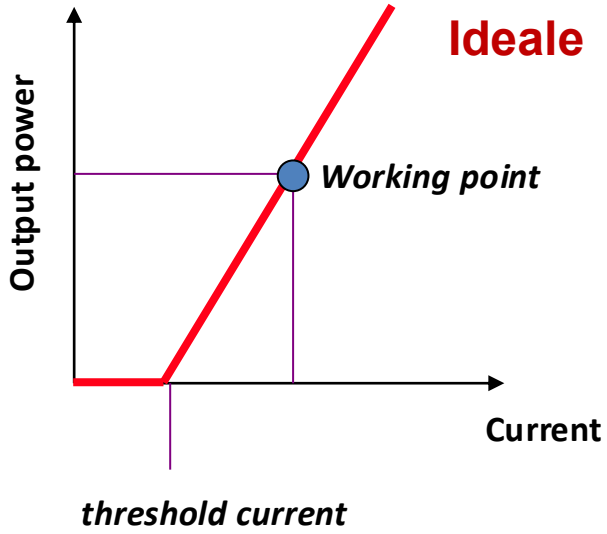
- All'interno della finestra trasmissiva della fibra si trasmettono più canali a diversa lunghezza d'onda
- In caso di coarse WDM, la spaziatura $\Delta\lambda$ tra i canali ottici è di 20 nm
- Utilizzato in **banda O** (1310 nm) su fibra monomodo
- λ nominali:
  - 1270 nm
  - 1290 nm
  - 1310 nm
  - 1330 nm
- Soluzione molto efficace per aumentare di un fattore 4 la capacità trasportata da una singola fibra ottica con una bassa complessità del sistema
- Sistemi di modulazione basati sull'utilizzo di modulatori esterni

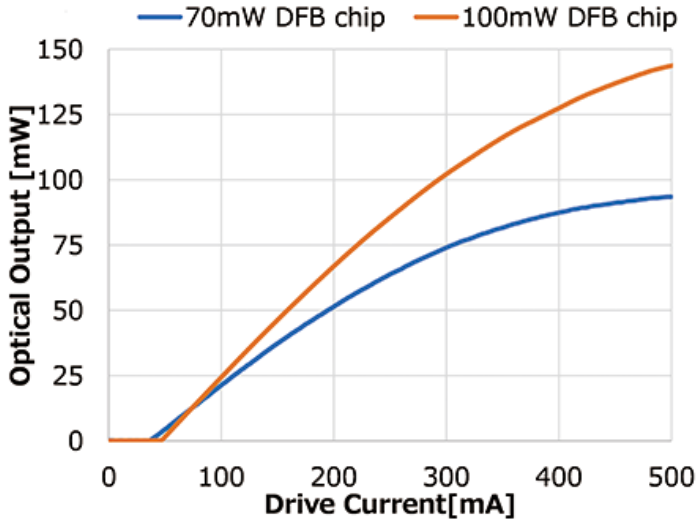


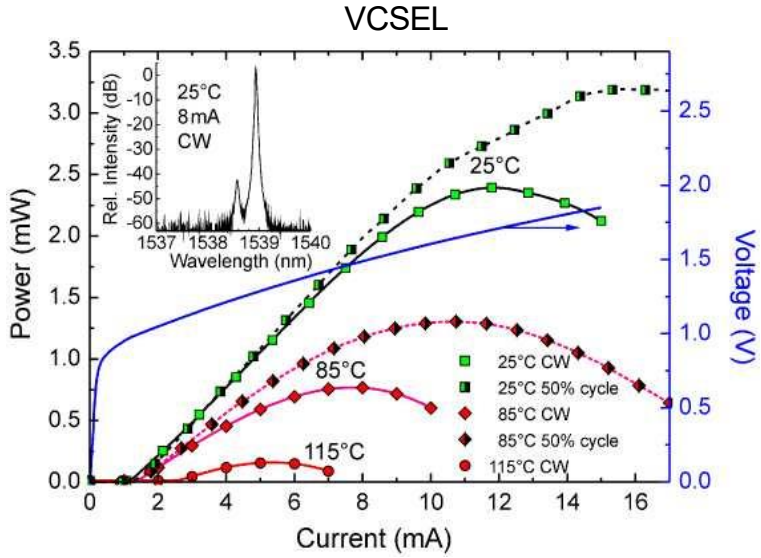




Caratteristica potenza – corrente di un laser





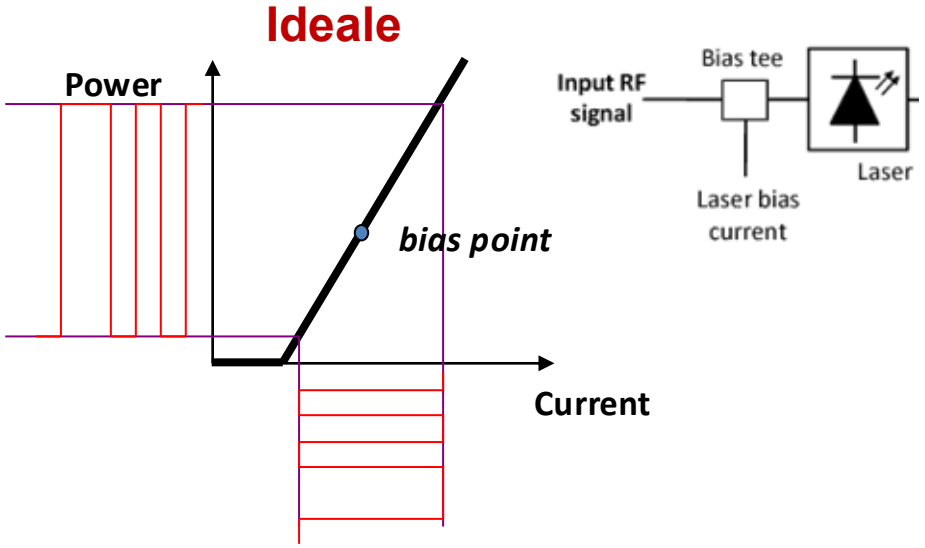


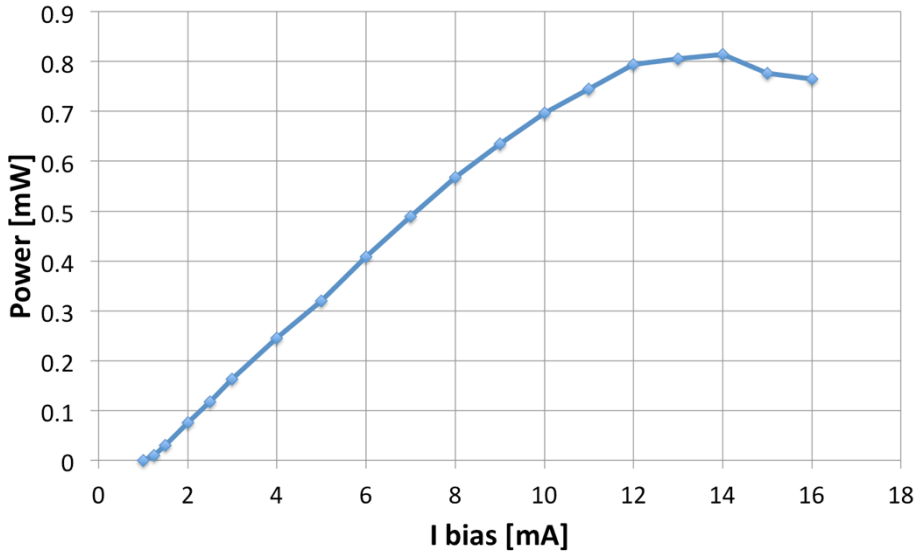
- La potenza emessa da un laser dipende dalla corrente di alimentazione, che agisce sul numero di portatori disponibili nel mezzo attivo (numero di elettroni carichi pronti a decadere per emissione stimolata)
- Idealmente, la caratteristica dovrebbe essere perfettamente lineare
- Corrente di soglia: corrente oltre la quale si riesce ad instaurare una radiazione laser, cioè corrente che permette di ottenere un guadagno del mezzo attivo che bilancia perfettamente le perdite di cavità
- Dispositivi reali: la curva non è perfettamente lineare, ma tende a saturare ad una determinata potenza massima, in base alla caratteristiche fisiche del dispositivo
- Oltre questo punto, la potenza emessa può anche diminuire a causa del *thermal roll-over*, cioè alla dissipazione in calore di tutta l'energia in eccesso (molto evidente per laser di tipo VCSEL)

Modulazione diretta di un laser (1)

- Il segnale RF viene utilizzato per variare la corrente di alimentazione del laser ⇒ «1»: acceso; «0»: spento
- Modulazione di tipo **On-Off Keying (OOK)**
- Rapporto di estinzione $\boldsymbol{ER = \frac{P_1}{P_0}}$ indica quanto i due livelli di segnale sono separati in ampiezza
- $ER \to +\infty$ nel caso ideale, per modulazioni reali $ER \approx 3 - 20\ dB$ in base a quanto è vasta la zona lineare nella dinamica del laser e a causa della presenza di oscillazioni di rilassamento per correnti troppo vicine alla soglia
- Più ER è alto, migliore sarà la qualità del segnale generato (maggiore differenza tra livello alto e basso)
- Corrente di bias: valore medio del segnale modulante
- La potenza media emessa è immediatamente ottenuta dal punto corrispondente alla corrente di bias
- In generale

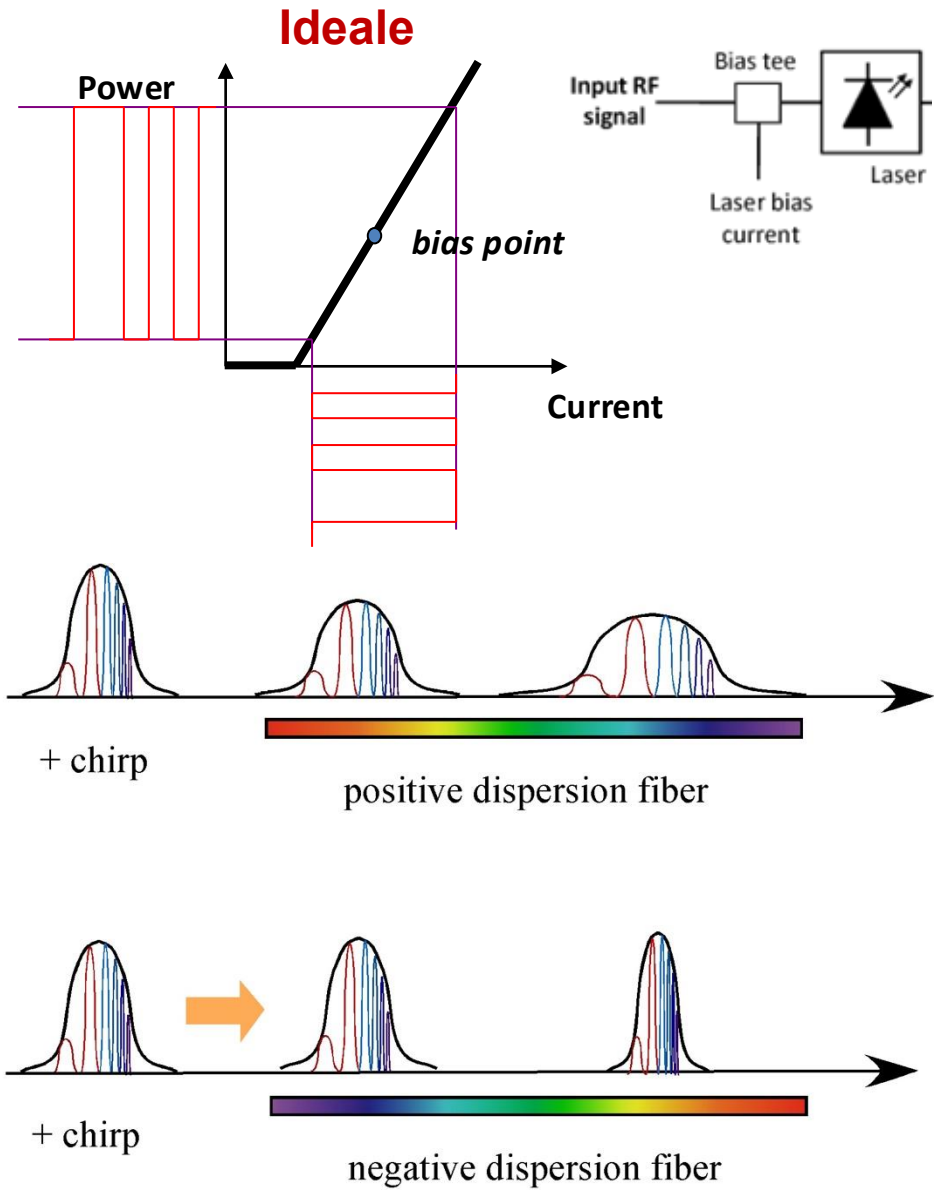
$$\bar{P}_m = \frac{1}{2}(P_1 + P_0) = \frac{1}{2}P_0(1 + ER) \xrightarrow{ER \gg 1} \frac{1}{2}P_0 \cdot ER = \frac{1}{2}P_1$$



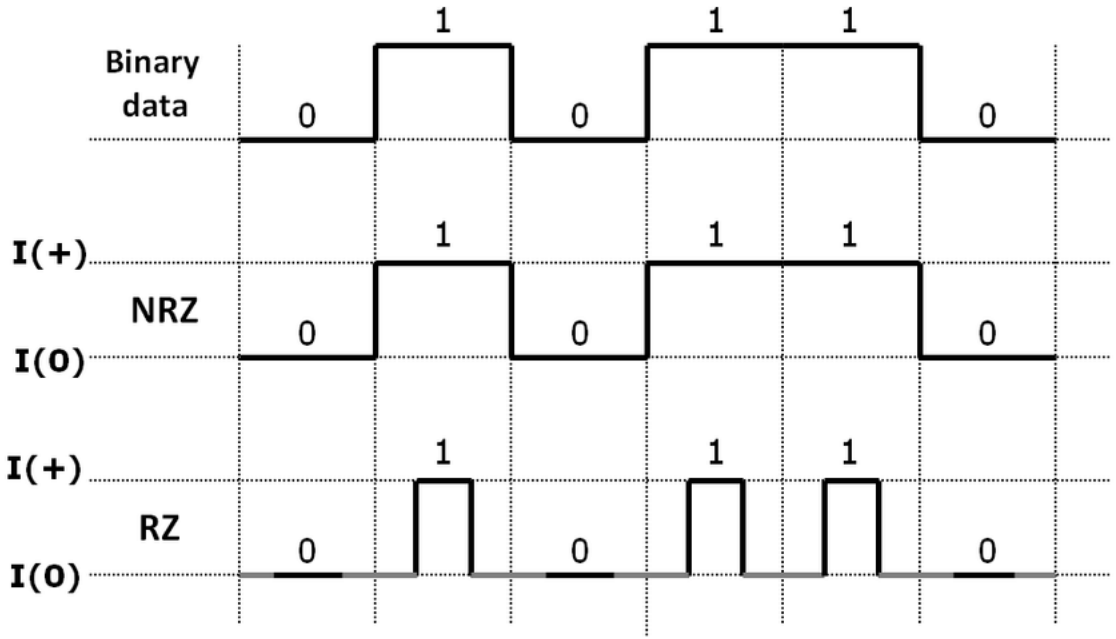


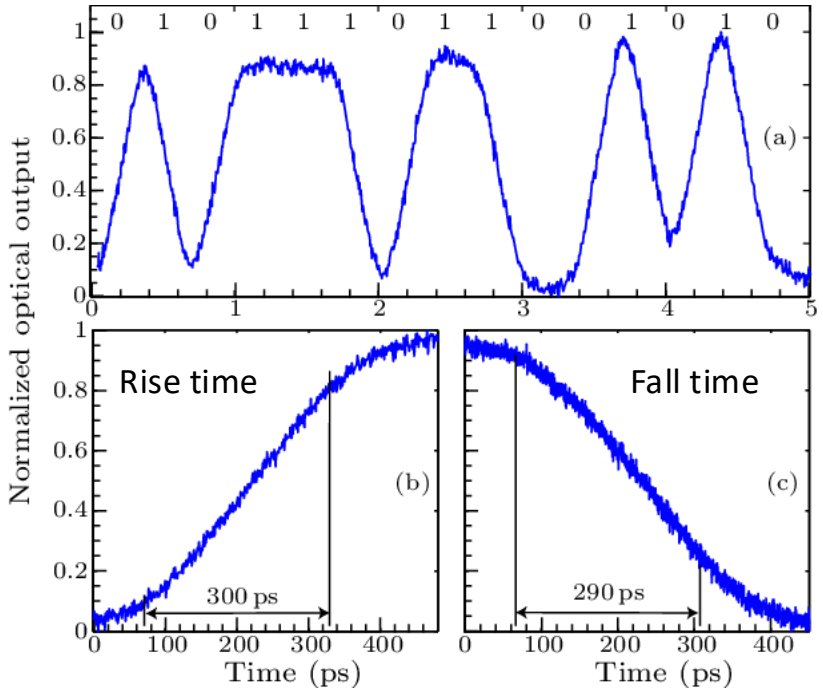
Modulazione diretta di un laser (2)

- La variazione della corrente di alimentazione è accompagnato da una variazione della densità di portatori carichi dentro la cavità laser, che a sua volta ne modifica l'indice di rifrazione
- La fase del segnale ottico emesso dal laser modulato direttamente cambia con il tempo (fenomeno del chirp in frequenza) ⇒ allargamento dello spettro del segnale
- La modulazione diretta induce un blue-shift nella testa del bit (sono ritardate le λ maggiori)
- Se segnale è IM/DD, non si riscontrano problemi in ricezione diretta, ma si hanno effetti sulla propagazione a causa della dispersione cromatica
- Regione di dispersione anomala (D > 0): la dispersione ritarda le λ maggiori ⇒ la dispersione allarga più velocemente l'impulso
- Regione di dispersione normale (D < 0): la dispersione ritarda le λ minori ⇒ la dispersione inizialmente comprime la forma d'onda dell'impulso, compensando il chirp; successivamente si ha un nuovo allargamento



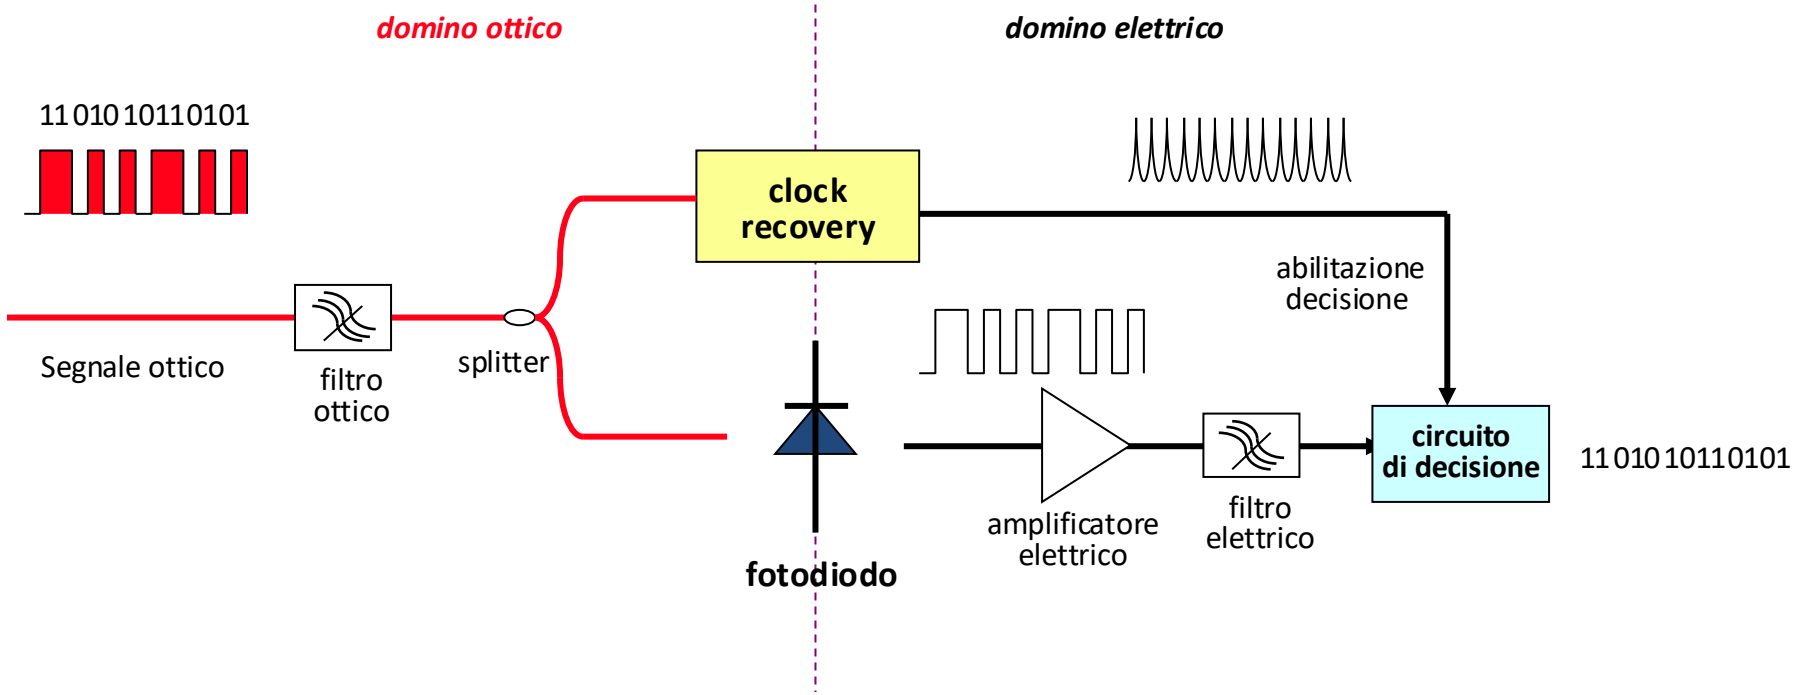
Codifica di segnale





- Il segnale binario modulante è normalmente espresso tramite la codifica **Non-Return-to-Zero (NRZ)**
- NRZ: il segnale non ritorna a zero tra un bit e il successivo
- In presenza di sequenze di 1 o di 0, il segnale rimane costante nel tempo (livello alto o basso)
- Banda monolatera elettrica utilizzata $\approx \frac{1}{T_b}$ ⇒ banda ottica $\approx \frac{2}{T_b}$
- Formato Return-to-Zero (RZ): il segnale ritorna a zero tra un bit e il successivo
- Permette un recupero di clock migliore, ma banda doppia

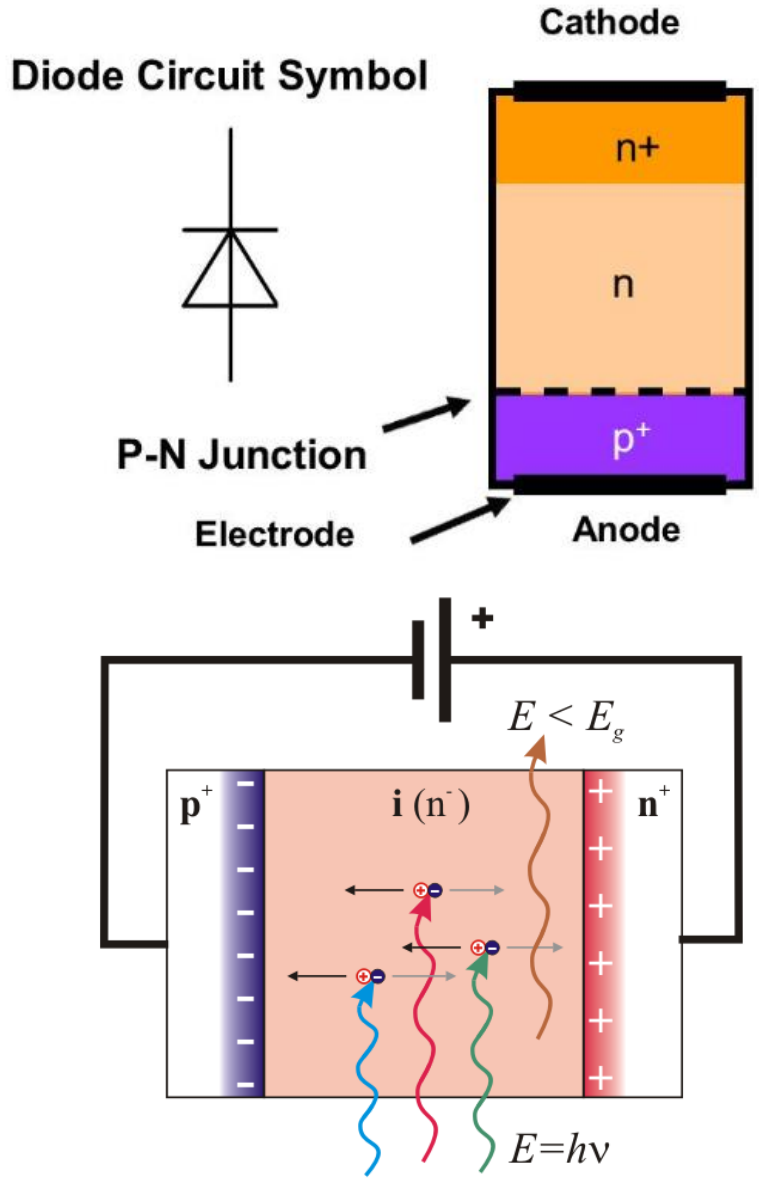
Blocco di ricezione



- **Rivelazione diretta**: la radiazione ottica viene convertita in corrente elettrica da un **fotodiodo**
- Il fotodiodo genera una corrente elettrica proporzionale alla potenza ottica in ingresso
- Può essere modellato come un'operazione di modulo quadro del campo elettrico in ingresso
- Il segnale elettrico risultante viene poi campionato al centro dell'impulso; il bit ricevuto è determinato da un'operazione a soglia
- Dal segnale ricevuto si stima in parallelo il clock utilizzato al trasmettitore per effettuare operazioni di campionamento e decisione correttamente sincronizzate

Il fotorivelatore

- I rivelatori di segnali ottici sono riconducibili a fotorivelatori PIN: dispositivi a semiconduttore dove l'energia ceduta dai fotoni in arrivo provoca una proporzionale liberazione di cariche elettriche, raccolte su un carico.
- La struttura del diodo PIN è realizzata con 2 strati *p* e *n*, separati da una regione di materiale non drogato (strato intrinseco). Il diodo viene polarizzato con tensione inversa, tale da svuotare completamente la regione intrinseca. In queste condizioni, nessuna corrente circolerà nella giunzione.
- All'arrivo di un fotone, l'energia incidente provoca la transizione di un elettrone dalla banda di valenza alla banda di conduzione: gli elettroni liberati grazie alla differenza di potenziale applicata danno luogo ad un passaggio di corrente.

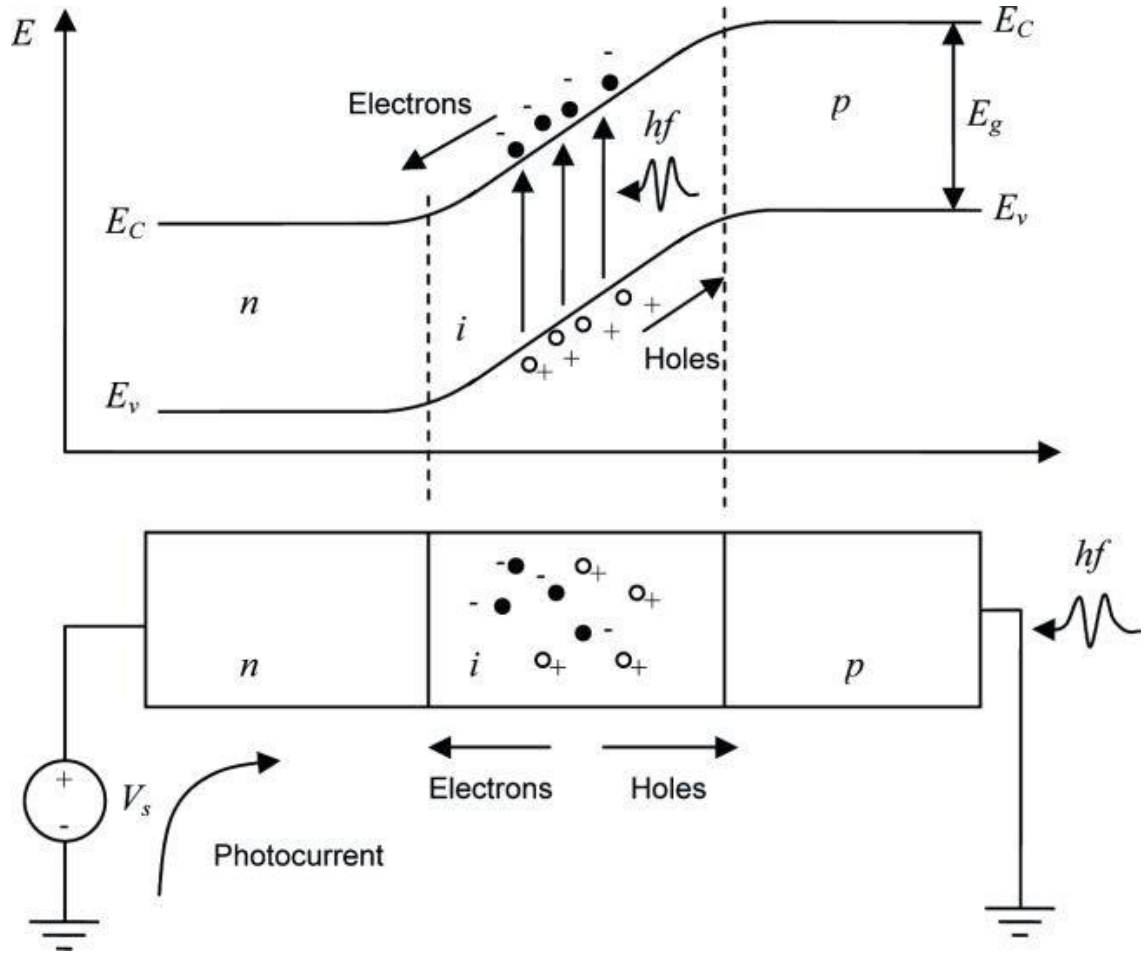


Fotoricevitori PIN

- Il processo può venire attivato solo da fotoni che possiedono energia hv superiore all'energia del gap E_g
- Data una determinata potenza ottica incidente $P_{ottica} = I_{ottica}A$, dove I_{ottica} è l'intensità della radiazione ottica e A è la superficie su cui è distribuita, si ottiene una fotocorrente pari a

$$i_{photo} = \eta \frac{I_{ottica}A}{hv} q$$

- In cui q è la carica dell'elettrone e η rappresenta l'efficienza di conversione tra fotoni incidenti e cariche elettriche generate
- Idealmente $\eta = 1$, ma nella pratica $\eta < 1$ a causa di assorbimento ottico incompleto e di ricombinazione delle cariche generate



Caratteristiche del ricevitore ottico

- **Efficienza quantica** = rendimento medio della conversione tra fotoni incidenti e coppie elettroni/lacune generate nel processo di fotorivelazione
- **Responsivity** = definisce la relazione tra la corrente generata nel carico del rivelatore i_{photo} e la potenza luminosa incidente P_{ottica} (in *A/W* o *V/W*)

$$R = \frac{i_{photo}}{P_{ottica}} = \eta \frac{q}{h\upsilon} \left[\frac{A}{W}\right]$$

- In terza finestra si utilizzano diodi PIN in InGaAs con responsivity intorno a 0.7 A/W.
- **SNR** = è il rapporto tra il segnale utile ed il rumore all'uscita del sistema. In assenza di radiazione luminosa, il carico raccoglie la cosiddetta "corrente di buio"
- **Sensitivity** = esprime il valore minimo di potenza ottica di ingresso capace di produrre un tasso d'errore (BER) sui dati ricostruiti inferiore ad un determinato valore (per esempio 10^{-9})
- **Banda elettrica** = la fotocorrente prodotta è chiusa su un carico schematizzabile tramite una resistenza equivalente R ed una capacità C. Questi parametri elettrici definiscono la banda elettrica B_e del ricevitore

Dimensionamento del sistema di comunicazione: power budget

- L'obiettivo è assicurare che la potenza di segnale al ricevitore sia maggiore della sensibilità del ricevitore ad un dato bit-rate (cioè maggiore della potenza che assicura di operare ad un certo BER target).
- Nei sistemi ottici, il POWER BUDGET deve tenere conto di tutte le perdite di segnale intercorse durante il cammino (accoppiatori, giunti, dispositivi e componenti, attenuazione della fibra, ecc.) e di tutti gli eventuali guadagni presenti.

$$\boldsymbol{Power\ budget|_{dB} \rightarrow P_{TX} - \sum penalties + \sum G - margine = P_{RX} \geq P_{RX_{target}}}$$

- Le perdite e gli eventuali guadagni (per amplificazione) sono sommati in dB.
- Bisogna tenere conto anche di un certo margine (è desiderabile almeno di qualche dB) che garantisca una specie di 'riserva' del sistema per futuri upgrading o deterioramenti. E' di precauzione.
- Si devono tenere conto di tutte le "power penalties": potenza che sarebbe necessario addizionare al sistema al fine di ripristinare le condizioni ottimali di funzionamento
  - Attenuazioni (propagazione in fibra ottica, connettori, giunti a fusione, componenti passivi come filtri ottici)
  - Effetti di propagazione (dispersione, effetti non lineari, crosstalk tra canali)

Dimensionamento del sistema di comunicazione: BER

- Per valutare le prestazioni del sistema in termini di probabilità di errore, si introduce il parametro

$$\tilde{Q} = \frac{\mu_1 - \mu_0}{\sigma_1 + \sigma_0}$$

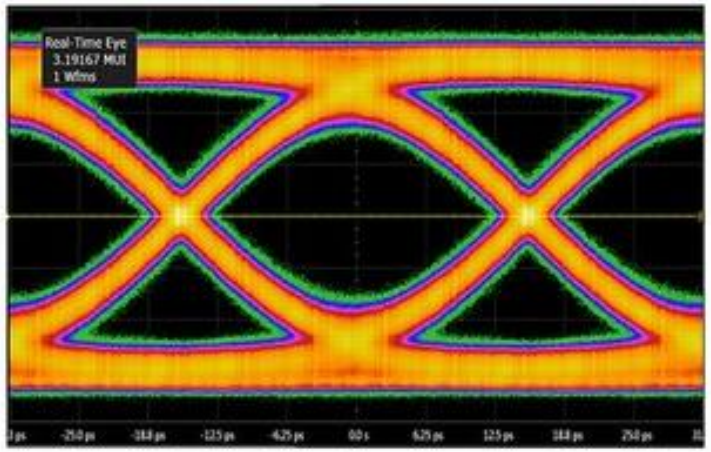
- Con μ_1 e μ_0 valori medi rilevati per i bit 1 e 0, rispettivamente; σ_1 e σ_0 deviazioni standard dei valori rilevati per il bit 1 e il bit 0, rispettivamente
- $\tilde{Q}$ rappresenta il fattore di merito della trasmissione e può essere utilizzato direttamente per il calcolo della probabilità di errore

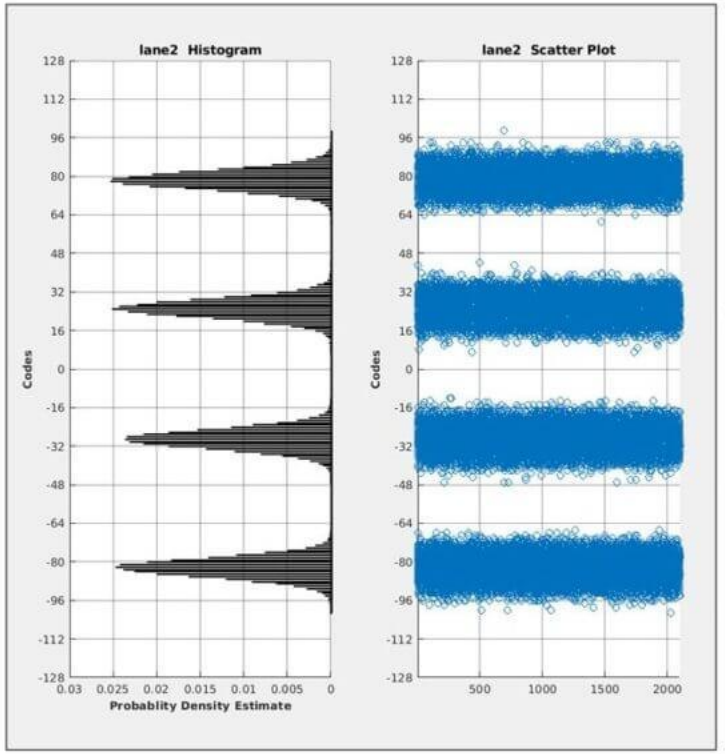
$$BER = P_e = Q(\tilde{Q}) = \frac{1}{2} erfc\left(\frac{\tilde{Q}}{\sqrt{2}}\right) \approx \frac{1}{\tilde{Q}\sqrt{2\pi}} e^{-\frac{\tilde{Q}^2}{2}}$$

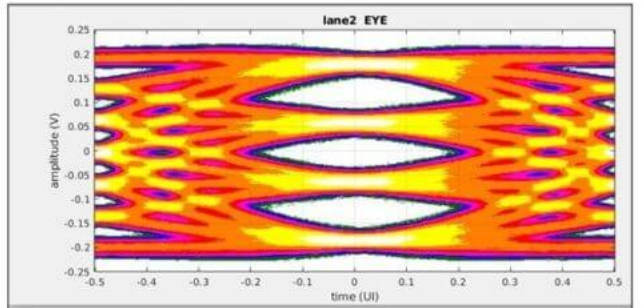
- Il fattore $\tilde{Q}$ dipende dalla differenza tra i valori medi del livello alto e del livello basso ⇒ dall'apertura del segnale
- Più i livelli sono separati tra di loro, meno il rumore avrà la possibilità di generare degli errori in ricezione

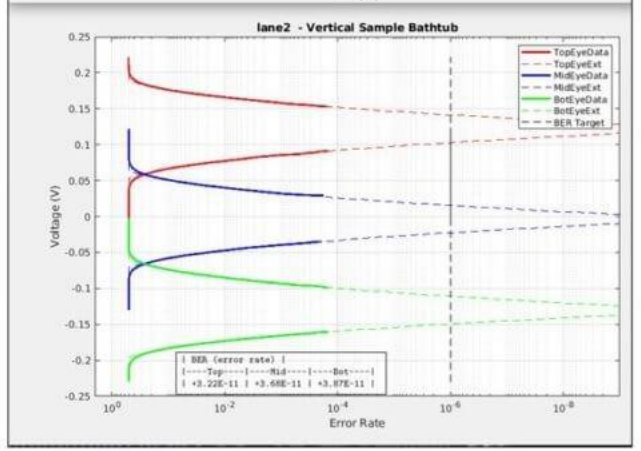
Dimensionamento del sistema di comunicazione: diagramma ad occhio

- Il fattore $\tilde{Q}$ è molto utile perché può essere misurato sperimentalmente dal segnale ricevuto, in modo da avere una stima relativamente accurata della probabilità di errore del sistema
- Più i livelli sono separati tra di loro, meno il rumore avrà la possibilità di generare degli errori in ricezione
- Utilizzo del «diagramma ad occhio»: ripiegamento del segnale su un tempo di 2 bit (simboli)
- Il punto di campionamento ideale corrisponde all'istante di massima «apertura» dell'occhio
- Misura dell'istogramma: immediato calcolo di media e varianza dei livelli ⇒ $\tilde{Q}$
- Stima approssimata del BER per segnali limitati dal rumore, problemi nella stima se è presente una dispersione non compensata









Dimensionamento del sistema di comunicazione: sensitivity

- In generale, la potenza media del segnale OOK può essere espressa come

$$\bar{P}_{RX} = \frac{1}{2}(P_1 + P_0) = \frac{1}{2}P_1\left(1 + \frac{1}{ER}\right) = \frac{1}{2}P_0(1 + ER)$$

$$P_1 = 2\bar{P}_{RX}\left(\frac{1}{1 + {}^{1}/_{ER}}\right) = 2\bar{P}_{RX}\left(\frac{ER}{ER + 1}\right)$$

$$P_0 = 2\bar{P}_{RX}\left(\frac{1}{ER + 1}\right)$$

- I valori medi rilevati per i bit 1 e 0, rispettivamente μ_1 e μ_0, sono direttamente proporzionali alle potenze associate P_1 e P_0; in questo modo si può esprimere il fattore $\tilde{Q}$ come

$$\tilde{Q} = \frac{\mu_1 - \mu_0}{\sigma_1 + \sigma_0} = \frac{RP_1 - RP_0}{\sigma_1 + \sigma_0} = \frac{R}{\sigma_1 + \sigma_0}2\bar{P}_{RX}\left(\frac{ER}{ER + 1} - \frac{1}{ER + 1}\right) = \frac{R}{\sigma_1 + \sigma_0}2\bar{P}_{RX}\left(\boldsymbol{\frac{ER - 1}{ER + 1}}\right)$$

- Un rapporto di estinzione finito introduce quindi una penalità alle prestazioni del sistema, poiché appare un termine che riduce il fattore $\tilde{Q}$ al ricevitore
- La potenza media necessaria al ricevitore in caso di rapporto di estinzione finito per ottenere un certo livello di prestazioni, cioè un determinato $\tilde{Q}$ al ricevitore, è quindi

$$\boldsymbol{\bar{P}_{RX} = \frac{\sigma_1 + \sigma_0}{2R}\left(\frac{ER + 1}{ER - 1}\right)\tilde{Q}_{target}}$$

Dimensionamento del sistema di comunicazione: sensitivity

- In caso di ricezione diretta di un segnale non amplificato, le deviazioni standard σ_1 e σ_0 sono uguali poiché il rumore elettrico agisce indipendentemente dal livello del segnale

$$\sigma_1 = \sigma_0 = \sigma \rightarrow P_{noise\ el}$$

- In questo caso, si ottiene

$$\boldsymbol{\tilde{Q} = \frac{\mu_1 - \mu_0}{\sigma_1 + \sigma_0} = \frac{\mu_1 - \mu_0}{2\sigma} \approx \frac{1}{2}\sqrt{SNR_{eq}}}$$

- In cui SNR_{eq} rappresenta il rapporto segnale-rumore equivalente
- Spesso, è possibile avere una stima approssimata dalle potenza di rumore generata da un fotodiodo a partire dalla *noise equivalent power* (o *noise equivalent current*)
- **NEP**: parametro caratteristico di un fotodiodo che corrisponde alla potenza necessaria per ottenere un SNR pari a 1; normalmente, il NEP è definito in $\left[\frac{W}{\sqrt{Hz}}\right]$: per ottenere la potenza di rumore complessiva basta calcolare

$$P_{noise\ el} = NEP \cdot \sqrt{B_{el}}$$

- In questo modo

$$\boldsymbol{\bar{P}_{RX} = \frac{\sigma_1 + \sigma_0}{2R}\left(\frac{ER+1}{ER-1}\right)\tilde{Q}_{target} = \frac{2\sigma}{2R}\left(\frac{ER+1}{ER-1}\right)\tilde{Q}_{target} = NEP \cdot \sqrt{B_{el}}\left(\frac{ER+1}{ER-1}\right)\tilde{Q}_{target}}$$